

進度報告 | 2026 年 9 月 21–23 日

全民查證公社

AI 假訊息與詐騙查證系統

原專題名稱「AI 為核心的假訊息驗證系統」的重做版。貼上訊息，或在 Threads 標記機器人，就能拿到 AI 判定與已做出判定的查核來源。

網站

fakenewsverify.vercel.app

Threads 機器人 (本週為模擬模式)

[@factcheck_tw_bot](#)

團隊 廖哲勛 (負責人 / 測試負責人) · 石岱勳 (介面測試) · 姚睿 (績效與品質數據) · 張宇宏 (文件與審查) · 廖育翔 (影片與簡報)
指導教授 黃崇源

全民查證公社

深色

貼上訊息，10 秒知道真假

AI 判定詐騙／假訊息、尚待確認或查無異常，並附上查核來源。

文字

網址

貼上 LINE、Threads 或任何地方看到的
訊息…

0/20000

開始查證

查證約需 5–20 秒；查過的內容會直接命中快取。

試試看

健保卡即日起停用，請點連結重新驗證

網傳吃香蕉配優格會中毒

165 反詐騙專線提醒：遇到「保證獲利」請掛斷

還沒有查證紀錄。到首頁查一則試試。

Threads 查核機器人

在 Threads 回覆可疑貼文並
@factcheck_tw_bot，機器人會在 5 分鐘內
回覆判定與來源。

① 目前為開發模式：只有被加入為測試人員的
Threads 帳號 @factcheck_tw_bot 才會收到
回覆。

為什麼假訊息查證是「劣構問題」

〔需求分析〕

沒有單一標準答案

2

種標籤，出現在同一則謠言上

同一則 SIM 卡謠言：ETtoday 的報導被標「假訊息」、華視的報導被標「安全」。判定對象必須是「被查核的主張」，而不是報導本身。

來源本身會髒

31 / 63

筆熱門牆是 Google News 轉址 (2026-09-15 稽核)

知識庫 237 筆沒有一筆做過來源分級；AI 還會引用求證平台上「有人問、還沒判定」的貼文。

限制一直在變

3


個 AI 服務同一天失效 (2026-09-14)

CGU 401、myai168 的 OpenAI 400 與 Claude 402；Meta 開發模式只讀得到測試者的貼文；原排程一週 152 小時做不完。每一項都得重新取捨。

→ 我們把「怎樣才算可信」本身當成需求來分析，而不是只接一個 AI API。

走完一次完整設計循環

[全部]



第二次循環：2026 上半年的第一版做出可用 MVP → 這次針對第一版暴露的問題重做，每一步都留下文件可回溯

需求分析 → 設計

grill 共識 → 規格 v1.3 (19 條功能需求、測試通過準則) → mockup 9 張畫板 + 強調色比較。規格經兩輪審查，共 45 + 21 條意見。

實作 → 測試驗證

109 張票 (primitives → screens → 後端 / 資料 / Threads)，報告週切片 A 已完成 69 張。測試計畫書 46 項、pytest 700 + 前端 380、150 筆評測。

修正 → 展示

資料清洗 dry-run → 人工審閱 → 套用。3 分鐘 demo 影片。整合 React、Vercel、FastAPI、向量檢索、LLM 闡道、Threads API、Cloudflare Tunnel。

系統架構：一條查證管線、兩個入口

[設計]



快取先擋掉重複的問題

真的沒看過才花 AI 額度：每次 AI 查證約 USD 0.006，命中快取不花額度。

延遲為 2026-09-16 用戶端 p50。0.75 門檻為實測校準：同一謠言改寫版 0.79 ~ 0.82、不同謠言 ≤ 0.68 、不同主題 ≤ 0.52 。

報告週範圍：先做影片看得到的

〔設計 / 修正〕

109

張票 (03_tickets.md)

69

張已完成 (報告週切片 A)

152 h

原排程一週工時，做不完 → 改做切片

報告前完成

文字 / 網址查證、結果頁 /r/{id}

分享到 Threads (Web Intent)

熱門牆、知識庫

來源分級與資料清洗 (D-05 已套用)

Threads 模擬模式閉環

測試計畫書 v1.0 + 本輪測試執行

gpt-5.4-mini 重跑評測、快取延遲量測
(09-16 補做)

報告後 (每項都有票)

Threads 實機串接：Meta App、測試者、token、兩段式發佈與錯誤分流
/bot 狀態頁

向量命中率重測 (PF-2)、評測資料集擴充

UI 深色全套截圖檢核、無障礙 (P-18)

圖片查證 (P1)、文件同步 (B-25)

明確不做

影片查證

FB / IG 平台

把使用者原文送 Google 搜尋

帳號登入

Threads Webhook

理由：成本、隱私，或需要企業驗證

來源分級：只有「已做出判定」的來源才算數

[設計 → 修正]

- Tier 1 查核機構**

台灣事實查核中心、MyGoPen、有 RUMOR / NOT_RUMOR 回覆的 Cofacts、*.gov.tw、WHO / CDC
- Tier 2 主流媒體查核報導**

標題同時含查核語境與判定詞才算 (判的是主張，不是報導)
- Tier 3 其他**

對外不顯示、不寫入「已證實」、不參與向量命中

找不到 Tier 1 / 2 來源

結果頁明示「尚無查核機構證實」、不給綠燈；知識庫頁與向量命中只收已證實的判定。

對外只顯示 Tier 1 / 2：寧可說「還沒被證實」，也不硬給一個看起來有來源的答案。

資料清洗 D-05 (2026-09-16 套用)

知識庫	已證實 128 筆 (113 筆帶向量) 未證實 90 筆保留、不對外
236 → 218	
熱門牆	全部已證實 只留三個查核網站的資料
63 → 24	
Google News 轉址	解析不出真正網址、 爬不到內文、 依規則不得當來源
31 → 0	

流程：dry-run → 人工審閱 → 套用並自動備份。刪除的謬資料類型：徵才公告、小考題、闢謠 TOP10 列表、標籤雲、聊天碎片、一般新聞報導。以本地模型 gpt-oss:20b 做第二意見 (300 筆，不花 OpenAI 額度)。

← 返回 深色

● 尚無查核機構證實

安全資訊

信心高 AI 即時判定

① 尚無查核機構證實

目前找不到已對這則訊息做出判定的查核機構或媒體查核報導，以上為 AI 的初步判讀。轉傳前請先到台灣事實查核中心、MyGoPen 或 Cofacts 查證。

你查的內容

內政部消防署提醒，颱風期間請避免前往海邊與山區，並事先準備手電筒、行動電源及飲用水。

判讀摘要

內政部消防署的防颱安全提醒：颱風期間避免前往海邊與山區，並預先準備手電筒、行動電源與飲用水。

詳細說明

查核來源

尚無查核機構證實這則訊息，請自行查證。

查證時間 2026-09-16 03:27 • AI 判定
判讀由 AI 自動產生，僅供參考，請自行查證。

結果頁：黃燈「尚無查核機構證實」

Threads 機器人：開發模式與上線條件

[實作]

```
poll -> mention m1 -> cache hash -> sources: 1 x tier1 -> reply sim_reply_1  
result_id=eb06622e-0592-4361-bfbd-0046b745cba6 frame_type=red
```

--poll 終端機實際輸出 (模擬模式 · L1 hash 命中 · 未呼叫 AI)

● 詐騙警告

冒用健保署名義的釣魚詐騙：

以「即日起停用、逾期停卡」製造急迫感誘騙點連結，

健保署不會要求民眾點連結驗證健保卡

查核來源：<https://www.mygopen.com/2026/08/line.html>

完整判讀：<https://fakenewsverify.vercel.app/r/eb06622e-...>

AI 自動判讀，請自行查證。

replies.jsonl 實際回覆內容 (≤ 500 字；實機串接後格式相同，只換 Threads 用戶端)

205–264 ms 模擬模式文字提及 → 回覆寫入 (3 輪實測，準則 ≤ 60 s)

使用方式

在可疑貼文底下回覆並標記 @factcheck_tw_bot → 機器人回覆燈號、一句摘要、查核來源、結果頁連結 (≤ 500 字，AI 幻覺出的死連結已被過濾)。

目前進度

模擬模式閉環可展示，處理流程與正式串接完全相同、只換 Threads 用戶端 (讀本機 JSON、寫 replies.jsonl)。實機串接需 Meta App、測試者邀請、60 天 token，以及兩段式發佈與錯誤分流程式 (T-12 / T-13)，排在報告後。

上線條件

未審核前只讀得到測試者的公開貼文；公開給所有人需通過 Meta App Review 與企業驗證，論文列為上線條件。

Threads 查核機器人


在 Threads 回覆可疑貼文並 @factcheck_tw_bot，機器人會在 5 分鐘內回覆判定與來源。

① 目前為開發模式：只有被加入為測試人員的 Threads 帳號 @factcheck_tw_bot 才會收到回覆。

網站首頁的說明卡：對使用者明示「目前為開發模式」

Demo 影片 (約 3 分鐘)

[展示]



播放 demo 影片 (約 3 分鐘)

字幕全程標示模擬模式 · 線上播放：網站 /demo/demo_v0.4.0.mp4

1 Threads 模擬閉環

標記機器人 → 命中快取的紅燈回覆 → 手機結果頁 → 分享回 Threads。

2 三層快取實證

同一則謠言換個說法命中「語意相似」；全新訊息才交給 AI 即時判讀。

3 誠實呈現

模擬模式全程標示、「尚無查核機構證實」橫幅、數據字卡只放已實測的數字。

現場時間不足或影片另交時，只播鏡 3–8 (Threads 模擬閉環 → AI 即時判讀，依分鏡約 2 分鐘)

測試計畫 TP-FNV-2026-01 與目前證據

[測試驗證]

46 項

5 類測試項目 (P0 30) : 操作 9、功能 16、介面 8、績效 7、品質 6

700

後端 pytest 全數通過 (離線、零點數，執行約 1 分鐘)

380

前端單元測試全數通過

CI 綠燈

GitHub Actions test + frontend 兩個 job (commit 49be377)

類別	項目數	本次執行	通過	通過 (待補驗)	未通過	未執行	報告後
操作測試	9	6	3	1	0	1	4
功能測試	16	13	12	0	1	0	3
介面測試	8	6	4	0	0	2	2
績效測試	7	4	1	1	1	1	3
品質測試	6	5	4	0	1	0	1
合計	46	34	24	2	3	4	13

本輪執行結果 (2026-09-16 · 測試計畫書 §6.1)

已驗證、可引用的數字

1.000

150 筆評測 accuracy (FN 0、FP 0)

213 ms

hash 快取命中 p50 (p95 257 ms)

3.06 s

向量快取命中 p50

205–264 ms

Threads 模擬回覆

4.2 通過準則：重測後仍差 3 項 P0

P0 通過：第一輪 23 / 30 → 重測後 27 / 30 (含待補驗 3)。

第一輪未通過 3：FN-4 (Threads 錯誤處理) 與 QA-2 (評測報告欄位) 已修正、09-20 重測通過；PF-2 向量命中率 65% 未達 70% (差 1 筆) 仍未通過——未命中句的相似度確實低於門檻，不調低門檻，10-05 前以組員審定題組重測。

第一輪未執行 4：PF-1 重測通過 (未命中 p50 4.86 s / p90 6.64 s)、OP-1 全新安裝 4 分 07 秒 (待補驗)；UI-1 深色全套與組員勾核、UI-6 簡繁比對仍未執行。

審查建議：有條件通過——引用已驗證數字，同時揭露未達標項目與時程。


評測結果：舊模型 vs 新模型（150 筆標註）

[測試驗證]

資料集：150 筆人工標註（SCAM / MISINFO / SAFE 各 50）· 刻意放入「像詐騙的合法官方訊息」當難題。

舊：gpt-5-mini

myai168 闢道 · 2026-06 (git 9d63eef)



96.0%

accuracy

0.960


macro-F1

FN 0 · FP 5

FN = 風險訊息被判成安全

新：gpt-5.4-mini

長庚 CGU AIR 闢道 · 2026-09-16 重跑 (推理強度 medium、web_search 關)



100%

accuracy

1.000

macro-F1

FN 0 · FP 0

FN = 風險訊息被判成安全

成對比較

兩模型判定不同的 6 筆全是「舊錯新對」（5 筆合法官方宣導被舊模型判成 SCAM、1 筆 MISINFO 判成 SCAM），0 筆「舊對新錯」；精確 McNemar 檢定 $p = 0.031$ 。舊模型那 6 筆的信心都 ≥ 0.9 ，代表信心未校準。

限制（老實說）

150 筆對新模型已飽和（accuracy 95% CI 下限 0.976），無法再區分模型或設定，需擴充資料集（例如 300 筆）並做信心校準；兩次也不只換模型——闢道與推理強度都不同，差異不能全歸因於模型本身。

成本與風險

[修正]

USD 10

新學期 CGU AIR 額度 (另有本地模型 1,000 萬 tokens) ; 不另購 API

≈ USD 1.2

截至 2026-09-16 已用 : 評測 0.94 、 影片配音與測試約 0.25

USD 0.006

每次 AI 查證 (未命中) 平均 ; 評測與 批次一律關閉 web_search

USD 0.14

demo 影片製作 (配音、語音抽查、實錄)

風險 → 對策 (每一項都有「壞了還能 demo」的退路)

CGU 是唯一 AI 來源

AI 失敗回固定 fallback、不寫入知識庫、不回覆 Threads ; 額度用盡時網站顯示灰卡，不假裝判定。

後端在免費雲端主機 (Render)

09-19 已上雲 (Render + Supabase) : 閒置會休眠，排程每 10 分鐘喚醒 ; 每日 AI 上限 300 次 ; 可退回個人電腦 + tunnel ; 影片預錄。

資料清洗可能過度降級，知識庫與向量命中縮水

先 dry-run、人工審閱後才套用並自動備份 ; 已證實 128 筆 ≥ 門檻 125 ; 向量命中率 65% 待重測 (DEF-05 修 11 筆向量) 。

本輪測試發現並修正的缺陷 (都補了回歸測試)

DEF-01

結果頁偶發 500 : 讀到寫一半的 tasks.parquet → 改先寫暫存檔再原子替換、讀取失敗重試 ; 全套 478 通過、存取 log 0 次 5xx 。

DEF-02

舊任務 AI 失敗的結果仍可「分享到 Threads」→ 改以 is_fallback() 推導 ai_unavailable，分享資料改為 null 。

QA-2 ③

評測全對時錯誤檔殘留舊模型 6 筆 → 0 筆錯誤時輸出只有表頭的空檔。

下一步

[下一輪循環]

09-21 ~ 23

進度報告

本簡報 + demo 影片

09-24 ~ 30

Threads 實機串接

Meta App、測試者、token；兩段式發佈與錯誤分流 (T-12 / T-13) → 實機端到端回覆驗證 → /bot 狀態頁；文件同步 B-25

10-05 前

驗證補齊

向量命中率重測 (先修 11 筆向量維度)；擴充評測資料集 (300 筆) 與信心校準；UI 深色全套與無障礙；計畫書 §6 更新

上線前待決

三個決定

低信心紅燈是否降為黃燈 (D-6)；免費雲端方案能否長期使用 (後端已於 09-19 上雲)；Meta App Review 與企業驗證

下一輪循環從實機串接開始；完成後把新評測與測試結果填進測試計畫書第 6 節。

fakenewsverify.vercel.app · [@factcheck_tw_bot](https://twitter.com/factcheck_tw_bot) · 目前 Threads 為模擬模式；公開服務需通過 Meta App Review 與企業驗證

文件：docs/rebuild/00_consensus.md → 01_spec.md → 03_tickets.md → docs/test/TP-FNV-2026-01.md → docs/demo/storyboard.md