

AI 為核心的 假訊息驗證系統

系統名稱：全民查證公社

報告別	第三次進度報告
報告日期	2026 年 9 月
團隊成員	廖哲勛、石岱勳、姚睿、張宇宏、廖育翔
指導教授	黃崇源
系統網址	https://fakenewsverify.vercel.app
原始碼	github.com/cansfakenewsverify/AI-Fake-News-Verification-System

指導教授簽名

簽名：_____ 日期：

一、這一期做了什麼

上次報告時，系統只能在組員自己的電腦上跑。這一期最主要的進展是**整套系統已經上線**，2026 年 9 月 19 日起任何人都能直接打開網址使用，不需要有人開著電腦，也不需要註冊或登入。

這一期完成的項目：

1. **上雲**：前端部署到 Vercel、後端部署到 Render、資料改存 Supabase 的 PostgreSQL (含 pgvector 向量索引) 。
2. **介面重做**：依規格書 v1.3 與設計稿重寫前端，統一文案與紅黃綠燈的使用規則。
3. **來源紀律**：只採計已經做出判定的查核來源；找不到就明白標示「尚無查核機構證實」，而且不給綠燈。
4. **上線護欄**：每日 AI 呼叫上限、每個 IP 的頻率限制、請求與上傳大小上限。
5. **測試計畫書**：依課程格式完成 TP-FNV-2026-01 (5 類 46 項)，執行兩輪並記錄未結缺陷。
6. **簡報影片**：依老師 9 月 20 日的規定，錄製 4 分 38 秒的預錄簡報影片，畫面全部是正式站實錄。

二、系統在做什麼

使用者把收到的可疑訊息 (文字或網址) 貼到網站上，系統判定它是**詐騙**、**假訊息**、還是**查無異常**，以紅黃綠燈呈現，並附上已經做出判定的查核來源。判不出來的內容標為「無法查證」。每一筆結果都有自己的網址，可以複製連結或分享到 Threads。

除了單筆查證之外，網站還有三個部分：

- **熱門牆**：彙整 MyGoPen、台灣事實查核中心與 Cofacts 的查核結果。
- **知識庫**：所有查證過而且有來源佐證的內容都留在這裡，可以搜尋與依判定篩選。
- **Threads 查核機器人**：在可疑貼文底下標記機器人，它會回覆判定、來源與結果頁連結。目前以**模擬模式**展示，尚未對外開放 (原因見第六節) 。

三、系統架構

瀏覽器

- └ Vercel (前端 : React 靜態檔 ; /api/* 同源代理)
 - └ Render (後端 : FastAPI)
 - └ Supabase PostgreSQL + pgvector (知識庫、結果、熱門、用量)
 - └ 長庚 CGU AIR 閘道 (判讀模型 gpt-5.4-mini ; 向量模型 text-embedding-3-small)

金鑰只存在兩個地方：負責人本機的設定檔與 Render 後台，版本庫是公開的，裡面不含任何金鑰。

判讀流程：先找答案，找不到才問 AI

呼叫大型語言模型是整個系統最貴的一步，所以設計了三層，只有前兩層都沒有命中時才真的呼叫 AI：

層	比對方式	說明	實測延遲
L1	內容雜湊	完全相同的內容直接沿用先前的判定。	213 ms
L2	向量語意相似	換句話說也認得。相似度門檻 0.75，且只比對已經證實的資料列。	約 3.1 秒
L3	AI 判讀	前兩層都沒中才呼叫一次模型；判讀對象一律是使用者的原文。	9–27 秒

門檻 0.75 是實際量測校準的結果：同一則謠言的改寫版相似度落在 0.79–0.82，不同謠言之間不超過 0.68。先前使用的 0.88 會把所有改寫版本擋掉，等於讓向量層失去作用。

上線護欄

項目	設定值	目的
每日 AI 呼叫上限	300 次 / 日	控制學校提供的額度；達上限後仍可回覆快取命中的內容。
每個 IP 的頻率限制	30 次 / 分、200 次 / 時	避免單一來源大量佔用。
請求與上傳大小	1 MB / 圖片 10 MB	避免超大請求拖垮免費主機。

四、評測結果

自建 150 筆已標註的訊息資料集（詐騙、假訊息、安全各 50 筆），其中刻意放入「看起來像詐騙的合法官方訊息」作為難題。同一份題目在換模型前後各跑一次：

版本	判讀模型	準確率	macro-F1	漏判	誤報
前一版（2026-06）	gpt-5-mini	96.0%	0.960	0	5
現行（2026-09-16）	gpt-5.4-mini	100%	1.000	0	0

兩次評測都沒有把任何詐騙或假訊息判成安全（漏判為 0）；前一版的 5 次誤報全部是把反詐宣導或政府補助公告誤判成詐騙，新版已全部判對。現行結果的 95% 信賴區間為 0.976–1.000。

這個 100% 不能解讀成「系統不會出錯」。150 筆全部判對，代表這組題庫對現行模型已經飽和，分不出模型或設定之間的差異；而且題庫自 2026 年 6 月起就公開在版本庫中，無法排除新模型看過。下一步是把題庫擴充後再比較，這一點在報告與投影片中都會一併說明。

五、測試與品質

自動化測試

後端 700 項、前端 385 項自動化測試，全部離線執行、不消耗 AI 額度，每次提交由 GitHub Actions 自動跑完。另有 24 項針對雲端資料庫的契約測試，確保本機檔案版與 PostgreSQL 版行為一致。

測試計畫書 TP-FNV-2026-01

依課程格式撰寫，含 5 類 46 項測試、通過準則、中止與再繼續規則。第一輪 P0 通過 23 / 30，修正缺陷後重測為 27 / 30。未通過與未執行的項目都列出原因與補做時程：

項目	狀態	說明
PF-2	未通過	語意快取命中率 65% (13 / 20)，未達 70% 的準則。 沒有為了讓它通過而調低 0.75 的門檻 ，因為那是實測校準值，調低會提高誤命中。已排定由組員重新出題後重測。
UI-1	已補齊素材	介面逐格檢核。深色版截圖已於 9 月 20 日補齊 (54 張)，檢核表共 143 列，由非實作組員勾核、另一位組員覆核中。
UI-6、PF-1、OP-1	未執行	分別需要另外安裝的比對工具、未合入的量測參數，以及全新環境的重新取得流程；均非測試失敗。

六、誠實交代的限制

1. **Threads 機器人尚未對外開放**。流程與程式都完成並以模擬模式驗證過，但要公開回覆一般使用者，必須先通過 Meta 的 App Review 與企業驗證；在那之前只有被加入測試名單的帳號收得到回覆。簡報影片中這一段全程標示為模擬模式。
2. **評測資料集已飽和** (見第四節)。
3. **語意快取命中率未達準則** (見第五節)。
4. **免費雲端方案的限制**：後端 15 分鐘沒有流量會休眠，喚醒約需 1 分鐘；前端已能在喚醒期間自動重試並顯示提示，但第一次查詢仍可能較慢。
5. **知識庫仍有待清理的資料**：9 月 20 日檢查發現雲端知識庫 128 筆中，有 24 筆的「查核來源」其實是求證平台上尚未有判定的回報貼文，卻被標成查核機構等級。這與本專題「只有已做出判定的來源才算來源」的原則不符，已列入待辦，會在下一期清除或重新標記。
6. **AI 判讀僅供參考**：網站每一頁都標示判讀由 AI 自動產生、可能有誤，請使用者自行查證，並提供隱私政策與資料刪除說明。

七、下一步

1. **Threads 實機串接**：申請 Meta App Review 與企業驗證，完成後對外開放。
2. **擴充評測資料集並重新評測**，取得能分辨模型差異的結果。
3. **完成 PF-2 重測**，並清理第六節第 5 點的知識庫資料。
4. **補做 UI-6、PF-1、OP-1 三項未執行的測試**。
5. **開放首頁的圖片上傳介面** (後端端點已具備檔頭檢查與大小限制)。

八、分工

成員	角色	這一期負責的工作
廖哲勛	組員 A · 測試負責人	系統實作與部署、測試執行與彙整、金鑰與資料管理。
石岱勳	組員 B · 介面測試	介面截圖逐格勾核、手機實機與行動網路測試。
姚睿	組員 C · 績效與品質數據	語意快取題組出題與命中率量測、效能數據整理。
張宇宏	組員 D · 文件與審查	維護測試計畫書、覆核檢核表、文件一致性檢查。
廖育翔	組員 E · 影片與簡報	簡報影片與投影片、報告呈現。

九、附件與可查證的位置

項目	位置
線上系統	https://fakenewsverify.vercel.app
簡報影片 (4 分 38 秒)	https://fakenewsverify.vercel.app/demo/presentation_v1.mp4
原始碼	github.com/cansfakenewsverify/AI-Fake-News-Verification-System
測試計畫書	docs/test/TP-FNV-2026-01.md (v1.5)
評測資料與結果	code/backend/data/eval_set.csv 、 eval_*.csv
介面檢核表與截圖	docs/test/ui_checklist.csv 、 docs/test/screens/
規格與設計文件	docs/rebuild/ (共識、規格書 v1.3、設計稿、實作票、部署手冊)

本專題的程式實作與自動化測試執行，包括撰寫程式與測試碼、執行測試、評測與量測腳本、以無頭瀏覽器擷取截圖與彙整紀錄檔，由 AI 程式開發助理 Claude Code (Anthropic) 協助完成， 全程在負責人監督下進行。需要人工判斷的工作——介面勾核、資料清洗審閱、測試結論與簽核——由組員與審查者執行， 不由 AI 代為判定。此一說明同時記載於測試計畫書中。