AI 為核心的假訊息驗證系統

An AI-Centered Misinformation Verification System

系統名稱：**全民查證公社** ｜ 指導教授：黃崇源 ｜ 組員：廖晢勛、石岱勳、姚睿、張宇宏、廖育翔

系統架構

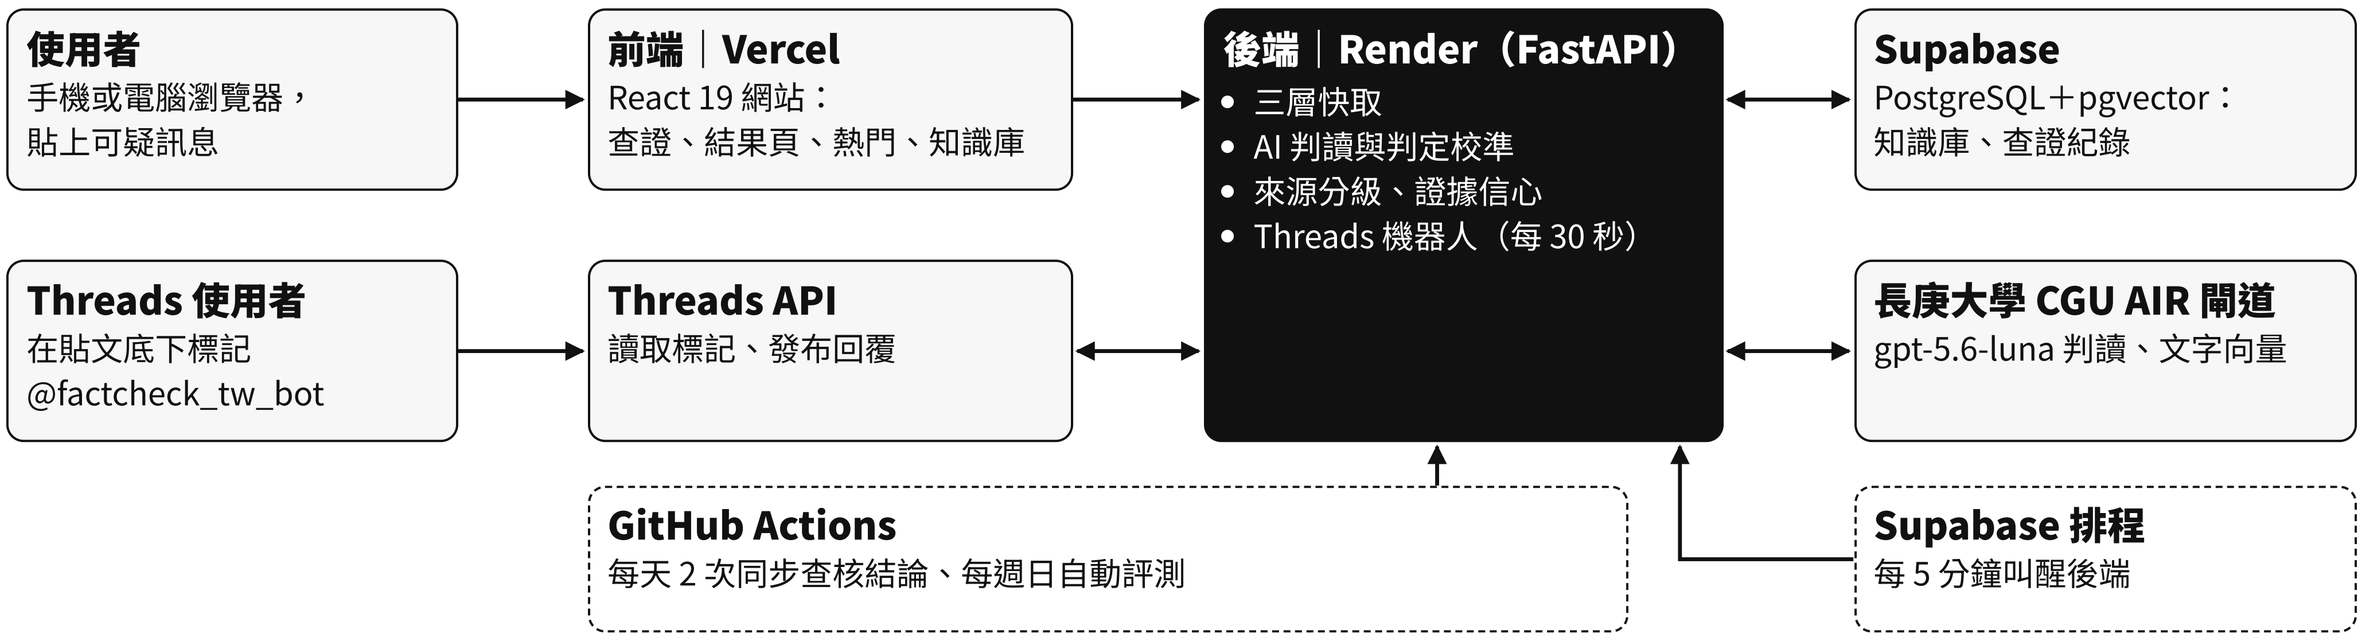


圖 5　系統架構：網站與 Threads 機器人共用同一個後端與知識庫；查核結論由 MyGoPen、台灣事實查核中心、Cofacts 每天同步

研究方法

三層快取 查過就記住，省時間也省成本

L1	**內容雜湊**	一字不差就命中	0.2 秒
L2	**語意向量**	cos ≥ 0.75，只比已證實資料	約 3 秒
L3	**AI 判讀**	每次約 USD 0.0014	中位數 4.8 秒

任何一層命中就直接回答；AI 的結果經來源分級後寫回知識庫。

來源分級 還沒被查證的不能當來源

第 1 級　查核機構　台灣事實查核中心、MyGoPen、已回覆的 Cofacts、政府機關
第 2 級　媒體查核　其他媒體的查核、闢謠報導
第 3 級　未查證　一般新聞、社群貼文：只列為相關討論

沒有第 1、2 級來源，就不給綠燈。

證據信心 看「夾角」，不看 AI 自評

信心	依據：與查核機構已證實內容的夾角
高	≤ 41°（cos ≥ 0.75）：同一則訊息換個說法
中	≤ 49°（cos ≥ 0.65）且判定有風險，或符合已知話術
低	沒有相近的查核案例，只有 AI 判斷

判為安全、卻和已知謠言相近時，信心降為低並提醒使用者。

判定校準 每週用新查核結論檢驗後調整

- 查不到、也沒有造假跡象：回「無法查證」，不硬判真假。
- 轉傳片段、照片影片說明、聳動說法：有疑點仍判假訊息。
- 冒名官方帳號、「解除分期」、代辦門號：判為詐騙。

上線前以 306 題開發組比較 v1～v4，選漏判最少的 v4（10/15 上線）。

實驗結果

150 題評測 2026-10-15



漏判 0、誤報 0。真實訊息中查不到出處的官方公告回「無法查證」（黃燈），沒有一題被判成假訊息或詐騙。

圖 6　150 題評測結果（每列為一種正確答案，色塊為系統的判定）

每週新查核自動評測

每週日自動出題：歷史抽樣約 2,600 題＋當週新查核。

	10/05 校準前	10/12 v2	10/19 v4
謠言被判成安全（漏判）	10.4%	12.8%	**2.0%**
真實內容被判紅燈（誤報）	68.5%	55.0%	**54.0%**
當週新謠言：漏判	6／41	4／24	**1／29**
當週新謠言：無法查證	0／41	0／24	**9／29**

前兩列為歷史抽樣；當週新謠言題數少，只看趨勢。

18,745 筆
查核機構已證實的假訊息與詐騙，每天自動同步

0.2 秒
相同訊息再查一次（快取命中）

4.8 秒
新訊息的 AI 判讀（中位數）

1,260 項
自動化測試（後端 851、前端 409），每次更新都跑

研究限制

- 150 題題庫已公開也偏簡單，數字偏樂觀；以每週新查核評測為準。
- 真實的轉傳訊息仍有過半被判紅燈，誤報偏高。
- AI 不連網搜尋，最近發生的事常回「無法查證」。
- Threads 機器人在 Meta 開發模式，只回覆測試人員。

結論與未來展望

先比對查核機構的結論、再交給 AI 判讀；
只列已判定的查核來源，查不到就說查不到。

下一步：降低真實訊息的誤報、找一般使用者實測、用不公開的新題庫量上線準確率、開放圖片查證。