# 測試報告書

**結論：第二次簡報輪次未達通過條件。** 共 62 個測試項目：通過 38、通過（待補驗）3、未通過 4、未執行 4、待裁定 1、報告後執行 12。最大的問題是學校 2026-11-03 起不再提供 embedding，語意比對停用（DEF-13）。同日上線關鍵字備援比對，情境劇兩則訊息都查得到查核報告，但改寫句有誤命中（DEF-14），未命中的查證也變慢。

## 1. 名稱、編號與版本

| 項目 | 內容 |
|---|---|
| 計畫名稱 | 全民查證公社 AI 假訊息與詐騙查證系統（原專題名稱：AI 為核心的假訊息驗證系統） |
| 計畫編號 | `TP-FNV-2026-01` |
| 版本與日期 | v2.1，2026-11-03 |
| 受測系統 | 網站 `https://fakenewsverify.vercel.app`、Render 後端、Threads 機器人 `@factcheck_tw_bot`（測試版） |
| 詳細版 | `03_測試計畫書_TP-FNV-2026-01_v2.1_完整版.pdf`：逐項步驟、各輪重測與原始紀錄 |

| 版本 | 日期 | 內容 |
|---|---|---|
| v1.0 | 2026-09-16 | 第一輪 46 項實測結果 |
| v1.4～v1.9 | 2026-09-20～10-15 | 第一輪重測、換模型與判定校準後重測 |
| v2.0 | 2026-10-30 | 第二次簡報版：新增 16 項與需求追溯矩陣 |
| v2.1 | 2026-11-03 | 回填實測；登錄 DEF-13；整體判定未達成 |

## 2. 測試範圍

涵蓋文字與網址查證、結果頁與分享、Threads 機器人、知識庫與查核同步、熱門牆、資料清洗、準確率、延遲與使用者測試。

不納入本輪：圖片上傳（介面尚未開放）、每日查核貼文（FR-12）。研究限制：歷史安全題被判紅燈的比例仍有 51.9%（315／607，10-26）；本週新查核每週只有 9～41 題，信賴區間很寬，只看趨勢。

## 3. 環境與通過準則

| 項目 | 規格 |
|---|---|
| 正式環境 | Vercel 前端、Render 免費方案 FastAPI、Supabase Postgres＋pgvector（知識庫 18,813 筆，2026-11-03） |
| AI | 學校 CGU AIR 閘道 `gpt-5.6-luna`；embedding `text-embedding-3-small` 已無法使用（DEF-13），改用關鍵字備援比對 |
| 測試電腦 | i7-13700HX、32 GB RAM、Windows 11；Python 3.12、Node.js 24 |
| 自動化 | GitHub Actions：`ci`、`factcheck-sync`（每天 2 次）、`weekly-eval`（每週日） |

本輪通過條件（看第二次簡報輪次新增的 16 項）：P0 全部通過；P1 通過率 80% 以上，未執行算未通過；`pytest`、`npm run build` 與 `ci` 全綠。

| 指標 | 案例 | 計算方式 | 門檻 | 最新結果 | 判定 |
|---|---|---|---|---|---|
| 漏判 | QA-1a | 150 題中有風險卻判 SAFE 的筆數 | 0 | 0（10-15） | 達成 |
| 未命中延遲 | PF-1 | 150 題的 p50／p90 | ≤15 s／<20 s | 5.87 s／8.31 s（09-30）；語意比對停用期間約 27.7 s（n＝11，11-03） | 09-30 達成；停用期間未達 |
| 語意快取命中率 | PF-2 | 20 句改寫句的命中比例 | ≥70% | 語意比對 50%（09-21）；關鍵字備援正確 10 句＝50%（11-03，另有 2 句相關、2 句錯誤） | 未達成 |
| 快取命中延遲 | PF-7 | 正式站 p50：已證實／未證實 | 都 ≤5 s | 1.22 s／12.61 s（11-03） | 未達成 |
| 查核同步成功率 | OP-11 | 最近 30 次成功次數 | ≥90% | 25／30＝83.3%（11-03） | 未達成 |
| 每週歷史漏判率 | QA-6 | 歷史風險題判 SAFE 的比例 | ≤10.4% | 2.1%（10-26）；4.7%（11-02，閘道不穩） | 達成 |
| 第三方實測 | UX-1 | T1 達成率／SUS 平均 | ≥80%／≥68 | 尚未量測 | 未執行 |

缺陷分級：高＝使 P0 無法達成或中斷主流程；中＝影響 P1 或有替代操作；低＝外觀、文案或舊資料。

## 4. 測試案例總表

狀態是各項目目前最新的判定。「待補驗」計為通過，但還有延後的子項目。

| 編號 | 優先 | 測試項目 | 預期 | 狀態 | 備註 |
|---|---|---|---|---|---|
| OP-1 | P0 | 全新環境啟動 | clone 後 5 分鐘內前後端可用 | 通過（待補驗） | 09-20 重測 |
| OP-2 | P0 | AI 連線 | 回合法判定、非 fallback | 通過 | |
| OP-3 | P0 | 模擬 Threads 一輪 | 新增回覆、/bot 顯示 | 通過（待補驗） | /bot 顯示待補驗 |
| OP-4～OP-6 | P1 | Threads 授權、讀取、token 續期 | 實機可授權與續期 | 報告後執行 | 10-01 實機串接成功，未逐項判定 |
| OP-7 | P0 | 舊資料相容 | 載入成功、筆數不變 | 通過 | |
| OP-8 | P0 | 手機開結果頁 | 4G 可看到結果 | 通過 | 09-20 重測 |
| OP-9 | P0 | 清洗 dry-run | 不改檔、列出影響筆數 | 通過 | |
| OP-10 | P0 | Threads 實機回覆 | 2 分鐘內回覆，附 Tier 1 來源 | 未執行 | 阻礙已排除，待負責人實機執行 |
| OP-11 | P1 | 查核同步穩定度 | 最近 30 次成功率 ≥90% | 未通過 | 25／30；11-02 起恢復成功，舊失敗約 2 週才移出 |
| OP-12 | P1 | 每週評測排程 | 每週有報告、剩餘 ≥ USD 3 | 通過 | 10-04 起五次 |
| FN-1 | P0 | AI 契約 | 新契約測試全過 | 通過 | |
| FN-2a | P0 | 網址安全 | 私網網址回 422、不發請求 | 通過 | |
| FN-2b | P1 | 圖片查證 | 格式與大小檢查 | 報告後執行 | 介面未開放 |
| FN-2c | P1 | 相似查證來源 | 只取已證實列 | 報告後執行 | |
| FN-3 | P0 | 結果 API | 各狀態回應正確 | 通過 | |
| FN-4 | P0 | 機器人流程 | 長度、退避、錯誤分流 | 通過 | 09-20 重測 |
| FN-5 | P0 | 回覆模板 | 七種第一行、長度限制 | 通過 | |
| FN-6 | P0 | 燈號判定 | 對照表全部正確 | 通過 | |
| FN-7 | P0 | fallback 判斷 | 判斷方式統一 | 通過 | |
| FN-8 | P0 | 知識庫 API | 搜尋、分頁、只回已證實 | 通過 | |
| FN-9 | P0 | 管理端點權限 | 無 token 回 401 | 通過 | |
| FN-10 | P1 | AI 額度護欄 | 超過上限回 429 | 報告後執行 | 測試已通過，未另行判定 |
| FN-11 | P0 | 快取分層 | hash 與語意都能命中 | 通過 | 離線 fixture，不受 DEF-13 影響 |
| FN-12 | P0 | 來源分級 | 網址對應正確 tier | 通過 | |
| FN-13 | P0 | 知識庫寫入門檻 | 四組驗收正確 | 通過 | |
| FN-14 | P0 | 清洗腳本 | dry-run 不改檔 | 通過 | |
| FN-15 | P1 | 查核結果回補 | 命中後改回已證實列 | 通過 | |
| FN-16 | P1 | 熱門排行 | 時間衰減、只回已證實 | 通過 | |
| FN-17 | P1 | 證據信心 | 規則表每列有案例 | 通過 | 正式站受 DEF-13 影響 |
| FN-18 | P1 | 同步程式 | recent／full、單一來源失敗不擋 | 通過 | |
| FN-19 | P1 | 每週評測程式 | 額度計算、報告欄位完整 | 通過 | |
| FN-20 | P0 | 無法查證 | 黃燈、不算漏判或誤報 | 通過 | |
| FN-21 | P1 | 分類顯示 | 不再顯示「其他」 | 通過 | |
| FN-22 | P1 | 機器人雲端運作 | 狀態存資料庫、token 自動續期 | 通過 | |
| UI-1 | P0 | 全畫面截圖檢核 | 深淺色全套，組員勾核 | 未執行 | 缺深色全套與非實作組員勾核 |
| UI-2 | P0 | 手機版面 | 360 px 無橫向捲動 | 通過 | |
| UI-3 | P1 | 顏色紀律 | 燈號色只用在指定元件 | 通過 | |
| UI-4 | P0 | 深淺色 | 切換後重整保持 | 通過 | |
| UI-5 | P1 | 無障礙 | Lighthouse ≥90 | 報告後執行 | |
| UI-6 | P0 | 文案一致 | 與文案表逐字一致 | 未執行 | 英文字允許清單待裁定 |
| UI-7 | P1 | Threads App 內開啟 | 燈號首屏可見 | 報告後執行 | |
| UI-8 | P0 | 來源顯示 | 抽查 10 筆都有 tier 標示 | 通過 | |

| 編號 | 優先 | 測試項目 | 預期 | 狀態 | 備註 |
|---|---|---|---|---|---|
| UX-1 | P1 | 第三方實測 | 5～8 人；T1 ≥80%、SUS ≥68 | 未執行 | 記錄表還是空白 |
| UX-2 | P1 | 情境訊息查證 | 兩次判定相同，影片畫面皆為實錄 | 未通過 | 判定相同；Threads 段還是示意畫面 |
| PF-1 | P0 | 未命中延遲 | p50 ≤15 s、p90 <20 s | 通過 | 5.87 s／8.31 s |
| PF-2 | P0 | 語意快取命中率 | ≥70% | 未通過 | 關鍵字備援正確 50%（DEF-14） |
| PF-3a | P0 | 機器人可控延遲 | ≤60 s | 通過（待補驗） | 模擬 205～264 ms |
| PF-3b | P1 | Threads 端到端時間 | 記錄 5 次 | 報告後執行 | |
| PF-4 | P1 | 模擬 10 則處理時間 | 一輪 <3 分鐘 | 報告後執行 | |
| PF-5 | P1 | 成本 | 150 題 ≤ USD 1.5 | 通過 | |
| PF-6 | P1 | 模型比較組 | 記錄項，可選 | 報告後執行 | |
| PF-7 | P1 | 正式站快取命中延遲 | 兩類 p50 都 ≤5 s | 未通過 | 未證實列 12.61 s；DEF-11 |
| QA-1a | P0 | 150 題漏判 | FN＝0 | 通過 | |
| QA-1b | P1 | 150 題準確率 | accuracy ≥93%、FP ≤8 | 待裁定 | 風險題全對、FP 0；安全題 32 題判無法查證，嚴格算 78.7% |
| QA-2 | P1 | 報告欄位 | 含模型、日期、耗時 | 通過 | 09-20 重測 |
| QA-3 | P0 | CI | 每次 push 綠燈 | 通過 | |
| QA-4 | P1 | 文件與程式一致 | 文件審查勾核 | 報告後執行 | |
| QA-5 | P0 | 清洗審查 | 報告數字與資料一致 | 通過 | |
| QA-6 | P0 | 每週評測漏判 | v4 不高於校準前 10.4% | 通過 | 見第 3 節 |
| QA-7 | P0 | 回歸 | pytest、前端測試、lint、build、ci 全綠 | 通過 | 970 passed、410 pass（11-03） |

## 5. 缺陷清單

共 14 筆：未修復或未裁定 6 筆（DEF-03、04、08、11、13、14），已修正 8 筆。DEF-09 以後的嚴重度依第 3 節定義判定。

| 編號 | 問題 | 嚴重度 | 狀態 | 對應案例 |
|---|---|---|---|---|
| DEF-14 | 關鍵字比對會誤命中：很短的詐騙話術可能配到別的詐騙訊息 | 中 | 未修復 | PF-2 |
| DEF-13 | 學校閘道關閉 embedding（`/embeddings` 回 404），語意比對與證據信心停用 | 高 | 已緩解，語意比對仍停用 | OP-10、OP-11、UX-2 |
| DEF-12 | 結果頁分類一律顯示「其他」 | 中 | 已修正 | FN-21 |
| DEF-11 | 命中未證實列要 13～16 秒：回補時重新呼叫 embedding | 中 | 未修復 | PF-7 |
| DEF-10 | 閘道下架 `gpt-5.4-mini`，未命中的查證全回 fallback | 高 | 已修正 | PF-1、QA-1a |
| DEF-09 | 後端冷啟動時結果頁顯示連不上伺服器 | 中 | 已修正 | OP-8 |
| DEF-08 | 橫幅與錯誤文字顏色的規格文字衝突 | 低 | 待裁定 | UI-3 |
| DEF-07 | 寫入知識庫時印出 pandas 警告 | 低 | 已修正 | 無 |
| DEF-06 | 模型價格設定與閘道實際計價不符 | 低 | 已修正 | PF-5 |
| DEF-05 | 11 筆向量維度不對，壓低語意命中率 | 中 | 已修正 | PF-2 |
| DEF-04 | 部分已證實列其實是文章標題 | 低 | 未處理 | UI-8 |
| DEF-03 | 同一主張有兩張卡、標籤不同 | 低 | 未處理 | 無 |
| DEF-02 | 舊任務 AI 失敗仍標成有效判定 | 低 | 已修正 | FN-3 |
| DEF-01 | 結果頁偶發 500 並停止輪詢 | 高 | 已修正 | FN-3 |

## 6. 需求追溯矩陣

| 需求 | 內容 | 對應案例 | 結果 |
|---|---|---|---|
| FR-01 | 文字查證 | FN-1、FN-20、PF-1、PF-7、QA-1a、QA-6 | 部分：PF-7 未達標；語意比對停用 |
| FR-02 | 網址查證 | FN-2a、FN-2c | 通過 |
| FR-03 | 圖片查證 | FN-2b | 後端有端點，介面未開放 |
| FR-04 | 結果頁 | FN-3、FN-21、UI-2、OP-8、UI-1 | 部分：UI-1 未執行 |
| FR-05 | 分享到 Threads | UI-7、UX-1 | 未驗證 |

| 需求 | 內容 | 對應案例 | 結果 |
|---|---|---|---|
| FR-06 | 熱門牆 | FN-16、UI-1 | 部分：UI-1 未執行 |
| FR-07 | 知識庫搜尋 | FN-8 | 通過 |
| FR-08 | 查證歷史 | UI-1 | 部分：單元測試通過，UI-1 未執行 |
| FR-09 | Threads 機器人 | FN-4、FN-5、FN-22、OP-10、PF-3a | 部分：OP-10 未執行 |
| FR-10 | 模擬 Threads | OP-3、FN-4 | 通過 |
| FR-11 | 機器人狀態頁 | OP-3、UI-1 | 部分：已上線，截圖檢核未做 |
| FR-12 | 每日查核貼文 | 無 | 不在範圍 |
| FR-13 | 隱私與資料刪除頁 | UI-1 | 部分：已上線，UI-1 未執行 |
| FR-14 | AI 額度護欄 | FN-10、PF-5 | 通過 |
| FR-15 | 工程清理 | OP-1、OP-7、QA-3、QA-7 | 通過 |
| FR-16 | 來源分級與顯示 | FN-12、UI-8 | 通過 |
| FR-17 | 知識庫寫入門檻 | FN-8、FN-11、FN-13 | 通過 |
| FR-18 | 資料清洗 | OP-9、FN-14、QA-5 | 通過 |
| FR-19 | AI 來源規則 | FN-1、OP-2 | 通過 |
| FR-20 | 查核結果回補 | FN-15、PF-7 | 部分：DEF-11 |
| FR-21 | 本站熱門查證 | FN-16 | 通過 |
| FR-22 | 證據信心 | FN-17 | 部分：正式站受 DEF-13 影響 |
| FR-23 | 查核結論同步 | FN-18、OP-11 | 部分：已恢復寫入，OP-11 仍未達 90% |
| FR-24 | 每週新查核評測 | FN-19、OP-12、QA-6 | 通過 |