測試報告書

結論：第二次簡報輪次未達通過條件。 共 62 個測試項目：通過 38、通過（待補驗）3、未通過 3、未執行 5、待裁定 1、報告後執行 12。最大的問題是學校 2026-11-03 起不再提供 embedding，語意比對停用（DEF-13），網站對改寫過的謠言查不到查核來源；判讀與快取命中仍可使用。

1. 名稱、編號與版本

項目	內容
計畫名稱	全民查證公社 AI 假訊息與詐騙查證系統（原專題名稱：AI 為核心的假訊息驗證系統）
計畫編號	`TP-FNV-2026-01`
版本與日期	v2.1，2026-11-03
受測系統	網站 `https://fakenewsverify.vercel.app`、Render 後端、Threads 機器人 `@factcheck_tw_bot`（測試版）
撰寫與審查	撰寫：廖晢勛，由 Claude Code 協助；審查：張宇宏、指導教授黃崇源
詳細版	`03_測試計畫書_TP-FNV-2026-01_v2.1_完整版.pdf`：逐項步驟、各輪重測與原始紀錄

版本	日期	內容
v1.0	2026-09-16	第一輪 46 項實測結果
v1.4～v1.9	2026-09-20～10-15	第一輪重測、換模型與判定校準後重測
v2.0	2026-10-30	第二次簡報版：新增 16 項與需求追溯矩陣
v2.1	2026-11-03	回填實測；登錄 DEF-13；整體判定未達成

2. 測試範圍

涵蓋文字與網址查證、結果頁與分享、Threads 機器人、知識庫與查核同步、熱門牆、資料清洗、準確率、延遲與使用者測試。

不納入本輪：圖片上傳（介面尚未開放）、每日查核貼文（FR-12）。安全內容被誤判為紅燈的比例仍高，列為研究限制，見第 8 節。

3. 環境與通過準則

項目	規格
正式環境	Vercel 前端、Render 免費方案 FastAPI、Supabase Postgres＋pgvector（知識庫 18,806 筆，2026-11-03）
AI	學校 CGU AIR 閘道 `gpt-5.6-luna`；embedding `text-embedding-3-small` 已無法使用（DEF-13）
測試電腦	i7-13700HX、32 GB RAM、Windows 11；Python 3.12、Node.js 24
自動化	GitHub Actions：`ci`、`factcheck-sync`（每天 2 次）、`weekly-eval`（每週日）

本輪通過條件：3.6 節的 P0 全部通過；P1 通過率 80% 以上，未執行算未通過；`pytest`、`npm run build` 與 `ci` 全綠。

指標	案例	計算方式	門檻	最新結果	判定
漏判	QA-1a	150 題中有風險卻判 SAFE 的筆數	0	0（10-15）	達成
未命中延遲	PF-1	150 題的 p50／p90	≤15 s／<20 s	5.87 s／8.31 s（09-30）	達成
語意快取命中率	PF-2	20 句改寫句的命中比例	≥70%	50%（09-21）	未達成
快取命中延遲	PF-7	正式站 p50：已證實／未證實	都 ≤5 s	1.87 s／14.28 s（10-26）	未達成
查核同步成功率	OP-11	最近 30 次成功次數	≥90%	25／30＝83.3%（11-03）	未達成
每週歷史漏判率	QA-6	歷史風險題判 SAFE 的比例	≤10.4%	2.1%（10-26）；4.7%（11-02，閘道不穩）	達成
第三方實測	UX-1	T1 達成率／SUS 平均	≥80%／≥68	尚未量測	未執行

缺陷分級：高＝使 P0 無法達成或中斷主流程；中＝影響 P1 或有替代操作；低＝外觀、文案或舊資料。

4. 測試案例總表

狀態是各項目目前最新的判定。「待補驗」計為通過，但還有延後的子項目。

編號	優先	測試項目	預期	狀態	備註
OP-1	P0	全新環境啟動	clone 後 5 分鐘內前後端可用	通過（待補驗）	09-20 重測
OP-2	P0	AI 連線	回合法判定、非 fallback	通過	
OP-3	P0	模擬 Threads 一輪	新增回覆、/bot 顯示	通過（待補驗）	/bot 顯示待補驗
OP-4～OP-6	P1	Threads 授權、讀取、token 續期	實機可授權與續期	報告後執行	10-01 實機串接成功，未逐項判定
OP-7	P0	舊資料相容	載入成功、筆數不變	通過	
OP-8	P0	手機開結果頁	4G 可看到結果	通過	09-20 重測
OP-9	P0	清洗 dry-run	不改檔、列出影響筆數	通過	
OP-10	P0	Threads 實機回覆	2 分鐘內回覆，附 Tier 1 來源	未執行	受 DEF-13 影響
OP-11	P1	查核同步穩定度	最近 30 次成功率 ≥90%	未通過	25／30；DEF-13
OP-12	P1	每週評測排程	每週有報告、剩餘 ≥ USD 3	通過	10-04 起五次
FN-1	P0	AI 契約	新契約測試全過	通過	
FN-2a	P0	網址安全	私網網址回 422、不發請求	通過	
FN-2b	P1	圖片查證	格式與大小檢查	報告後執行	介面未開放
FN-2c	P1	相似查證來源	只取已證實列	報告後執行	
FN-3	P0	結果 API	各狀態回應正確	通過	
FN-4	P0	機器人流程	長度、退避、錯誤分流	通過	09-20 重測
FN-5	P0	回覆模板	七種第一行、長度限制	通過	
FN-6	P0	燈號判定	對照表全部正確	通過	
FN-7	P0	fallback 判斷	判斷方式統一	通過	
FN-8	P0	知識庫 API	搜尋、分頁、只回已證實	通過	
FN-9	P0	管理端點權限	無 token 回 401	通過	
FN-10	P1	AI 額度護欄	超過上限回 429	報告後執行	測試已通過，未另行判定
FN-11	P0	快取分層	hash 與語意都能命中	通過	離線 fixture，不受 DEF-13 影響
FN-12	P0	來源分級	網址對應正確 tier	通過	
FN-13	P0	知識庫寫入門檻	四組驗收正確	通過	
FN-14	P0	清洗腳本	dry-run 不改檔	通過	
FN-15	P1	查核結果回補	命中後改回已證實列	通過	
FN-16	P1	熱門排行	時間衰減、只回已證實	通過	
FN-17	P1	證據信心	規則表每列有案例	通過	正式站受 DEF-13 影響
FN-18	P1	同步程式	recent／full、單一來源失敗不擋	通過	
FN-19	P1	每週評測程式	額度計算、報告欄位完整	通過	
FN-20	P0	無法查證	黃燈、不算漏判或誤報	通過	
FN-21	P1	分類顯示	不再顯示「其他」	通過	
FN-22	P1	機器人雲端運作	狀態存資料庫、token 自動續期	通過	
UI-1	P0	全畫面截圖檢核	深淺色全套，組員勾核	未執行	缺深色全套與非實作組員勾核
UI-2	P0	手機版面	360 px 無橫向捲動	通過	
UI-3	P1	顏色紀律	燈號色只用在指定元件	通過	
UI-4	P0	深淺色	切換後重整保持	通過	
UI-5	P1	無障礙	Lighthouse ≥90	報告後執行	
UI-6	P0	文案一致	與文案表逐字一致	未執行	英文字允許清單待裁定
UI-7	P1	Threads App 內開啟	燈號首屏可見	報告後執行	
UI-8	P0	來源顯示	抽查 10 筆都有 tier 標示	通過	

編號	優先	測試項目	預期	狀態	備註
UX-1	P1	第三方實測	5～8 人；T1 ≥80%、SUS ≥68	未執行	記錄表還是空白
UX-2	P1	情境訊息查證	兩次判定相同	未執行	受 DEF-13 影響
PF-1	P0	未命中延遲	p50 ≤15 s、p90 <20 s	通過	5.87 s／8.31 s
PF-2	P0	語意快取命中率	≥70%	未通過	50%；目前無法重測
PF-3a	P0	機器人可控延遲	≤60 s	通過（待補驗）	模擬 205～264 ms
PF-3b	P1	Threads 端到端時間	記錄 5 次	報告後執行	
PF-4	P1	模擬 10 則處理時間	一輪 <3 分鐘	報告後執行	
PF-5	P1	成本	150 題 ≤ USD 1.5	通過	
PF-6	P1	模型比較組	記錄項，可選	報告後執行	
PF-7	P1	正式站快取命中延遲	兩類 p50 都 ≤5 s	未通過	未證實列 14.28 s；DEF-11
QA-1a	P0	150 題漏判	FN＝0	通過	
QA-1b	P1	150 題準確率	accuracy ≥93%、FP ≤8	待裁定	風險題全對、FP 0；安全題 32 題判無法查證，嚴格算 78.7%
QA-2	P1	報告欄位	含模型、日期、耗時	通過	09-20 重測
QA-3	P0	CI	每次 push 綠燈	通過	
QA-4	P1	文件與程式一致	文件審查勾核	報告後執行	
QA-5	P0	清洗審查	報告數字與資料一致	通過	
QA-6	P0	每週評測漏判	v4 不高於校準前 10.4%	通過	見第 3 節
QA-7	P0	回歸	pytest、前端測試、lint、build、ci 全綠	通過	933 passed、409 pass（11-03）

5. 缺陷清單

共 13 筆：未修復或未裁定 5 筆（DEF-03、04、08、11、13），已修正 8 筆。DEF-09 以後的嚴重度依第 3 節定義判定。

編號	問題	嚴重度	狀態	對應案例
DEF-13	學校閘道關閉 embedding（`/embeddings` 回 404），語意比對、證據信心、查核同步都停用	高	未修復	OP-10、OP-11、UX-2
DEF-12	結果頁分類一律顯示「其他」	中	已修正	FN-21
DEF-11	命中未證實列要 13～16 秒：回補時重新呼叫 embedding	中	未修復	PF-7
DEF-10	閘道下架 `gpt-5.4-mini`，未命中的查證全回 fallback	高	已修正	PF-1、QA-1a
DEF-09	後端冷啟動時結果頁顯示連不上伺服器	中	已修正	OP-8
DEF-08	橫幅與錯誤文字顏色的規格文字衝突	低	待裁定	UI-3
DEF-07	寫入知識庫時印出 pandas 警告	低	已修正	無
DEF-06	模型價格設定與閘道實際計價不符	低	已修正	PF-5
DEF-05	11 筆向量維度不對，壓低語意命中率	中	已修正	PF-2
DEF-04	部分已證實列其實是文章標題	低	未處理	UI-8
DEF-03	同一主張有兩張卡、標籤不同	低	未處理	無
DEF-02	舊任務 AI 失敗仍標成有效判定	低	已修正	FN-3
DEF-01	結果頁偶發 500 並停止輪詢	高	已修正	FN-3

6. 需求追溯矩陣

需求	內容	對應案例	結果
FR-01	文字查證	FN-1、FN-20、PF-1、PF-7、QA-1a、QA-6	部分：PF-7 未達標；語意比對停用
FR-02	網址查證	FN-2a、FN-2c	通過
FR-03	圖片查證	FN-2b	後端有端點，介面未開放
FR-04	結果頁	FN-3、FN-21、UI-2、OP-8、UI-1	部分：UI-1 未執行
FR-05	分享到 Threads	UI-7、UX-1	未驗證
FR-06	熱門牆	FN-16、UI-1	部分：UI-1 未執行
FR-07	知識庫搜尋	FN-8	通過
FR-08	查證歷史	UI-1	部分：單元測試通過，UI-1 未執行
FR-09	Threads 機器人	FN-4、FN-5、FN-22、OP-10、PF-3a	部分：OP-10 未執行
FR-10	模擬 Threads	OP-3、FN-4	通過
FR-11	機器人狀態頁	OP-3、UI-1	部分：已上線，截圖檢核未做
FR-12	每日查核貼文	無	不在範圍
FR-13	隱私與資料刪除頁	UI-1	部分：已上線，UI-1 未執行
FR-14	AI 額度護欄	FN-10、PF-5	通過
FR-15	工程清理	OP-1、OP-7、QA-3、QA-7	通過
FR-16	來源分級與顯示	FN-12、UI-8	通過
FR-17	知識庫寫入門檻	FN-8、FN-11、FN-13	通過
FR-18	資料清洗	OP-9、FN-14、QA-5	通過
FR-19	AI 來源規則	FN-1、OP-2	通過
FR-20	查核結果回補	FN-15、PF-7	部分：DEF-11
FR-21	本站熱門查證	FN-16	通過
FR-22	證據信心	FN-17	部分：正式站受 DEF-13 影響
FR-23	查核結論同步	FN-18、OP-11	未通過：DEF-13
FR-24	每週新查核評測	FN-19、OP-12、QA-6	通過

7. 時程與人員

階段	日期（2026）	工作	結果
第一輪	09-15～09-20	46 項實測與重測	P0 27／30；PF-2、UI-1、UI-6 未結
報告後輪次	09-21～10-15	PF-2 重測、換模型、判定校準	PF-1、QA-1a 維持通過
第二次簡報輪次	10-26～11-03	新增 16 項、回歸、情境劇	P0 3／4；P1 8／12
簡報	11-04	播放情境劇與回答提問	預定

姓名	角色	負責項目
廖晢勛	測試負責人、操作	OP、QA-7、PF-7、UX-2
石岱勳	介面測試、第三方實測主持	UI、UX-1
姚睿	效能與品質數據、第三方實測記錄	PF、QA-6、UX-1
張宇宏	文件與審查	本報告審閱
廖育翔	影片與簡報	簡報當天播放與提問

8. 審查結論

判定：未達第二次簡報輪次的通過條件。 P0 通過 3／4（差 OP-10）；P1 通過 8／12＝66.7%，未達 80%；回歸條件達成。線上系統的判讀與快取命中可用。

完成下列項目後才視為通過：

1. 語意比對恢復或完成替代做法，再重測 OP-10、OP-11、UX-2；替代做法開發中，原有 embedding 程式保留。
2. 完成 UX-1：5～8 位非組員實測。
3. 修正 DEF-11 並重測 PF-7。
4. PF-2 達 70%，並完成 UI-1、UI-6。
5. 審查者裁定 QA-1b 的準則與 DEF-08。

研究限制：歷史安全題被判紅燈的比例仍有 51.9%（315／607，10-26）。本週新查核每週只有 9～41 題，信賴區間很寬，只看趨勢。

證據：`docs/test/results/embedding_closed_2026-11-03.md`、`regression_2026-11-03.txt`、`pf7_latency_2026-10-26.txt`、`weekly/weekly_eval_*.md`。

角色	姓名	審查日期	結論	簽名
測試負責人	廖晢勛			
文件審查	張宇宏			
指導教授	黃崇源			