測試計畫書

1. 測試計畫名稱與編號

項目	內容
計畫名稱	全民查證公社 AI 假訊息與詐騙查證系統 測試計畫書（原專題名稱：AI 為核心的假訊息驗證系統）
計畫編號	TP-FNV-2026-01
版本	**v2.1（第二次簡報版，完整版）**：第 1–5 節補上第二次簡報輪次的目的、範圍、環境、準則、時程與分工；3.6 新增 16 項測試；**6.10 為第二次簡報輪次（2026-10-26～11-03）結果，整體判定未達成，2026-11-03 起學校閘道不再提供 embedding（DEF-13）**；附錄 A 為需求追溯矩陣。v1.9 以前的內容（含 6.1～6.9 各輪結果）保留原樣
日期	2026-11-03（v2.1）；v2.0：2026-10-30；v1.0：2026-09-16
受測系統	全民查證公社：網站前端 `https://fakenewsverify.vercel.app`（Vercel）；FastAPI 後端（Render，2026-09-19 起雲端運作）；資料庫 Supabase Postgres＋pgvector；AI 為長庚大學 CGU AIR 閘道 `gpt-5.6-luna`（embedding 2026-11-03 起無法使用，DEF-13）；Threads 機器人 `@factcheck_tw_bot`（2026-10-01 起在雲端以測試版運作）。第一輪受測時（2026-09-16）的狀態見 2.2 第一張表
測試輪次	第一輪（報告前）：2026-09-15～09-20；報告後輪次：2026-09-21～10-15（6.5～6.9）；**第二次簡報輪次：2026-10-26～11-03**（簡報 2026-11-02～11-04，評審平均及格才能參加 12-03 期末成果展）
撰寫與審查	撰寫：廖晢勛（負責人），由 AI 程式開發助理 Claude Code 協助；審查：張宇宏、指導教授（見 6.4、6.10.4）
撰寫依據	`docs/rebuild/00_consensus.md` §7；`docs/rebuild/01_spec.md` v1.6 §1、§4（FR-01～FR-24）、§10、§11；`docs/rebuild/03_tickets.md` §0.5 與票 B-35～B-44、O-31；`docs/rebuild/owner_decisions_day0.md`

修訂紀錄

版本	日期	內容
v0.1	2026-09-15	第 1–3 節初稿
v0.9	2026-09-16	章節名稱依課程範本；第 1–3 節同步現況（CGU AIR `gpt-5.4-mini`、Vercel 網址、Threads 模擬模式、D-05 清洗結果、parquet 原子寫入修正）；第 3 節各表新增「本次執行」欄；OP-1、OP-9、FN-1 準則依負責人核准事項修訂、QA-1b 評測日期更正（見 4.2）；完成第 4、5 節；建立第 6 節結構
v1.0	2026-09-16	第 6 節填入 2026-09-16 實測結果（6.1 摘要與整體判定、6.2 全部 46 項明細、6.3 缺陷 DEF-01～DEF-08、6.4 審查結論與簽核欄）；§5.1 組員姓名與分工定案（票 O-10）；匯出 `docs/test/TP-FNV-2026-01_v1.0.pdf`。本輪未達 4.2 之「全部 P0 通過」與「P1 ≥80%」，理由見 6.1
v1.1	2026-09-19	§5.1 姓名欄改為留白：各角色由哪位組員擔任尚待組內確認（v1.0 的姓名為負責人草擬）；全文其餘各處改以代號「組員 A～E」指稱；6.4 簽核表姓名欄留白。測試項目、結果、缺陷與結論皆未更動。匯出 `docs/test/TP-FNV-2026-01_v1.1.pdf`
v1.2	2026-09-19	組員分工經組內確認：廖晢勛＝組員 A（測試負責人／操作者）、石岱勳＝組員 B（介面測試）、姚睿＝組員 C（績效與品質數據）、張宇宏＝組員 D（文件與審查）、廖育翔＝組員 E（影片與簡報）。§5.1 姓名欄與 6.4 簽核表填入姓名，全文代號改回姓名。測試項目、結果、缺陷與結論皆未更動。匯出檔改放 `presentations/2026-09_進度報告/04_測試計畫書_TP-FNV-2026-01_v1.2.pdf`
v1.3	2026-09-20	更正組員姓名用字（廖育翔，v1.2 誤植為同音字）；填入指導教授姓名（黃崇源）；計畫名稱加註原專題名稱。測試項目、結果、缺陷與結論皆未更動。匯出檔改為 `presentations/2026-09_進度報告/04_測試計畫書_TP-FNV-2026-01_v1.3.pdf`
v1.4	2026-09-20	新增 **6.5 第二輪重測紀錄**：FN-4、PF-1、QA-2 重測通過；OP-1、OP-8 重測為通過（待補驗）；PF-2 仍未通過（DEF-05 已修正但不影響該題組）；UI-1、UI-6 仍未執行。受測系統於 2026-09-19 改為雲端部署。第一輪（6.1～6.3）內容未更動。匯出檔改為 `presentations/2026-09_進度報告/04_測試計畫書_TP-FNV-2026-01_v1.4.pdf`
v1.6	2026-09-21	新增 **6.6 PF-2 第三輪重測**：改以姚睿依票 O-11 審定的 20 句題組，於本機後端量測，語意快取命中 10／20＝50%，仍未達 70%，PF-2 維持未通過。其中 4 句與原文逐字相同而命中 hash 層，已於該節載明。未調低 0.75 門檻、未事後修改句子。6.1～6.5 內容未更動。P0 通過數維持 27／30
v1.5	2026-09-20	6.5：OP-8 之待補驗項目完成（負責人以手機 4G 開啟結果頁）→ 通過；登錄過程中發現並修正的 DEF-09（後端冷啟動時結果頁顯示連不上伺服器）。匯出檔改為 `presentations/2026-09_進度報告/04_測試計畫書_TP-FNV-2026-01_v1.5.pdf`
v1.7	2026-09-30	新增 **6.7 AI 模型下架後的重測**：CGU 閘道已下架 `gpt-5.4-mini`，正式站未命中快取的查證全數回 fallback，登錄為 DEF-10；改用 `gpt-5.6-luna`（備援 `gpt-6-luna`）後重跑 QA-1a、QA-1b、PF-1：accuracy 96.7%、FN 0、FP 5、未命中 p50 5.87 s，三項皆達準則。6.1～6.6 內容未更動
v1.8	2026-10-12	新增 **6.8 判定校準後的重測**：每週新查核自動評測的覆核發現 AI 常把真的內容判成假，系統提示加判定校準（票 B-40）；QA-1b 兩次 150／150、開發組漏判 16 → 13、誤報 94 → 75
v1.9	2026-10-15	新增 **6.9 AI 可回「無法查證」後的重測**（票 B-43）：QA-1b 風險題 100 題全對、FN 0、FP 0、安全題 32 題判無法查證（三類 accuracy 78.7%）；開發組漏判 16 → 2
v2.0	2026-10-30	**第二次簡報版（完整版）**：老師要求這次交完整且詳盡的測試計畫書。補 2.1～2.3 第二次簡報輪次之目的、範圍與受測系統（2026-10-26 狀態）；新增 3.6（OP-10～12、FN-15～22、PF-7、QA-6、QA-7、UX-1、UX-2 共 16 項）；4.1、4.2、4.4、4.5、5.1 補第二輪環境、準則、交付、時程與分工；新增 6.10 第二次簡報輪次結果與缺陷 DEF-11、DEF-12；新增附錄 A 需求追溯矩陣。匯出 `presentations/2026-11_第二次簡報/03_測試計畫書_TP-FNV-2026-01_v2.0_完整版.pdf`
v2.1	2026-11-03	**回填第二次簡報輪次實測**：學校因資安考量關閉 API 與外部模型，閘道不再提供 embedding，登錄 **DEF-13**（未修復）；OP-11 依最新 30 次（25／30）改判未通過；OP-12、QA-6 補到 2026-11-02；QA-7 重跑；OP-10、UX-1、UX-2 改記未執行並附原因；6.10 整體判定為**未達成**。匯出 `presentations/2026-11_第二次簡報/03_測試計畫書_TP-FNV-2026-01_v2.1_完整版.pdf`

本計畫各節與規格書之對應

本計畫章節	來源
2.1 計畫目的、2.2 計畫範圍	spec §1（成功定義、非目標）、§4；`03_tickets.md` §0.5
2.3 參考文件	spec §10.6「2.3 參考文件」，補列報告週決策與執行紀錄
3.1–3.5 測試項目	spec §10.1–§10.5（FR 編號引用 spec §4）
4.1 測試環境需求、4.4 測試交付項目	spec §10.6，依 2026-09-16 實際環境調整
4.2 測試項目的通過準則、4.3 測試中止的準則與再繼續的需求	spec §10 開頭與「4.2 通過準則彙總」
4.5 測試工作項目與時程	spec §11；`03_tickets.md` §0.5、§10.2
5 人員配置與訓練需求	共識 §1（團隊 5 人）、spec §11
3.6 第二次簡報輪次測試項目（v2.0）	spec v1.6 §4 FR-20～FR-24；票 B-35～B-44、O-31；`docs/test/` 上線後準確率驗證計畫.md
6.10 第二次簡報輪次結果（v2.0）	`docs/test/results/` 之原始紀錄
附錄 A 需求追溯矩陣（v2.0）	spec §4 全部 FR 對照第 3 節測試項目與最新結果

2. 簡介

2.1 計畫目的

驗證「全民查證公社」重做版本（2026-09-15 起一週重做）是否達到進度報告與 3 分鐘 demo 影片的交付條件，並以可量測、可重跑的準則留下證據，供進度報告與論文引用。

產品定位（spec §1）：台灣繁中的假訊息／詐騙查證平台——貼上文字或網址（圖片為 P1），AI 判定 SCAM／MISINFO／SAFE 並附查核來源；同一套判定在 Threads 上 @機器人 即可取得，網站結果可一鍵分享回 Threads。

測試目標（spec §1 成功定義，依報告週範圍調整）：

1. 進度報告與 3 分鐘 demo 影片如期交出。
2. 影片完整呈現閉環：Threads 可疑貼文 → Tester 回覆並 @機器人 → 機器人回覆紅／黃／綠燈號＋來源＋`/r/{id}` 連結 → 手機版結果頁 → 「分享到 Threads」。報告週 Threads 採模擬模式（FR-10）呈現同一閉環，實機串接排在報告後。
3. 網站四個主畫面（首頁／結果頁／熱門牆／知識庫）在手機寬度可用；淺色為預設；紅黃綠只出現在判定。
4. AI 實際可用（CGU AIR `gpt-5.4-mini`，provider 鍵 `['cgu']`）：至少一次「未命中快取 → AI 判定」與一次「改寫版命中向量快取（`cache_layer="vector"`）」；全程無「AI 分析暫時無法使用」畫面。
5. `pytest tests` 全綠、CI 通過；評測數字（前一版模型 accuracy 96.0%／FN=0 與 CGU `gpt-5.4-mini` 新跑值並列）與三層快取證據可供報告引用。
6. demo 資料乾淨：畫面上每一個「查核來源」皆為 Tier 1／2；熱門牆無 Google News 轉址；知識庫頁不出現 `verified=false` 記錄；找不到查核來源時明示「尚無查核機構證實」且不出現綠燈。

第二次簡報輪次的目的（v2.0）：第一次簡報（2026-09）驗證的是「系統做得出來、功能完整」；第二次簡報（2026-11）的重點是**使用情境**，所以本輪驗證系統在真實使用情境下是否可靠：

1. 線上系統無人值守也能持續運作：查核結論每天同步、每週自動評測、Threads 機器人在雲端回覆測試人員。
2. 判定準確度改以模型沒看過的題目衡量：每週新查核自動評測（M5）是主要的準確率證據；150 題題庫已公開也已飽和（6.8），只當回歸測試。
3. 一般使用者用得起來：由非組員實測達成率與易用性（陳仁暉教授 2026-09-21 的審查意見「找別人實測達成率」）。
4. 情境劇影片中的四個使用情境在正式站可以重現：畫面上的系統結果都是真的，不是做出來的。
5. 第一輪之後新增的功能（FR-20～FR-24、AI 可回「無法查證」、分類顯示修正、Threads 雲端運作）都有自動化測試，且整體回歸全綠。

2.2 計畫範圍

測試範圍：spec §4 FR-01～FR-19 中列為 P0 者為必測；P1 條目依 4.2 之通過率計入；P2 條目（FR-12 每日查核貼文、`/history` 全頁、速率限制）不在範圍內。測試分為操作（3.1）、功能（3.2）、介面（3.3）、績效（3.4）、品質（3.5）五類，共 46 項（P0 30 項、P1 16 項）。

本輪與報告後之劃分（`03_tickets.md` §0.5，2026-09-15 負責人選定「報告週切片 A」；各項目歸屬見第 3 節「本次執行」欄）：

輪次	範圍
本輪（報告前）	網站（首頁、結果頁、熱門牆、知識庫、靜態頁）；三層快取與 AI 判定；來源分級與資料清洗（D-05 已套用）；Threads 模擬模式閉環（終端機輸出＋`replies.jsonl`）；自動化功能測試與 CI；評測、績效與成本量測；以 headless 瀏覽器擷取之介面截圖檢核；公開部署與發佈前操作測試
報告後	Threads 實機串接（Meta App、Threads Tester、長效 token、live 回覆與延遲）；機器人狀態頁 `/bot`（票 S-11）；真手機測試（含 Threads App 內建瀏覽器）；無障礙量測；P1 功能（圖片查證、`similar_news`、AI 額度護欄程式）；文件同步

非目標（不測）（spec §1、共識 §2）：影片查證（yt-dlp＋Whisper）、FB／IG 封閉平台（Playwright）、文字輸入的 Google 搜尋抓取、熱門牆的 Google News 來源、管理者覆寫 UI（`/api/admin` API 保留）、使用者帳號／登入、英文介面、Threads Webhook、Threads 私訊、公開讓陌生人 @機器人（需 App Review＋企業驗證，論文寫明為上線條件）。

受測系統範圍（2026-09-16 狀態）

元件	說明	對應 FR
網站前端	React 19＋Vite 8.3.0＋Tailwind 4＋react-router-dom 7（`code/frontend`），部署於 Vercel（`https://fakenewsverify.vercel.app`，即 `PUBLIC_BASE_URL`）。路由：首頁 `/`、結果頁 `/r/{id}`、熱門牆 `/trending`、知識庫 `/knowledge`、授權碼顯示 `/oauth/callback`；純 HTML 靜態頁 `/privacy.html`、`/data-deletion.html`、`/deauthorize.html`。`/bot` 目前為佔位頁，正式機器人狀態頁（S-11）排在報告後。前端只讀後端 `frame_type`／`frame_label` 顯示燈號；查證歷史存 localStorage（首頁最近 5 筆）。依第二批刪減，熱門牆篩選只留「全部／未查證」，知識庫單次讀取 60 筆（無「載入更多」與四格統計）。	FR-04～08、FR-11、FR-13
後端 API	FastAPI＋Uvicorn（`code/backend`，v0.3.0，單 worker），執行於負責人電腦，經 Cloudflare quick tunnel 對外；Vercel `vercel.json` rewrites 將 `/api/*` 同源代理至 tunnel。查證送出後立即取得 `result_id`，結果頁輪詢 `GET /api/result/{id}`。管理端點以 `ADMIN_TOKEN` 保護（`start.bat` 自動產生）。	FR-01、FR-02、FR-04、FR-15
三層快取	文字輸入：L1 內容 SHA-256 → L2 向量（`text-embedding-3-small` 1536 維，以使用者原文比對，門檻 0.75，只比對 `verified=true` 列）→ L3 AI；不送 Google 搜尋。網址輸入：L0 URL → L1 hash → trafilatura 爬取（SSRF 防護 `safe_url.py`）→ L2 向量（以爬到內文比對）→ L3 AI。結果回填 `knowledge_base.parquet`；回應帶 `cached`／`cache_layer`（url／hash／vector）。	FR-01、FR-02、FR-17
AI 引擎	CGU AIR Gateway（OpenAI-compatible Responses API；`AI_PROVIDER=cgu`、`CGU_MODEL=gpt-5.4-mini`、`OPENAI_REASONING_EFFORT=low`、單次逾時 60 s），provider 鍵 `['cgu']`；新學期額度為 OpenAI 成本 USD 10＋本地模型 1,000 萬 tokens，用量以 `GET {CGU_BASE_URL}/me/usage` 查詢；不使用 OpenAI 直連，myai168 已停用。provider 全失敗時回 HTTP 200 fallback（`ai_unavailable=true`、summary 以「AI 分析暫時無法使用」開頭），不寫知識庫。系統 prompt 含來源規則（FR-19）；`allowed_domains` 為 P1，本輪不實作。	FR-01、FR-14、FR-19
來源分級	`app/utils/source_tier.py`：Tier 1 為已有判定之查核機構（TFC、MyGoPen、有 RUMOR／NOT_RUMOR 回覆之 Cofacts 文章、`*.gov.tw` 等官方機構）；Tier 2 為主流媒體查核報導（呼叫 `_title_indicates_debunk()`）；Tier 3 為其餘。對外只顯示 Tier 1／2；無 Tier 1／2 來源時 `verified=false`，顯示「尚無查核機構證實」且不得為綠燈。	FR-16、FR-17
資料清洗	`scripts/clean_sources_2026_09.py`（預設 dry-run、冪等、apply 前自動備份）。D-05 於 2026-09-16 經負責人核准後套用（決定 1a／2a／3a）：知識庫 236 → 218 筆，`verified=true` 128 筆（其中 113 筆帶向量；實測僅 102 筆為 1536 維、可實際參與向量命中，見 6.3 DEF-05）；熱門牆 63 → 24 筆（刪除 Google News 轉址 31 筆與髒資料 8 筆），全數 `verified=true`。審閱紀錄見 `docs/test/clean_sources_review.md`。	FR-18
紅黃綠映射	`app/utils/verdict.py`：`frame_of()` 為單一權威（spec §7.8，8 列），`is_fallback()` 為 fallback 唯一判斷點，Web 結果頁與 Threads 回覆共用。	FR-04、FR-09
Threads 機器人	`@factcheck_tw_bot`；`THREADS_MODE=live／sim／off`。**報告週為模擬模式**：`FakeThreadsService` 讀 `data/threads_sim/mentions.json`、寫 `data/threads_sim/replies.jsonl`，分析管線、回覆模板（≤500 字，spec §7.7）、去重與 state 原子寫入皆與實機相同；以 `scripts/test_threads_bot.py --reset-sim／--poll` 或帶管理金鑰之 `POST /api/threads/poll`（202）觸發，`GET /api/threads/status`、`GET /api/threads/replies` 提供狀態與回覆。實機模式需 Meta App（Threads use case 四項權限）、公開之 Threads Tester 帳號與 60 天長效 token，開發模式下只讀得到 Tester 的提及與貼文，排在報告後。	FR-09、FR-10、FR-11

元件	說明	對應 FR
分享	結果頁「分享到 Threads」以 Web Intent `https://www.threads.com/intent/post?text=…&url=…` 開新視窗，純前端、零 token。	FR-05
資料	SQLite `factcheck.db`（熱門牆 24 筆，不進 git）；`knowledge_base.parquet`（218 筆，清洗後種子已提交，commit `db8c62d`）；`tasks.parquet`（結果頁，上限 5,000 筆；自 commit `c114413` 起先寫暫存檔再原子替換）；`eval_set.csv`（150 筆評測集）。	FR-06、FR-07、FR-18

第二次簡報輪次範圍（v2.0）：第一輪 46 項中，自動化項目以 QA-7 整體回歸；仍未結的 PF-2、UI-1、UI-6 依原準則繼續追蹤（6.6、6.10.1）。另於 3.6 新增 16 項：操作 3 項（OP-10～12）、功能 8 項（FN-15～22）、績效 1 項（PF-7）、品質 2 項（QA-6、QA-7）、使用者 2 項（UX-1、UX-2）；其中 P0 4 項、P1 12 項。

受測系統範圍（2026-10-26 狀態）

元件	說明	對應 FR
網站前端	Vercel（`https://fakenewsverify.vercel.app`）；路由 `/`、`/r/{id}`、`/trending`（「查核機構最新」與「本站熱門查證」兩個分頁）、`/knowledge`、`/bot`（機器人狀態頁，2026-09-30 上線）、`/oauth/callback`。結果頁顯示信心等級與依據、「知識庫中的相似查證」；AI 判讀「無法查證」時走一般結果頁並顯示黃燈	FR-04～08、FR-11、FR-21、FR-22
後端 API	Render 免費 web service（`render.yaml`），Vercel 以同源代理轉送 `/api/*`；Supabase pg_cron 每 5 分鐘叫醒，避免休眠。護欄：每日 AI 300 次、每 IP 每分 30 次與每時 200 次、請求 1 MB（圖片 10 MB）	FR-01、FR-02、FR-14、FR-15
資料	Supabase Postgres＋pgvector：知識庫已證實 18,769 筆（2026-10-21：假訊息 18,552、詐騙 193、安全 24），其中絕大多數為查核機構結論（`label_source=rule`）；另有查證任務（結果頁）、熱門牆、每日 AI 次數、Threads 狀態與回覆紀錄	FR-06、FR-07、FR-17、FR-23
AI 引擎	CGU AIR `gpt-5.6-luna`（2026-09-30 起；備援 `gpt-5-luna`），推理強度 medium、`USE_WEB_SEARCH=false`；embedding `text-embedding-3-small`（1536 維）。系統提示含判定校準 v4（2026-10-15）：查不到又沒有明顯跡象時回 `UNVERIFIABLE`，以 `verified=false` 保存	FR-01、FR-19；票 B-40、B-43
查核結論同步	GitHub Actions `factcheck-sync`：每天 2 次 recent、週日 full；抓 MyGoPen、台灣事實查核中心、Cofacts，只寫入已判定為假訊息或詐騙者（`label_source=rule`），只耗 embedding 額度	FR-23
每週新查核自動評測	GitHub Actions `weekly-eval`：週日用本週剩餘額度（上限 USD 6、保留 USD 3 給網站）評測「本週新發布的查核」與「歷史抽樣」，報告自動 commit 至 `docs/test/results/weekly/`	FR-24
Threads 機器人	2026-10-01 起 Render 上 `THREADS_MODE=live`，每 30 秒檢查提及；狀態、回覆紀錄、token 存 Supabase，重啟不會重複回覆；Meta 開發模式只回覆測試人員；2026-10-03 決定先不送 Meta App Review	FR-09；票 B-38、B-39
證據信心	信心等級依「與查核機構已證實內容的相似度（夾角）」決定，不用 AI 自評分數；規則表 9 列	FR-22

2.3 參考文件

1. `docs/rebuild/00_consensus.md`（重做共識，2026-09-14，含 2026-09-15 §4／§9 補充）
2. `docs/rebuild/01_spec.md`（功能與 UX 規格書 v1.3）
3. `docs/rebuild/02_mockup_brief.md` 與 `docs/rebuild/mockup/*.dc.html`（設計簡報與 mockup；UI-1 對照）
4. `docs/rebuild/03_tickets.md`（實作票 v1.1；§0.5 報告週範圍）
5. `docs/rebuild/owner_decisions_day0.md`（負責人決策紀錄）
6. `docs/rebuild/runbook_tunnel.md`（tunnel 啟動與 `vercel.json` 換主機程序）
7. `CLAUDE.md`（專案說明；§6 評測現況）
8. `code/backend/data/eval_archive_gpt5mini_2026-06/`（前一版模型 `gpt-5-mini` 150 筆評測之 `eval_report.csv`、`eval_binary.csv`、`eval_errors.csv`、`eval_predictions.csv`、`confusion_matrix.png`，2026-06-06，commit `9d63eef`；本輪新結果寫回 `code/backend/data/eval_*.csv` 與 `assets/confusion_matrix.png`）
9. `code/backend/data/clean_sources_report.txt`、`check_before_d05.txt`、`check_after_d05.txt`、`clean_sources_drop_ids.txt`（FR-18 清洗報告、前後比對與核准刪除清單）
10. `docs/test/clean_sources_review.md`（D-05 清洗審閱紀錄；QA-5）
11. `docs/demo/storyboard.md`、`docs/demo/footage_log.md`（demo 影片分鏡與素材紀錄）
12. Threads 官方文件（Threads API Overview、Reference > Publishing／Replies／Mentions、Get Started > Permissions／App Roles、Web Intents；以 threads_gap_analysis／threads_verify_10 記錄之 URL 為準）
13. CGU AIR Gateway 教學頁（`https://air.cgu.edu.tw/workspace4/LLMAPI/api_call.html`；OpenAI-compatible Responses API，`/v1/me/usage` 用量查詢）
14. OpenAI Responses API 文件（僅作格式參考；`web_search` `filters.allowed_domains` 於閘道之支援性見 OP-2）
15. `docs/rebuild/01_spec.md` v1.6（FR-20 查核結果回補、FR-21 本站熱門查證、FR-22 證據信心、FR-23 查核結論同步、FR-24 每週新查核自動評測）
16. `docs/test/上線後準確率驗證計畫.md`（上線後怎麼量準確率：M1～M5）
17. `docs/test/results/weekly/`（每週新查核自動評測報告與 CSV：2026-10-05、10-12、10-19、10-26；覆核紀錄 `review_2026-10-05.md`）
18. `docs/test/results/prompt_calibration_2026-10-12.md`（判定校準 v1～v4 與 306 題開發組）
19. `docs/test/results/evidence_confidence_2026-09-24.md`、`docs/rebuild/信心程度的產生方式.md`（證據信心）
20. `docs/test/第三方實測_說明.md`、`第三方實測_題卡.md`、`第三方實測_記錄表.csv`、`第三方實測_問卷.csv`（UX-1）
21. `docs/test/threads_live_log.md`（Threads 實機串接與雲端運作紀錄）
22. `presentations/2026-11_第二次簡報/01_真人劇本.md`（UX-2、OP-10；2026-11-02 起唯一的劇本，舊版劇本與配音稿已刪、在 git 歷史）
23. `docs/test/results/pf7_latency_2026-10-26.txt`（PF-7 原始紀錄）

3. 測試項目

各表欄位：ID／優先級／本次執行／對應 FR／（操作測試另有「步驟」）／通過準則。ID、優先級與準則文字與 spec §10 一致；v0.9 修訂處以〔v0.9 修訂〕標示，理由見 4.2。「對應 FR」欄在 spec 功能測試表已列者照抄，其餘依準則內容對應 spec §4 之 FR 或章節。

「本次執行」欄：**本次執行**＝於報告前輪次執行，結果記於第 6 節；**報告後執行（原因）**＝依報告週切片 A（`03_tickets.md` §0.5）或功能優先級延後，目標日期見 4.5。本次執行項目若有部分準則依附報告後才實作之功能，於各表下方「註」列明，判定方式見 4.2。

3.1 操作測試

操作者：廖晢勛（負責人）；腳本執行可由 Claude Code 在其監督下進行。來源：spec §10.1。

ID	優先級	本次執行	對應 FR	步驟	通過準則
OP-1	P0	本次執行	FR-15、FR-18、§5.6	全新 clone → `start.bat`	後端 `/health` 200 且 `ai_available=true`；前端 5173 開啟首頁；<5 分鐘（含 pip/npm）；`.env` 已自動產生 ≥32 字 `ADMIN_TOKEN`，`curl -X POST -H "X-Admin-Token: …" /api/threads/poll` 回 202 或 200 `threads_disabled`；**`GET /api/knowledge/stats.total ≥ 125`**（證明提交的種子是 FR-18 清洗後版本，`verified` 已回填；在 OP-9 之後執行）〔v0.9 修訂：原 ≥150〕
OP-2	P0	本次執行	FR-19、FR-14	`scripts/test_ai_provider.py --provider cgu`（關／`--web-search` 開／`--web-search --allowed-domains` 各跑一次；前後各查一次 `GET {CGU_BASE_URL}/me/usage`）	**P0 條件（只有這一項擋交付）**：關閉 web_search 的一次印出合法 `risk_type`、非 fallback、印出 `usage`，embedding 維度 1536。**記錄項（回 400／不支援不算不達標）**：`--web-search` 與 `--allowed-domains` 兩次結果寫入 `docs/test/cgu_usage.txt`——`--web-search` 回 400／閘道不支援 → `USE_WEB_SEARCH=false` 進 demo 並在報告註明；`--allowed-domains` 回 200 且 `url_citation` 全在清單內（另記 gov.tw 裸網域是否涵蓋子網域）→ 閘道支援，FR-19 維持 P1，由 D-16 決定是否於報告後實作（票 B-24）；否則不做。三次 `/me/usage` 前後差合計 ≤ USD 0.06
OP-3	P0	本次執行	FR-10、FR-11	`THREADS_MODE=sim` + `scripts/test_threads_bot.py --poll`（或 `curl` 打 `/api/threads/poll` 後輪詢 `status`）	一輪完成、`replies.jsonl` 新增 ≥1 行、`/bot` 頁 ≤4 秒顯示該回覆、`status.mode == "sim"`
OP-4	P1	報告後執行（需 Meta App、Threads Tester 與實機授權）	FR-09（§7.3）	`scripts/threads_auth.py` 走完授權	`data/threads_token.json` 產生，含 `authorized_at`，`token_days_left` 介於 55–60
OP-5	P1	報告後執行（需 Threads 實機 token 與 Tester 帳號）	FR-09（§7.6、§7.7、§7.10）	`scripts/test_threads_bot.py --live`	profile 與 mentions 皆 200；log 一則真實 mention 原始 JSON（記下 `media_type` 實際值）；對機器人自己貼文試發 `auto_publish_text=true` 回覆一則並 `GET /{id}` 可讀（7.6 D-11 依據）；480 字純中文 + 3 emoji 試發一則（7.7 長度規則）；故意讀非 Tester 貼文、用壞 token 各一次並記錄狀態碼與 `error` body（7.10）
OP-6	P1	報告後執行（需實機 token 取得滿 24 小時）	FR-09（§7.3）	`scripts/threads_auth.py --refresh`	`expires_at` 延後 ≥50 天（或拒絕：token <24 h）
OP-7	P0	本次執行	FR-15、§6	以 v1.0 前的舊 `tasks.parquet`／`knowledge_base.parquet`／`factcheck.db`（快照 `docs/test/op7_legacy/`）啟動後端	載入成功、新欄位為預設值、筆數不變（`check_db.py` 前後比對）
OP-8	P0	本次執行	FR-04、§8.2	Vercel 部署 + quick tunnel + `vercel.json` rewrites	手機 4G 開 `{PUBLIC_BASE_URL}/r/{任一 id}` 可看到結果；`{PUBLIC_BASE_URL}/api/health` 200（同源代理）
OP-9	P0	本次執行	FR-18	`scripts/clean_sources_2026_09.py --dry-run` → 負責人審閱 `data/clean_sources_report.txt`（D-17）→ `--apply --drop-ids data/clean_sources_drop_ids.txt` → 再 `--apply` 一次	dry-run 不改任何檔（`git status`／檔案 mtime 不變）；報告列出各規則影響筆數與逐筆 before→after；apply 後 `check_db.py`：知識庫筆數 = 236 − 核准刪除清單中存在於種子之筆數、`verified=true` ≥125、熱門牆 `news.google.com` 0 筆、`.bak-{date}` 備份存在；第二次 apply 影響筆數 0（冪等）；`pytest tests` 仍綠〔v0.9 修訂：原「知識庫 236 筆不變、`verified=true` ≥150」〕

註：

1. OP-3 之「`/bot` 頁 ≤4 秒顯示該回覆」依附機器人狀態頁（票 S-11，報告後），本輪以其餘準則判定；報告週 demo 影片以終端機輸出與 `replies.jsonl` 呈現機器人回覆（`docs/demo/footage_log.md`）。
2. OP-2 前置：`test_ai_provider.py` 須具備 `--web-search`／`--allowed-domains` 旗標與 `usage` 輸出（票 B-02）。
3. OP-1、OP-7 於獨立資料夾之全新 clone 執行，不複製原 `.env`（金鑰由廖晢勛自行填入），OP-7 將舊檔快照複製至新 clone 之 `code/backend/data/`（票 O-25 做法）。
4. OP-8 前置：啟動 cloudflared quick tunnel，依 `docs/rebuild/runbook_tunnel.md` 將主機寫入 `vercel.json` 並部署 Ready（票 O-08）。

3.2 功能測試

執行方式：`cd code/backend && .\venv\Scripts\python -m pytest tests -q`（本機）與 GitHub Actions（CI 自動）。來源：spec §10.2。

ID	優先級	本次執行	對應 FR	通過準則
FN-1	P0	本次執行	FR-01、FR-19	既有測試依 5.5／7.7／7.8 新契約更新後全過（**允許改寫** `tests/test_ai_service_contract.py` 的框色案例（改驗 7.8 表 **8 列**）與 Threads 回覆案例（改驗 7.7 新模板，含「尚無查核機構證實」替代行）；其餘 `test_cache_and_store`／`test_marking_rules`／`test_api`／`test_url_validator`／`test_processor_flow` 五檔**不得修改斷言**〔v0.9 修訂：經負責人同意閘門 O-01，`test_processor_flow.py`（B-03，移除文字輸入關鍵字爬取）與 `test_api.py::test_health_and_root`（B-22，改為只比對 `status`）兩處例外允許修改〕——`test_cache_and_store` 的 fixture 直接呼叫 `save_record`、無 `verified` 參數，其來源 `165.npa.gov.tw` 為 gov.tw Tier 1，由 `save_record` 內部離線計算得 `verified=true`（FR-17「計算位置」），`test_vector_search_exact_hit` 在 `find_similar_by_vector` 加 `verified` 過濾後仍原樣通過）+ 新增：文字輸入不呼叫 crawler（mock 斷言 `process_input` 未被呼叫）；系統 prompt 含 FR-19 逐字規則（字串比對「找不到這類來源就回 `sources: []`」）
FN-2a	P0	本次執行	FR-02	`test_safe_url.py`：10 個私網／協定樣本全部拒絕（422 `blocked_url`）且未發出請求、3 個公網放行；連線逾時 10 s 與總逾時 `CRAWLER_TIMEOUT` 以 mock 各自驗證生效；爬取失敗回 UNVERIFIABLE 而非例外；非網址 422；輸入網址同網域的 `sources` 項被剔除。（`similar_news` 向量近鄰斷言隨功能降 P1 移至 FN-2c）

ID	優先級	本次執行	對應 FR	通過準則
FN-2c	P1	報告後執行（similar_news 向量近鄰為 P1，本輪固定回 []，D-18）	FR-02 similar_news	similar_news 由向量近鄰填入（固定向量 fixture）、只取 verified=true 列、排除自己、≥0.6
FN-2b	P1	報告後執行（圖片查證 FR-03 為 P1，端點 B-26 報告後實作）	FR-03	非圖片 415、>10 MB 413、bytes hash 命中
FN-3	P0	本次執行	FR-04、5.1	test_result_api.py：/api/result/{id} 對 pending／completed／failed／404／ai_unavailable 五態 schema 正確；sync／async／threads_sim 三種來源皆 200；/health 含 scheduler.{enabled,interval_hours}
FN-4	P0	本次執行	FR-09／FR-10	test_threads_bot_sim.py：文字 mention 產生 threads_len ≤ 400 回覆且含 /r/；圖片 mention（media_type=IMAGE、無文字）→ reply_media_only；get_post HTTP 403 → reply_cannot_read；HTTP 429 → backoff_until 設定；未知 4xx → 標 failed 不回覆；二次 poll 不重複；fallback 不回覆不標記；自我貼文跳過（username == bot 與 reply_id 在本機清單兩種）；每則後 state 已寫入（crash 模擬）；container FINISHED 才 publish、ERROR 重試一次
FN-5	P0	本次執行	7.7	**七種**第一行模板（含黃燈符號＋「尚無查核機構證實」）threads_len ≤ 400（實測後放寬 480）；4 個 emoji + 200 字 summary、含警示符號（U+26A0 U+FE0F）之 summary 兩個極端案例仍 ≤500 且保留結果頁連結；「黃燈＋尚無查核機構證實」第一行＋替代行「尚無查核機構證實」（無連結）一組長度案例：連結數 = 1（只剩結果頁）、替代行計入長度不計連結；連結數 ≤2；threads_len 對 BMP emoji／U+FE0F／U+200D 以 bytes 計；**實測長度規則紀錄欄**（OP-5 實測結果）
FN-6	P0	本次執行	7.8	frame_of() 對表格 **8 列** + 11 組 (is_risk, risk_type, confidence, ai_unavailable, verification_status) 輸入的表格測試；含「SAFE、0.95、unverified → yellow 尚無查核機構證實」與「SAFE、0.95、verified → green」、「缺 verification_status 鍵 → 視為 unverified」三組
FN-7	P0	本次執行	5.5	is_fallback() 統一判斷（含 evaluate.py／test_ai_provider.py 改呼叫）；ai_unavailable 與 summary 前綴同時成立
FN-8	P0	本次執行	FR-07	q="(" 200；offset 分頁不重複不遺漏；stats 四格加總 = total；fixture 中 verified=false 列不出現在列表、不計入 total（FR-17）
FN-9	P0	本次執行	5.6	管理端點無 token → 401；ADMIN_TOKEN 空 → 403；正確 → 202/200/409
FN-10	P1	報告後執行（AI 額度護欄 FR-14 程式為 P1，報告後實作）	FR-14	DAILY_AI_CALL_CAP=1 時第二次未命中回 429 且 AI mock 未被呼叫
FN-11	P0	本次執行	三層快取	同文 hash 命中、改寫文 vector 命中（固定向量 fixture）；verified=false 列即使相似度 0.99 也不命中 vector 層（hash 層仍命中）；圖片 bytes hash 命中移至 FN-2b
FN-12	P0	本次執行	FR-16	test_source_tier.py：≥15 組 URL／標題 → tier 表格測試（gov.tw.evil.com → 3、news.google.com/rss/… → 3、Cofacts 有回覆 mock → 1／無回覆 → 3、MyGoPen 任意標題 → 1、ETtoday 查核標題 → 2、ETtoday 一般標題 → 3、Cofacts GraphQL 逾時 → 3、offline=True 時 Cofacts → 3 且未發請求）；GraphQL mock 對準 https://api.cofacts.tw/graphql（與 search_service.py:216 同端點）；tier_of 對 Tier 2 呼叫的是 news_fetcher._title_indicates_debunk（mock 斷言，防複製規則）
FN-13	P0	本次執行	FR-17	test_kb_write_gate.py：FR-17 驗收 1 的四組（Tier 1 存活 → true；只有 Tier 3 → false 且 vector 不命中；sources=[] + rule → true；Tier 1 但 validator 判死 → false）；/api/result 回 verification_status 三值正確；sources[] 無 tier 3
FN-14	P0	本次執行	FR-18	test_clean_sources.py：fixture Parquet／SQLite 上 --dry-run 檔案 mtime 不變；--apply 兩次結果相同；Google News 解析 mock 成功（覆寫 + 去重）與失敗（刪列）兩種；label_source="rule" 列永不降級

整體目標（spec §10.2「目標」列，非獨立測試 ID）：P0 測試數 ≥60、CI 綠燈、執行 <60 s、零付費呼叫（Cofacts GraphQL 一律 mock）；FR-01／02／04～07／09／10／11／16／17／18 每條至少一個測試。

註：

1. FN-4 之「HTTP 429 → 設定 backoff_until」「未知 4xx → 標 failed 不回覆」「container FINISHED 才 publish、ERROR 重試一次」三組案例屬實機發佈與錯誤分流（票 T-12、T-13，報告後），本輪以其餘案例判定。
2. FN-5 之「實測長度規則紀錄欄」為記錄項，依附 OP-5 實機實測（報告後）；本輪長度上限採 spec §7.7 預設值。
3. 前端純 JS 模組之單元測試（npm run test:unit）隨 CI 執行，作為介面邏輯之輔助證據，不另立測試 ID。

3.3 介面測試

執行方式：visual review（共識 §7）。本輪以 Microsoft Edge headless 擷取截圖（桌機 1280 px、手機模擬 375 px，UI-2 另以 360×780；淺色與深色），由非實作組員（石岱勳）依截圖檢核表 docs/test/ui_checklist.csv 逐格勾核、張宇宏覆核；真手機與 Threads App 內建瀏覽器之測試排在報告後。來源：spec §10.3。

ID	優先級	本次執行	對應 FR	通過準則
UI-1	P0	本次執行	§8.3、§8.4（FR-04、FR-06、FR-07、FR-11、FR-13）	以 8.4 狀態總表為母版產出「截圖檢核表」（每格一列：畫面／狀態／寬度／主題／檔名／勾核者／結果）。P0 畫面 S1、S2、S3、S4、S6 的打勾格 × 2 寬（375／1280 px）× 2 主題 = 必交（約 100 張；S5 為 P2 不列）。「一致」定義：該格顯示 8.7 對應 key 的文案且無 8.6 列出的違規（字級 <13 px、hover-only 說明）；S1／S2 另與 mockup（docs/rebuild/mockup/Main.dc.html、Result.dc.html、ResultStates.dc.html）對照，S3／S4／S6 只對 8.3 元件清單。由非實作組員勾核
UI-2	P0	本次執行	FR-04、FR-05、§8.5	手機 360×780 無橫向捲動；結果頁動作列 sticky 可見；底部分頁列在安全區內
UI-3	P1	本次執行	§7.8、§8.1	顏色紀律：grep -l 'c-verdict' src/**/*.jsx 命中的元件檔 ≤3（ResultCard、Chip、燈號點）；導覽／按鈕不出現紅黃綠（截圖抽查）
UI-4	P0	本次執行	§8.1	淺色為預設；系統深色時自動深色；切換後重整保持
UI-5	P1	報告後執行（無障礙基準票 P-18 排在報告後）	§8.6	Lighthouse（手機）Accessibility ≥90、Performance ≥80；axe 零 critical；鍵盤 Tab 可走完首頁並完成一次查證
UI-6	P0	本次執行	§8.7	文案表 8.7 全部 key 在介面出現且逐字一致；grep -P '[a-zA-Z]{4,}' src/i18n.js 只允許品牌與 URL；簡體以 OpenCC t2s 轉換前後 diff 為空
UI-7	P1	報告後執行（需真手機與 Threads App 實機串接）	FR-04、FR-05	Threads 手機 App 內建瀏覽器開 /r/{id}：燈號首屏可見；分享鈕開出的 URL 符合 FR-05 驗收 1（App 內是否深連結 composer 只記錄）
UI-8	P0	本次執行	FR-16	來源紀律（FR-16）：S2 截圖抽查 10 筆結果頁，「查核來源」區每項皆帶 tier_1_chip／tier_2_chip，無 Tier 3 網域（用 OP-9 後的資料）；S3 截圖無 news.google.com；至少一張 S2「尚無查核機構證實」狀態截圖（SAFE 黃 + 橫幅）入檢核表

註：

1. UI-1 之 S6 `/bot`（票 S-11，報告後）截圖格延後；S3 篩選 chip 僅「全部／未查證」、S4 無「載入更多」與四格統計（`03_tickets.md` §0.5 第二批刪減），相應狀態格標「不適用（範圍刪減）」。
2. UI-6 之 `/bot` 畫面文案 key 隨 S-11 延後；P1／P2 功能與隱藏區塊之 key 不列入本輪範圍（範圍界定依票 O-28，須經 6.4 審查確認）。
3. 實作票（`docs/rebuild/03_tickets.md` §0 第 4 條）沿用 mockup brief §2 的 token 名（`--c-red` 等），UI-3 的 grep 關鍵字實際執行時以該 token 名為準，判定準則（命中元件檔 ≤3、導覽／按鈕不出現紅黃綠）不變。

3.4 績效測試

執行方式：`evaluate.py --timing`＋後端結構化 log（`result_id`、`origin`、`cache_layer`、`elapsed_ms`）＋手動計時（依共識 §7 不新增腳本）。來源：spec §10.4。

ID	優先級	本次執行	對應 FR	通過準則
PF-1	P0	本次執行	FR-01、三層快取、§9 效能	`evaluate.py --timing`（web_search 關）：未命中 p50 ≤15 s／p90 <20 s（150 筆 `elapsed_ms`）；L1／L2 命中：對 10 筆已入庫文字各重送一次、從後端結構化 log 取 `elapsed_ms + cache_layer`，L1 p50 <1.5 s、L2 p50 <4 s
PF-2	P0	本次執行	FR-01、三層快取	三層快取命中率：對 20 筆「改寫版謠言」（姚睿準備，獨立於 eval_set）以 `POST /api/analyze/sync` 送出，log 中 `cache_layer=vector` ≥70%
PF-3a	P0	本次執行	FR-09、FR-10	Threads 本專案可控延遲：從 `run_threads_poll` 取得 mention 到 `reply_to` 回 200 ≤60 s（log `elapsed_ms`；sim 與 live 各量 3 次）
PF-3b	P1	報告後執行（需 Threads 實機 @ 回覆）	FR-09	Threads 端到端牆鐘時間（含 Meta 索引延遲，不可控）：使用者送出 @ 到回覆出現，記錄 5 次實測，目標 ≤ poll 間隔 + 60 s（demo 設 1 分鐘 → ≤2 分鐘）；未達標只記錄不擋
PF-4	P1	報告後執行（本週無對應票；模擬 fixture 僅 6 則，需補足 10 則）	FR-10	模擬模式 10 則 mention 一輪 <3 分鐘（AI 開）；mock AI 時 <10 s
PF-5	P1	本次執行	FR-14、§9 成本	成本：150 筆評測總花費 ≤ USD 1.5；每次未命中平均 ≤ USD 0.02（CGU `GET /me/usage` 評測前後差 + OP-2 usage 輸出，記入 `docs/test/cgu_usage.txt`）
PF-6	P1（可選）	報告後執行（可選比較組；spec FR-14 將其預算保留至報告後）	FR-01（模型比較）	模型比較組：同 150 筆以 `CGU_MODEL=gpt-5.4` 重跑一次（`USE_WEB_SEARCH=false`；預算 ≤ USD 2，先以 `/me/usage` 確認餘額 ≥ USD 4 才跑），與 `gpt-5.4-mini` 並列 accuracy／FN／p50 延遲／每筆成本；報告 §6 一張表；不作通過條件

註：

1. PF-3a 本輪量測模擬模式 3 次；live 3 次隨 Threads 實機串接於報告後補量。
2. 前置：PF-1 須 `evaluate.py --timing`（票 B-23）；PF-2 須改寫謠言 20 筆 `docs/test/pf2_paraphrases.csv`（票 O-11）。
3. 會寫入資料之量測（PF-2、PF-3a、QA-1a 之 `--seed-db`）依序執行，不與其他寫入程序並行（單寫者假設，spec §12 R10），執行前依 4.3 備份資料檔。

3.5 品質測試

執行方式：`evaluate.py`（150 筆 `eval_set.csv`，SCAM／MISINFO／SAFE 各 50）；QA-3 依 GitHub Actions；QA-4、QA-5 依審查紀錄。來源：spec §10.5。

ID	優先級	本次執行	對應 FR	通過準則
QA-1a	P0（閘門）	本次執行	FR-01	`evaluate.py --seed-db`（web_search 關）以 **CGU `gpt-5.4-mini`**（provider 鍵 `['cgu']`）重跑 150 筆；**FN=0（絕對條件）**；跑前後各查 `/me/usage`（PF-5）
QA-1b	P1（量測）	本次執行	FR-01	同一次執行的 accuracy 與 FP 記錄實際值，目標 ≥93%／≤8；未達標不擋交付，但報告 §6 標示「未達標」並附錯誤分析。報告依 D-8 並列舊數字（0.96，gpt-5-mini via myai168，2026-06〔v0.9 修訂：原記 2026-07，依 commit `9d63eef` 更正〕）與新數字（gpt-5.4-mini via CGU AIR，2026-09），各標 provider／model／date；PF-6 比較組（gpt-5.4）有跑才加第三欄
QA-2	P1	本次執行	FR-01（評測報告）	`evaluate.py` 報告加 `provider/model/date/use_web_search/elapsed_ms` 欄；`--report-only` 重算一致；`eval_errors.csv` 逐筆有 `error_type`
QA-3	P0	本次執行	FR-15	CI 每次 push 綠燈（`pytest` + `npm run build`）；`ci.yml` 不再寫死測試數
QA-4	P1	報告後執行（文件同步票 B-25 排在報告後）	FR-15、FR-16	CLAUDE.md、README、`.env.example` 與本 spec 的端點／設定名一致（文件審查勾核表，含：Threads 權限清單修正、§2 表格「影片語音轉文字」列刪除、移除 `ENABLE_THREADS_BOT`／STT 設定鍵、`legacy/` 標示、**§2 AI 引擎改寫為「CGU AIR 為唯一 provider、myai168 已停用、額度查 `/me/usage`」**、§9 加來源分級三條規則、`BOT_HANDLE=factcheck_tw_bot`、**§4／§7「runtime 變動不用 commit」補例外：FR-18 清洗後的 `knowledge_base.parquet` 提交一次作新種子**）
QA-5	P0	本次執行	FR-18	清洗 dry-run diff 審查（FR-18）：`data/clean_sources_report.txt` 中 0 筆 `label_source="rule"` 被降級；隨機抽 10 筆降級列由負責人逐筆判斷，同意 ≥9（不同意者記回 `TIER1_DOMAINS`／規則修正後重跑 dry-run）；Cofacts 33 筆逐筆有「有回覆／無回覆」結論；Google News 31 筆逐筆有「解析成功→新網址／失敗→刪除」結論；審查紀錄存 `docs/test/clean_sources_review.md`

註：

1. 前置：QA-2 之報告欄位與 PF-1 之 `--timing` 同屬票 B-23。
2. QA-1a 之 `--seed-db` 會把判對案例以 `gold` 標記寫入知識庫，執行前依 4.3 備份資料檔；有效預測須為 150 筆（見 4.2）。

3.6 第二次簡報輪次測試項目（v2.0 新增）

本節各項排定於第二次簡報輪次（2026-10-26～11-03）執行，結果記於 6.10（含未執行項目與原因）。第一輪的自動化項目（FN-1～FN-14、QA-3）由 QA-7 整體回歸；QA-1a、QA-1b 沿用 2026-10-15 的 150 題結果（6.9），本輪不重跑，因為 10-15 之後沒有更動判讀邏輯（票 B-44 只改顯示）。

操作測試

ID	優先級	對應 FR／票	步驟	通過準則
OP-10	P0	FR-09（雲端 live；B-38、B-39）	測試人員帳號（公開）在 Threads 上真的在流傳的「巴黎超市唯獨豬肉沒人搶」貼文底下回覆「原文 2＋@factcheck_tw_bot」並錄螢幕（情境劇的原文 2，`presentations/2026-11_第二次簡報/01_真人劇本.md`；2026-11-02 由香蕉補鈣改）（與情境劇的 Threads 錄螢幕 T1 同時完成）；回覆前後各查一次 `GET /api/threads/status`	回覆在 2 分鐘內出現；內容依 spec §7.7：第一行燈號與判定、摘要、查核來源（Tier 1）、結果頁連結、免責行；結果頁可開啟且判定相同；`replied_count` 只增加 1、`last_error` 為 null；拍攝後刪除測試貼文
OP-11	P1	FR-23（B-35、O-30）	`gh run list --workflow factcheck-sync.yml --limit 30`；`GET /api/knowledge/stats`	最近 30 次執行成功率 ≥ 90%；知識庫已證實筆數不減少

ID	優先級	對應 FR／票	步驟	通過準則
OP-12	P1	FR-24（B-36、O-30）	`gh run list --workflow weekly-eval.yml`；檢查 `docs/test/results/weekly/`	2026-10-04 起每週日都有一份報告 commit；報告列出模型、額度前後、題數、一致率與 95% 信賴區間；每次花費不超過本次上限（USD 6），執行後本週剩餘 ≥ USD 3

功能測試（執行方式同 3.2：`pytest tests -q` 與 GitHub Actions）

ID	優先級	對應 FR／票	測試檔	通過準則
FN-15	P1	FR-20	`test_factcheck_supersede.py`	命中未證實列且有 rule／gold／admin 近鄰（≥ 0.75）時改回該列；近鄰只是一般 AI 判定列時不取代；embedding 或查詢失敗時照舊回原列，不讓快取命中變成失敗
FN-16	P1	FR-21	`test_hot_claims.py`、`test_knowledge_api.py`	排行依查證紀錄的時間衰減（半衰期 3 小時）與 7 天視窗；只回已證實列
FN-17	P1	FR-22	`test_evidence.py`	信心規則表 9 列（含 `ai_unverifiable` 與 `conflict`）每列至少一個案例；「知識庫中的相似查證」最多 3 筆、相似度 ≥ 0.60
FN-18	P1	FR-23	`test_factcheck_sync.py`	recent／full 兩種模式；知識庫沒有查核機構列時 recent 自動改跑 full；同文字已存在就略過；單一來源失敗不擋其他來源；同時只跑一輪（第二次請求回 409）；設定的模型不在閘道清單時回報失敗
FN-19	P1	FR-24	`test_weekly_eval.py`	只取本週新發布的查核加歷史抽樣；可用額 = min(上限, 剩餘 − 保留)；每 100 題重讀用量；報告與 CSV 欄位完整
FN-20	P0	FR-01（B-43）	`test_ai_service_contract.py`、`test_evidence.py`、`test_evaluate_timing.py`；前端 `resultState.test.js`	AI 回 `UNVERIFIABLE` 時 `is_risk=false`、`category=Unverifiable`；知識庫以 `verified=false` 保存（不參與語意比對）；信心依據為 `ai_unverifiable`（像已知謠言時為 `conflict`）；結果頁走一般結果頁並顯示黃燈；評測把無法查證另列，不算 FN 或 FP
FN-21	P1	FR-04（B-44）	`test_kb_write_gate.py::test_category_label_keeps_native_chinese`、`test_result_api.py::test_old_result_category_label_recomputed`；正式站開 2026-10-18 以前產生的結果頁	查核機構資料的分類顯示「已查核假訊息」或「已查核詐騙」，不再顯示「其他」；舊結果頁讀取時也更正
FN-22	P1	FR-09（B-38、B-39、T-14）	`test_threads_cloud.py`、`test_threads_publish.py`、`test_threads_token.py`	雲端 live 時狀態、回覆紀錄、token 與輪詢鎖存資料庫；資料庫沒有狀態時略過不回覆；token 剩 10 天自動續期；回覆配額剩不到 10 則時本輪不回覆

績效測試

ID	優先級	對應 FR	方法	通過準則
PF-7	P1	FR-01、三層快取（正式站端到端）	對正式站送出 10 則知識庫已證實列的原文，與 1 則已知的未證實訊息（3 次）；從送出到 `GET /api/result/{id}` 回 completed 計時（API 層，不含前端動畫）；腳本記錄於 6.10	已證實列命中 p50 ≤ 5 s；未證實列命中 p50 ≤ 5 s

品質測試

ID	優先級	對應 FR／票	方法	通過準則
QA-6	P0	FR-24、FR-01（B-40、B-43）	每週新查核自動評測（M5）報告：2026-10-05（校準前）、10-12（校準 v2）、10-19 與 10-26（校準 v4）	v4 的「歷史風險題被判 SAFE（漏判）」比例不高於校準前（10.4%），這是 2026-10-15 選擇 v4 時的決策條件。本週新查核的一致率、漏判數與安全題誤判率為記錄項（題數少、信賴區間寬）
QA-7	P0	FR-15	回歸：`pytest tests -q`、`npm run test:unit`、`npm run lint`、`npm run build`；GitHub Actions `ci`	全部通過；宣告結果之 commit 的 `ci` 兩個 job 皆綠

使用者測試

ID	優先級	對應 FR	方法	通過準則
UX-1	P1	FR-01、FR-04、FR-05、FR-06（審查意見）	`docs/test/第三方實測_說明.md`：5〜8 位非組員，以自己的手機完成 T1〜T5，再填 SUS 問卷	T1 達成率（3 分鐘內查完一則訊息，並正確說出判定與查核來源）≥ 80%，附 95% 信賴區間；SUS 平均 ≥ 68（一般網站平均）；誤解之處逐項列出處置
UX-2	P1	使用情境（FR-01、FR-09）	情境劇的兩則輸入（2026-11-02 起的真人版劇本：冷水煮蛋的文字、法國暴動冷凍豬肉 AI 圖的 Threads 貼文；貼網址那段已拿掉）在錄製當天與簡報前一天各在正式站查一次	兩次的燈號與判定相同；影片中的系統畫面皆為正式站實錄，加速畫面標示倍數

註：

1. OP-10 是 PF-3b（Threads 端到端時間）在雲端運作後的實測，本輪同時記錄送出標記到回覆出現的時間。
2. PF-7 的未證實列命中，指命中知識庫中 `verified=false` 的列（例如 AI 判「無法查證」的內容）。這類命中會先做查核結果回補（FR-20）。
3. UX-1 的準則在收集資料之前訂定（2026-10-26）。

4. 測試方法

4.1 測試環境需求

項目	規格	用於
硬體與作業系統	負責人個人電腦：Intel Core i7-13700HX（16 核 24 執行緒）、32 GB RAM、Windows 11 家用版 64 位元（build 26200）；後端、測試腳本與截圖擷取皆於此執行	全部
後端執行環境	Python 3.12.9 虛擬環境 `code/backend/venv`；FastAPI＋Uvicorn 單 worker；依賴 `requirements.txt`；主控台 cp950（腳本輸出不含 emoji）	OP、FN、PF、QA
前端建置環境	Node.js 24（本機 v24.15.0）；Vite 8.3.0、React 19、Tailwind 4；`npm run build`、`npm run test:unit`（`node --test`）	QA-3、UI
持續整合	GitHub Actions `.github/workflows/ci.yml`（push／PR 至 `main` 觸發）：`test` job 為 ubuntu-latest、Python 3.12、`pytest tests -q`；`frontend` job 為 Node 20、`npm ci`、`npm run build`、`npm run test:unit`	FN 全部、QA-3
前端部署	Vercel Hobby（team 與 project `fakenewsverify`，Root `code/frontend`）；`PUBLIC_BASE_URL` = `https://fakenewsverify.vercel.app`；`vercel.json` rewrites：`/api/*` 同源代理至 tunnel，其餘路徑 SPA fallback（排除 `*.html`）	OP-8、公開網址之檢查
對外網路	Cloudflare quick tunnel（`cloudflared tunnel --url http://localhost:8000`，安裝與啟動見票 O-08）；網址 `*.trycloudflare.com` 重啟即變，依 `docs/rebuild/runbook_tunnel.md` 更新 `vercel.json` 並重新部署；單一請求須於 100 s 內完成	OP-8
AI 服務	CGU AIR Gateway（OpenAI-compatible Responses API）：`AI_PROVIDER=cgu`、`CGU_MODEL=gpt-5.4-mini`、`OPENAI_REASONING_EFFORT=low`、embedding `text-embedding-3-small`（1536 維）；provider 鏈 `['cgu']`；額度 OpenAI 成本 USD 10＋本地模型 1,000 萬 tokens；用量 `GET {CGU_BASE_URL}/me/usage`；評測與量測一律 `USE_WEB_SEARCH=false`；無 OpenAI 直連，myai168 已停用	OP-1、OP-2、PF-1、PF-2、PF-3a、PF-5、QA-1a、QA-1b
介面測試工具	Microsoft Edge 153 headless（Chrome DevTools Protocol）：桌機 1280 px、手機模擬 375 px 與 360×780、淺色與深色（模擬 `prefers-color-scheme`）；`VITE_FIXTURES=1` fixture 模式重現各狀態；`grep`、OpenCC；報告後另用 Lighthouse、axe DevTools	UI-1～UI-4、UI-6、UI-8；UI-5（報告後）
行動裝置	Android 手機與 iPhone 各一台（Android Chrome 110+、iOS Safari 16+，安裝 Threads App）：本輪供 OP-8 以行動網路開啟結果頁；報告後供真手機與 Threads App 內建瀏覽器測試	OP-8；UI-7（報告後）
Threads	本輪：`THREADS_MODE=sim`（FakeThreadsService；輸入 `data/threads_sim/mentions.json`、輸出 `data/threads_sim/replies.jsonl`；不需 Meta 憑證）。報告後：Meta 開發者帳號與 App（Threads use case；權限 `threads_basic`、`threads_content_publish`、`threads_manage_replies`、`threads_manage_mentions`）、公開之機器人帳號 `@factcheck_tw_bot` 與 Threads Tester 帳號、60 天長效 token	OP-3、FN-4、PF-3a；OP-4～OP-6、PF-3b、UI-7（報告後）
測試資料	`knowledge_base.parquet` 218 筆（D-05 清洗後種子，`verified=true` 128 筆，commit `db8c62d`）；`factcheck.db` 熱門 24 筆（全數 `verified=true`、無 Google News 轉址；不進 git，清洗前備份 `factcheck.db.bak-20260916`）；`eval_set.csv` 150 筆（SCAM／MISINFO／SAFE 各 50）；`docs/test/pf2_paraphrases.csv` 改寫謠言 20 筆（獨立於 eval_set）；OP-7 舊檔快照 `docs/test/op7_legacy/`；pytest fixture（離線，AI 與 Cofacts 一律 mock）	全部
其他工具	`curl`、`git`；ffmpeg 9.0.1 僅供 demo 影片剪輯（影片配音使用 CGU `gpt-4o-mini-tts`，費用計入 CGU 用量），不參與測試判定	4.4 影片交付

第二次簡報輪次的環境變更（v2.0）：上表為第一輪的環境；2026-10 的差異如下。

項目	2026-10 規格	用於
後端執行環境	Render 免費 web service（Python 3.12，依 `requirements-prod.txt`）；只有 `code/backend` 的變更會觸發自動部署	OP-10、PF-7
資料庫	Supabase Postgres＋pgvector（免費方案）；pg_cron 每 5 分鐘叫醒 Render	全部線上項目
AI 服務	CGU AIR `gpt-5.6-luna`（備援 `gpt-6-luna`）、推理強度 medium；embedding `text-embedding-3-small`（2026-11-03 起閘道不再提供，DEF-13）；額度每週 USD 10、週四重置	QA-6、OP-12
排程	GitHub Actions：`ci`（每次 push）、`factcheck-sync`（每天 2 次＋週日 full）、`weekly-eval`（週日）、`keepalive`（每 10 分鐘）	OP-11、OP-12、QA-7
Threads	Meta App「全民查證公社」五項權限（含 `threads_read_replies`）；機器人 token 由後端自動續期；測試人員帳號須設公開	OP-10、FN-22
使用者實測	受測者自己的手機（iOS 或 Android）、計時器；記錄表與問卷 CSV	UX-1
情境劇	2026-11-02 起由負責人和同學演 4 個真人鏡頭；旁白為 edge-tts AI 語音；以 HyperFrames＋ffmpeg 剪輯（`video/hf-scenario/`）；網站畫面以 headless Edge 錄製正式站	UX-2

4.2 測試項目的通過準則

單項判定：各項目依第 3 節「通過準則」欄判定，所有可量測條件皆達標為「通過」，任一條件未達標為「未通過」。準則中標示為記錄項或「只記錄」之內容（OP-2 之 `--web-search`／`--allowed-domains` 兩次、FN-5 之實測長度規則紀錄欄、UI-7 之 App 內深連結）不影響判定。

優先級清單（spec §10「4.2 通過準則彙總」）：

- **P0**（30 項）：OP-1／2／3／7／8／9；FN-1／2a／3／4／5／6／7／8／9／11／12／13／14；UI-1／2／4／6／8；PF-1／2／3a；QA-1a／3／5。
- **P1**（16 項）：OP-4／5／6；FN-2b／2c／10；UI-3／5／7；PF-3b／4／5／6（可選）；QA-1b／2／4。

本輪（報告前）整體通過條件

條件	準則
P0	全部 P0 項目通過（P0 項目均列為本次執行）
P1	本次執行之 P1 項目通過率 ≥80%；分母不含記錄性項目 QA-1b、PF-3b、PF-6（spec 明定其未達標只記錄、不擋交付）
絕對閘門	QA-1a：CGU `gpt-5.4-mini` 150 筆評測 FN=0，任一筆詐騙或假訊息判為 SAFE 即不通過；有效預測須為 150 筆（`eval_predictions.csv` 中 `errored` 為 0）
回歸	宣告通過之 commit：`pytest tests` 全綠、`npm run build` 成功、GitHub Actions `ci` 兩個 job 皆綠
時點	2026-09-20 審查前達成（最早報告日 2026-09-21）

本輪與報告後之計算

1. 標示為「報告後執行」之項目不列入本輪判定，於 6.1「報告後」欄計數；報告後輪次以相同準則判定並回填第 6 節（v1.1 起）。
2. 部分準則延後之本次執行項目（OP-3、FN-4、UI-1、UI-6、PF-3a；延後內容見第 3 節各表註）：本輪以未延後之準則判定，達標者記「通過（待補驗）」並計為通過；報告後補驗未達標時改記「未通過」並登錄 6.3。
3. 結果一律以下列用語標示：通過、未通過、通過（待補驗）、報告後執行、未執行（附原因）。

準則修訂紀錄（v0.9）：下列修訂於該項測試執行前經負責人核准，或屬事實更正；第 3 節修訂處以〔v0.9 修訂〕標示。

ID	spec §10 原準則	修訂後	依據
OP-1	`stats.total ≥ 150`	`stats.total ≥ 125`	D-05 決定 3a：負責人於 apply 前核准接受清洗後已證實筆數低於原估 150（決定 2 刪除後約 125 筆）；未證實資料保留但不顯示、不參與向量命中（`docs/test/clean_sources_review.md`）
OP-9	知識庫 236 筆不變；`verified=true` ≥150	知識庫筆數僅減少核准刪除清單所列且存在於種子之筆數；`verified=true` ≥125	D-05 決定 2a（核准刪除 27 筆髒資料，其中知識庫 19 筆）、決定 3a
FN-1	五個既有測試檔不得修改斷言	`test_processor_flow.py`（B-03）與 `test_api.py::test_health_and_root`（B-22）兩處例外允許修改，其餘斷言不變	負責人同意閘門 O-01（`docs/rebuild/owner_decisions_day0.md`；`03_tickets.md` §0）
QA-1b	舊數字日期記為 2026-07	2026-06（2026-06-06，commit `9d63eef`）	事實更正（git 紀錄）

第二次簡報輪次整體通過條件（v2.0）

條件	準則
P0	3.6 之 P0 項目（OP-10、FN-20、QA-6、QA-7）全部通過
P1	3.6 之 P1 項目通過率 ≥ 80%；未執行者計為未通過
回歸	同第一輪：`pytest tests` 全綠、`npm run build` 成功、GitHub Actions `ci` 兩個 job 皆綠
時點	2026-10-31 前（簡報 2026-11-02～11-04）；第一輪仍未結的 PF-2、UI-1、UI-6 依原準則繼續追蹤，不列入本輪計算

4.3 測試中止的準則與再繼續的需求

共通規則（spec §10）：任一 P0 項目未通過即中止受影響之測試與程式凍結；再繼續須：缺陷修正、該項重跑通過、`pytest tests` 全綠且 `npm run build` 成功。會寫入資料之測試（QA-1a 之 `--seed-db`、PF-2、PF-3a、OP-1、OP-7、OP-9）執行前，先以複本備份 `knowledge_base.parquet`、`tasks.parquet`、`factcheck.db` 並記錄 SHA-256；同一時間只允許一個程序寫入（單寫者假設，spec §12 R10）。

#	中止準則	中止範圍	再繼續的需求
1	任一 P0 項目未通過（含 QA-1a 出現 FN>0）	該項及以其結果為前提之項目（例：QA-1a 未通過時暫停 PF-5 成本結論與報告引用之評測數字）；暫停程式凍結與 tag	缺陷登錄 6.3 並修正；該項重跑通過（QA-1a 須 150 筆整批重跑且 FN=0）；`pytest tests` 全綠、`npm run build` 成功
2	CGU AIR 不可用：`test_ai_provider.py --provider cgu` 回 fallback 或 HTTP 401／429／5xx、`/health` 之 `ai_available=false`，或畫面出現「AI 分析暫時無法使用」	需呼叫 AI 之項目：OP-1、OP-2、PF-1、PF-2、PF-3a、PF-5、QA-1a、QA-1b；離線之功能測試與 fixture 截圖不受影響	`test_ai_provider.py --provider cgu` 連續 2 次回合法 `risk_type` 且非 fallback；中斷期間之評測若有 API 錯誤筆（`errored`）則整批重跑（`--resume` 不會重試已記錄之錯誤筆）；中斷期間之量測樣本作廢重測
3	CGU 用量超出預算：150 筆評測前後差額 > USD 1.5（PF-5 上限），或報告週累計 > USD 5（spec §9 成本）	所有需呼叫 AI 之項目	廖哲勛確認剩餘額度並核定調整後預算（記入 `docs/test/cgu_usage.txt`）；維持 `USE_WEB_SEARCH=false`
4	資料檔損毀或遭覆寫：三個資料檔任一讀取失敗；或與測試前備份、`check_db.py` 基準（清洗後：知識庫 218 筆、`verified=true` 128 筆；熱門 24 筆全數 verified）之差異無法以該測試之預期寫入解釋；或發現兩個程序同時寫入	所有讀寫資料之項目（OP、PF、QA-1a、以真後端擷取之截圖）	自備份還原：知識庫取測試前備份或已提交之清洗後種子（commit `db8c62d`）；熱門牆取測試前備份，或以 `factcheck.db.bak-20260916` 重跑 `clean_sources_2026_09.py --apply --drop-ids data/clean_sources_drop_ids.txt`（冪等）；`check_db.py` 輸出與基準一致或 SHA-256 與備份一致後，改為序列執行並重跑受影響項目
5	CI 紅燈：GitHub Actions `ci` 之 `test` 或 `frontend` job 失敗	功能測試判定（3.2）、QA-3、程式凍結與正式部署	修正後 push，`ci` 兩個 job 皆綠；本機 `pytest tests -q` 全綠、`npm run build` 成功；修正不得違反 FN-1 之受保護斷言規則
6	Tunnel 或公開部署中斷：`{PUBLIC_BASE_URL}/api/health` 非 200（含 Cloudflare 502／524），或 Vercel 部署失敗	OP-8 與經公開網址之檢查；其餘項目改於本機（`localhost:8000`／`localhost:5173`）執行	依 `docs/rebuild/runbook_tunnel.md` 重啟 `cloudflared`、更新 `vercel.json` 主機並部署 Ready；`/api/health` 連續 3 次回 200 後重跑 OP-8
7	機密外洩：CGU 金鑰、`ADMIN_TOKEN`、Threads token 或 `.env` 內容出現在截圖、log 節錄、影片或 commit	相關交付物之產出與公開	撤銷並更換外洩之金鑰或 token 使舊值失效；移除或遮蔽外洩素材；重新產出受影響之交付物並複查

4.4 測試交付項目

各項原始執行輸出（主控台輸出、API 回應、用量紀錄）存於 `docs/test/results/`，檔名以測試 ID 為前綴；6.2「證據檔案」欄引用該目錄之原始檔或下表之彙整檔。

交付項目	內容與路徑	對應測試	時點
測試計畫書	本文件 `docs/test/TP-FNV-2026-01.md`（v1.5，第 6 節已填）與匯出檔 `presentations/2026-09_進度報告/04_測試計畫書_TP-FNV-2026-01_v1.5.pdf`	全部	本輪
功能測試與 CI 紀錄	GitHub Actions `ci` run 連結與截圖 `docs/test/ci_run.png`；本機 `pytest tests -q`、`npm run build`、`npm run test:unit` 輸出	FN 全部、QA-3	本輪
操作測試紀錄	`docs/test/op_log.md`（OP-1、OP-2、OP-3、OP-7、OP-8 之時間、指令與輸出節錄）；`docs/test/deploy_log.md`（部署網址、commit、時間）	OP	本輪
評測報告	本輪：`code/backend/data/eval_report.csv`、`eval_binary.csv`、`eval_errors.csv`、`eval_predictions.csv`、`assets/confusion_matrix.png`；前一版封存：`code/backend/data/eval_archive_gpt5mini_2026-06/`；`docs/test/eval_summary.md`（新舊數字並列，標 provider／model／date）	QA-1a、QA-1b、QA-2、PF-1（未命中）	本輪
績效紀錄	`docs/test/perf_log.csv`（`result_id`、`origin`、`cache_layer`、`elapsed_ms`）、`docs/test/perf_summary.md`；`docs/test/threads_latency.csv`	PF-1、PF-2、PF-3a	本輪（PF-3a live 部分報告後）
成本紀錄	`docs/test/cgu_usage.txt`（日期／動作／前／後／差）	OP-2、PF-5	本輪
介面截圖檢核	`docs/test/ui_checklist.csv`；`docs/test/screens/`（檔名 `{畫面}_{狀態}_{寬度}_{主題}.png`，寬度 375 或 1280，主題 light 或 dark）；`docs/test/ui6_copy_check.txt`	UI-1～UI-4、UI-6、UI-8	本輪（S6 與真手機部分報告後）
資料清洗證據	`code/backend/data/clean_sources_report.txt`、`check_before_d05.txt`、`check_after_d05.txt`、`clean_sources_drop_ids.txt`；`docs/test/clean_sources_review.md`	OP-9、QA-5	已產出（2026-09-16）
Threads 證據	本輪：模擬模式 `replies.jsonl` 節錄與 `test_threads_bot.py --poll` 輸出；報告後：`docs/test/threads_live_log.md`（OP-5 原始 JSON 與錯誤 body）	OP-3、FN-4、PF-3a；OP-4～OP-6、PF-3b	本輪／報告後
缺陷紀錄	本文件 6.3；修正 commit 與回歸測試（例：commit `c114413`、`tests/test_parquet_io.py`）	全部	隨時登錄
demo 影片與素材紀錄	`docs/demo/demo_v0.3.0.mp4`（175.4 秒，不進 git，另附雲端連結）、`docs/demo/demo_v0.3.0.srt`；`docs/demo/footage_log.md`（錄製環境、各鏡 `result_id` 與 `cache_layer`、CGU 用量）	OP-3（模擬閉環呈現）；2.1 測試目標 1、2、4、6	已產出（2026-09-16）

交付項目	內容與路徑	對應測試	時點
文件一致性勾核表	`docs/test/doc_review.md`	QA-4	報告後

第二次簡報輪次的交付項目（v2.0）

交付項目	內容與路徑	對應測試
測試計畫書完整版	本文件 v2.1 與 `presentations/2026-11_第二次簡報/03_測試計畫書_TP-FNV-2026-01_v2.1_完整版.pdf`	全部
測試報告書（短版）	`docs/test/TP-FNV-2026-01_v2.1_報告版.md` 與 `presentations/2026-11_第二次簡報/03_測試報告書_TP-FNV-2026-01_v2.1.pdf`	全部（數字同本文件）
回歸紀錄	`docs/test/results/regression_2026-11-03.txt`	QA-7、FN-15～FN-22
閘道關閉 embedding 的紀錄	`docs/test/results/embedding_closed_2026-11-03.md`	DEF-13、OP-11、OP-10、UX-2
每週評測報告	`docs/test/results/weekly/weekly_eval_*.md` 與 `.csv`	QA-6、OP-12
正式站延遲紀錄	`docs/test/results/pf7_latency_2026-10-26.txt`	PF-7
Threads 實機紀錄	`docs/test/threads_live_log.md`（OP-10 之時間、截圖與 status 前後值）	OP-10
第三方實測紀錄	`docs/test/第三方實測_記錄表.csv`、第三方實測_問卷.csv 與計分結果	UX-1
情境劇影片	網站可直接播放之影片檔與 `presentations/2026-11_第二次簡報/` 說明	UX-2

4.5 測試工作項目與時程

本輪（報告前）：以最早報告日 2026-09-21 為截止（`owner_decisions_day0.md`）。日期為預定，實際執行日期記於第 6 節；會寫入資料之項目依表列順序序列執行（4.3）。

日期（2026）	工作項目	測試 ID	主責	產出／完成條件
09-15（二）	規格書 v1.3、實作票、計畫書第 1–3 節初稿（v0.1）；清洗腳本 dry-run 與審閱文件	—（準備）	廖晢勛；Claude Code	已完成：`01_spec.md`、`03_tickets.md`、本計畫 v0.1、`clean_sources_review.md`
09-16（三）凌晨	D-05 清洗套用與二次 apply（冪等）；以模擬模式錄製 demo 影片 v0.3.0；修正結果頁偶發 500（DEF-01）	OP-9、QA-5；OP-3（模擬部分）	廖晢勛；Claude Code	已完成：`check_after_d05.txt`、`footage_log.md`、commit `c114413`
09-16（三）	計畫書 v0.9；補齊測試前置（B-02 `test_ai_provider.py` 旗標、B-23 `evaluate.py --timing` 與報告欄位、O-11 改寫謠言 20 筆）；確認本機 pytest、前端 build 與 CI；CGU provider 測試與用量基準	FN（本次執行項目）、QA-3、OP-2	廖晢勛；姚睿（審定改寫謠言）；Claude Code	本計畫 v0.9；CI 綠；`cgu_usage.txt` 基準列
09-16（三）～09-17（四）	資料檔備份後依序執行：150 筆評測（`USE_WEB_SEARCH=false`，前後查用量）→ 快取命中延遲與向量命中率 → 模擬模式 Threads 延遲	QA-1a、QA-1b、QA-2、PF-5、PF-1、PF-2、PF-3a（模擬部分）	姚睿；Claude Code	`eval_*.csv`、`eval_summary.md`、`perf_log.csv`、`perf_summary.md`、`threads_latency.csv`
09-17（四）	介面截圖擷取（Edge headless）、逐格勾核與文案／顏色／來源紀律檢查	UI-1、UI-2、UI-3、UI-4、UI-6、UI-8	石岱勳（勾核）；Claude Code（擷取與自動檢查）；張宇宏（覆核）	`ui_checklist.csv`、`screens/`、`ui6_copy_check.txt`
09-17（四）～09-18（五）	demo 影片審片（查核來源皆 Tier 1／2、無金鑰入鏡、無 fallback 畫面、長度 ≤3:00）；簡報數字依實測紀錄更新	—（交付項目）	廖育翔	審片結果記入 `footage_log.md`
09-18（五）	啟動 tunnel、更新 `vercel.json` 並確認部署；發佈前操作測試：全新 clone、舊檔載入、公開網址（含手機行動網路）	OP-8、OP-1、OP-7	廖晢勛；石岱勳（手機）	`op_log.md`、`deploy_log.md`
09-19（六）	缺陷修正與回歸；未通過項目依 4.3 重測；彙整 6.1～6.3	依 6.3	廖晢勛；Claude Code；張宇宏	回歸後 CI 綠；6.1～6.3 填妥
09-20（日）	第 6 節審查、升 v1.0 並匯出 PDF；demo 彩排（模擬模式）；程式凍結（tag `v0.3.0-demo`）	本輪全部	張宇宏（審查）；廖育翔（彩排）；廖晢勛（凍結）；指導教授簽核依其時程	本計畫 v1.0、`TP-FNV-2026-01_v1.0.pdf`、tag
09-21（一）～09-23（三）	進度報告與 demo 影片發表（確切日期依課程公告）；待命處理阻塞缺陷（只修 demo 阻塞者）	—	全員	報告完成

報告後：目標日期為暫定，依課程進度與 Meta App 設定進度調整；完成後回填第 6 節（v1.1 起）。

目標日期（2026）	工作項目	測試 ID	前置條件（票）
09-24（四）～09-25（五）	文件同步與一致性勾核	QA-4	B-25
09-24（四）～09-30（三）	Meta App 與 Threads use case 設定、Tester 邀請與接受（帳號公開）、取得長效 token；live 探測；兩段式發佈、錯誤分流與 backoff；live 端到端回覆與延遲量測	OP-4、OP-5、PF-3a（live 部分）、PF-3b；FN-4 延後案例、FN-5 紀錄欄	O-07、O-09、T-12～T-17
token 取得滿 24 小時後（10-01 前）	token 續期	OP-6	OP-4 通過
10-01（四）～10-03（六）	機器人狀態頁完成後補驗	OP-3、UI-1（S6）、UI-6（S6 文案）之延後部分	S-11
10-05（一）～10-09（五）	真手機（iOS、Android）與 Threads App 內建瀏覽器測試；無障礙量測（Lighthouse、axe、鍵盤操作）	UI-7、UI-5	P-18、O-28；Threads 實機串接完成
10-05（一）～10-16（五）	P1 功能實作後之測試：圖片查證、`similar_news` 向量近鄰、AI 額度護欄	FN-2b、FN-2c、FN-10	B-26／S-13；D-18；FR-14 程式
10-12（一）～10-16（五）	模擬模式 10 則一輪量測；`gpt-5.4` 模型比較組（可選）	PF-4、PF-6	10 則 mention fixture；`/me/usage` 餘額 ≥ USD 4
10-19（一）	報告後輪次結果回填第 6 節並審查	上列全部	上列完成

第二次簡報輪次（v2.0）：日期為預定，實際日期記於 6.10。

日期（2026）	工作項目	測試 ID	主責	產出／完成條件
10-26（一）	計畫書 v2.0 第 1–5 節；回歸測試；正式站延遲量測；同步與每週評測紀錄彙整	QA-7、PF-7、OP-11、OP-12、QA-6	廖晢勛；Claude Code	6.10 初稿

日期（2026）	工作項目	測試 ID	主責	產出／完成條件
10-27（二）～10-28（三）	情境劇拍攝，同時執行 Threads 實機回覆與錄影；情境訊息第一次查證	OP-10、UX-2	全員；廖晢勛（Threads 帳號）	拍攝素材；`threads_live_log.md` 增補
10-27（二）～10-29（四）	第三方實測 5～8 人	UX-1	石岱勳（主持）；姚睿（記錄）	記錄表與問卷 CSV
10-30（五）	計分並回填 6.10；審查	UX-1、本輪全部	Claude Code（計分）；張宇宏（審查）	本計畫 v2.0 定稿與 PDF
10-30（五）～10-31（六）	情境劇改為不拍真人（10-27～10-28 的拍攝沒有進行）：負責人錄旁白 V1～V4；Threads 實機回覆與錄影（OP-10、T1）改由負責人執行	OP-10、UX-2	廖晢勛	旁白錄音；`threads_live_log.md` 增補
11-01（日）	情境訊息第二次查證；最後檢查	UX-2	廖晢勛	6.10 補記
11-02（一）～11-03（二）	實際進度：真人 4 個鏡頭拍好；情境劇出片（煮蛋網站段以知識庫原文實錄，Threads 段為示意畫面）；查明閘道關閉 embedding；回歸重跑；回填 6.10	QA-7、OP-11、OP-12、QA-6	廖晢勛；Claude Code	本計畫 v2.1 與 PDF

5. 人員配置與訓練需求

5.1 測試人員配置

團隊共 5 人（共識 §1）。分工於 2026-09-19 經組內確認（v1.0 為負責人草擬、v1.1 暫時留白），如下表。「代號」欄供對照本輪之前已產出、沿用組員 A～E 稱呼的紀錄檔。

AI 輔助聲明：本專題的程式實作與自動化測試執行，包括撰寫程式與測試碼、執行 `pytest`、評測與量測腳本、以 headless 瀏覽器擷取截圖、彙整紀錄檔，由 AI 程式開發助理 Claude Code（Anthropic）協助完成，全程在廖晢勛（負責人）監督下進行。負責人決定範圍與準則、審核每一項程式變更與測試結果，並負責金鑰與資料之存取；需要人工判斷的工作（介面勾核、資料清洗審閱、測試結論與簽核）由組員與審查者執行，不由 AI 代為判定。

姓名	代號	角色	職責	負責測試項目
廖晢勛（負責人）	組員 A	測試負責人／操作者	訂定與維護測試計畫與時程；管理測試環境（`.env` 金鑰、CGU 用量、tunnel、Vercel）；執行操作測試；判定中止與再繼續（4.3）；監督 Claude Code 之實作與自動化執行並審核結果；報告後擔任 Threads Tester（發布測試貼文）	OP-1～OP-9、QA-3、QA-5；FN 全部（監督執行）
石岱勳	組員 B	介面測試員（真手機）	截圖檢核表逐格勾核（非實作者）；以手機行動網路開啟公開網址；報告後以 iOS／Android 真手機與 Threads App 內建瀏覽器測試；報告後擔任 Threads Tester（回覆並 @機器人）	UI-1～UI-4、UI-6、UI-8、OP-8（手機部分）；報告後 UI-5、UI-7、PF-3b
姚睿	組員 C	績效與品質數據	審定 PF-2 改寫謠言 20 筆；監看評測執行並記錄 CGU 用量；彙整延遲、命中率與成本；撰寫評測錯誤分析	PF-1～PF-6、QA-1a、QA-1b、QA-2
張宇宏	組員 D	文件與審查	維護本計畫書並彙整第 6 節；檢查交付項目完整性；覆核截圖檢核表；協助清洗審閱抽查；文件一致性勾核	QA-4、QA-5（協助）；4.4、6.1～6.3
廖育翔	組員 E	影片與簡報	demo 影片審片（對照 `footage_log.md`）；彩排；進度報告簡報；報告後補錄 live 片段	4.4 影片交付；OP-3（閉環呈現）
黃崇源（指導教授）	—	審查者	審閱本計畫與第 6 節結果並簽核	6.4
Claude Code（AI 輔助工具，非組員）	—	實作與自動化執行	於廖晢勛監督下撰寫程式與測試、執行自動化測試與量測腳本、擷取截圖、彙整紀錄；結果一律經廖晢勛確認	FN 全部、PF／QA 腳本、UI 截圖擷取（僅執行，不作判定）

第二次簡報輪次分工（v2.0）

姓名	本輪職責	負責測試項目
廖晢勛（負責人）	操作 Threads 測試帳號；情境劇真人演出（2026-11-02，與同學演自己）；監督自動化測試與量測	OP-10、OP-11、OP-12、QA-7、PF-7、UX-2
石岱勳	第三方實測主持人	UX-1
姚睿	第三方實測記錄員；彙整每週評測數字	UX-1、QA-6
張宇宏	審閱本計畫 v2.0 與 6.10	6.10.4
廖育翔	簡報當天播放影片與回答提問	UX-2

2026-10-30 起情境劇不拍真人：原訂由組員擔任的主持人、講解與短劇演員取消，旁白由負責人錄，角色台詞以 AI 語音產生（片頭片尾註明）。 | Claude Code（AI 輔助工具，非組員） | 執行自動化測試與量測腳本、計分、彙整紀錄；結果一律經廖晢勛確認，不作判定 | QA-7、PF-7、UX-1（計分） |

5.2 訓練需求

訓練項目	對象	內容	時點	完成確認
系統啟動與測試腳本	廖晢勛講授；石岱勳、姚睿、張宇宏、廖育翔	`start.bat` 一鍵啟動（自動產生 `ADMIN_TOKEN`；`.env` 不得外流）；`pytest tests -q`、`npm run build`、`npm run test:unit`；`test_ai_provider.py --provider cgu`；`test_threads_bot.py --reset-sim`／`--poll`（模擬模式）；`check_db.py`；Windows 主控台 cp950 輸出限制	09-16	每人至少於一台電腦完成一次 `pytest` 全綠
CI 判讀	廖晢勛、張宇宏	GitHub Actions `ci` 之 `test`、`frontend` 兩個 job；失敗 log 定位；與本機結果比對；CI 紅燈時依 4.3 中止	09-16	能說明最新一次 run 之狀態並附連結
評測腳本使用	姚睿	`evaluate.py` 參數（`--seed-db`、`--delay`、`--resume`、`--report-only`）與輸出檔；`USE_WEB_SEARCH=false`；前後查 `/me/usage` 並記錄；errored 筆數與 FN／FP 判讀；單寫者限制與執行前備份	09-16	能依 `eval_binary.csv`、`eval_errors.csv` 說明 FN、FP 與錯誤筆之意義
截圖檢核表	石岱勳（張宇宏覆核）	`ui_checklist.csv` 欄位與檔名規則；spec §8.4 狀態總表；§8.7 文案逐字比對；§8.6 違規（字級 <13 px、hover-only 說明）；來源 tier 小標與紅黃線使用紀律；不通過時登錄缺陷	09-17 擷取前	試勾 3 列並經廖晢勛確認
AI 輔助產出審核	廖晢勛	以 `git diff` 檢視 Claude Code 之變更；本機重跑 `pytest` 並比對 CI 以獨立確認結果；確認受保護測試斷言未被修改（FN-1）；確認第 6 節數字出自原始紀錄檔	持續	第 6 節每筆結果皆附證據檔案
Threads Tester 設定	廖晢勛、石岱勳（指導教授可選）	Meta App 角色邀請與於 Threads App「網站權限」接受；帳號設為公開；開發模式限制（只讀得到 Tester 之提及與貼文）；回覆可疑貼文並 `@factcheck_tw_bot` 之操作	報告後（09-24 起）	後台角色頁截圖與帳號公開確認
真手機測試程序	石岱勳	iOS Safari、Android Chrome 與 Threads App 內建瀏覽器開啟 `/r/{id}`；分享 Web Intent 驗證；結果頁 3 秒可讀性判定方式	報告後（10-05 前）	完成 1 筆試測紀錄

6. 測試結果與審查

本節依 2026-09-16 之實測紀錄填寫。結果用語依 4.2：通過、通過（待補驗）、未通過、未執行（附原因）、報告後執行；每一筆數字均出自 4.4 所列之原始紀錄檔（docs/test/results/），凡由本節換算者於「主要實測數據」欄註明。

6.1 測試執行摘要

本小節至 6.3 為 **2026-09-16 第一輪**結果，保留原樣。第一輪未通過與未執行的項目於 2026-09-19～09-20 修正後重測，結果見 **6.5**。

項目	內容
執行期間	2026-09-16（+08:00）：功能（3.2）與品質（3.5）03:11–03:47；操作（3.1）、介面（3.3）與績效（3.4）03:07–04:12；缺陷 DEF-02 之修正與回歸至 04:26。兩組測試並行執行並共用同一把 CGU 金鑰（見下方環境差異第 6 點）
受測版本（commit）	量測起始 `c114413`（= 當時 `origin/main`，工作樹乾淨）；量測期間合入 `b1fc5c3`（`parquet_io` 重試視窗加長、`evaluate.py` 於 0 筆錯誤時清空 `eval_errors.csv`）；本節宣告版本為 **`ad13f2f`**（= `origin/main`，含 DEF-02 修正與其回歸測試，後端 `pytest tests` **478 passed**）。8030 後端量得之操作／介面／績效數據執行的是 `c114413` 之程式碼
CI run	宣告版本 `ad13f2f`：run **35019722949**，`test` 與 `frontend` 兩個 job 皆 success；`b1fc5c3`：run 35015937421 success；量測當時最新為 `c114413` 之 run 35008720030（`test` job 19 s）。自 2026-09-14 重做起算之 17 次 run 全數 success、0 次失敗
與 4.1 環境之差異	1. 後端跑在 `127.0.0.1:8030`（OP-7 另開 8031 指向舊資料複本）而非 8000；前端以暫存 Vite dev server（5310／5311／5330／5342，獨立設定與 cacheDir）而非 5173，以免動到測試負責人自用的 5173／5179／5199。2. 未啟動 Cloudflare quick tunnel、未經 Vercel 公開網址測試（OP-8 未執行；`vercel.json` 之 tunnel 主機仍為 `REPLACE-ME.trycloudflare.com`）。3. 推理強度實際為 `CGU_REASONING_EFFORT=medium`（4.1 與 spec §9 寫的是 `OPENAI_REASONING_EFFORT=low`，provider `cgu` 讀的是前者；鍵名不一致列入 QA-4 文件同步）。4. 測試前置票 B-02（`test_ai_provider.py --web-search／--allowed-domains`）與 B-23（`evaluate.py --timing` 與報告欄位）未合入 HEAD，OP-2 記錄項與 PF-1 未命中子準則因此無法依計畫方法執行。5. 本機未安裝 OpenCC、Lighthouse、axe，且本輪不新增安裝（UI-6 簡繁 diff、UI-5 量測未執行）。6. 兩組測試並行，延遲數據是在閘道同時承受 150 筆評測流量下量得；`/me/usage` 差額混有兩組流量，成本以閘道計價分攤估算。7. QA-1a 未加 `--seed-db`（避免與並行測試同時寫入資料檔，單寫者假設），只影響判對案例是否回寫知識庫，不影響預測與指標。8. 介面檢核表之「目視」欄為 Claude Code 預檢，未經非實作組員勾核與覆核（UI-1 因此未執行）。9. PF-2 的 20 筆改寫句由 Claude Code 為本次量測撰寫，非票 O-11 所指之組員審定版本

類別	項目數	本次執行（§3 指定）	通過	通過（待補驗）	未通過	未執行	報告後執行
操作測試（3.1）	9	6	3	1	0	1	4
功能測試（3.2）	16	13	12	0	1	0	3
介面測試（3.3）	8	6	4	0	0	2	2
績效測試（3.4）	7	4	1	1	1	1	3
品質測試（3.5）	6	5	4	0	1	0	1
合計	**46**	**34**	**24**	**2**	**3**	**4**	**13**
其中 P0 小計	**30**	**30**	**21**	**2**	**2**	**4**	**1**

註：

1. 右側五個結果欄之和 = 項目數。「本次執行（§3 指定）」為第 3 節「本次執行」欄所列項目數，與結果欄的「報告後執行」相差 1 項，差額為 OP-8（見註 2）。
2. **OP-8（P0）**在第 3 節列為本次執行、4.5 排 09-18，本輪因未啟動 tunnel 與公開部署而未執行，改列報告後執行；4.2「P0 項目均列為本次執行」之前提本輪因此不成立，此範圍變更須經 6.4 審查確認。
3. 依 4.2 第 2 點，「通過（待補驗）」計為通過：OP-3（待補 `/bot` 頁顯示）、PF-3a（待補 live 3 次）。
4. FN-2b、FN-2c、FN-10、OP-4～OP-6、UI-5、UI-7、PF-3b、PF-4、PF-6、QA-4 於第 3 節即列為報告後執行，依 4.2 第 1 點不列入本輪判定。功能／品質執行結果檔將 FN-2b／2c／10 記為「未執行（功能未實作、無測試）」，本節依 4.2 統一記為「報告後執行」，兩者所指狀態相同。
5. 未執行 4 項（OP-1、UI-1、UI-6、PF-1）之原因逐項見 6.2，均為「需另備環境、人員勾核或前置票未合入」，非測試失敗。

整體判定（4.2）	結果
P0 通過數／P0 項目數	**23／30**（通過 21＋通過（待補驗）2）。未通過 2（FN-4、PF-2）、未執行 4（OP-1、UI-1、UI-6、PF-1）、報告後執行 1（OP-8）→ **未達「全部 P0 通過」**
本次執行之 P1 通過率（不含記錄性項目）	本次執行之 P1 共 4 項（UI-3、PF-5、QA-1b、QA-2），依 4.2 扣除記錄性項目 QA-1b 後分母為 3：通過 2（UI-3、PF-5）、未通過 1（QA-2）＝ **66.7%**，**未達 ≥80%**
QA-1a FN（有效預測筆數）	**FN = 0**；有效預測 **150／150**（`eval_predictions.csv` 之 `errored` 為 0），TP 100／FP 0／TN 50 → **絕對閘門達成**（執行偏差：未加 `--seed-db`，見 6.2）
通過（待補驗）之項目	**OP-3**（待補驗：`/bot` 頁 ≤4 秒顯示該回覆，票 S-11）、**PF-3a**（待補驗：live 3 次量測）

本輪是否達到 4.2 之通過準則：否。 四項本輪整體通過條件中，只有「絕對閘門 QA-1a（FN=0）」與「回歸（宣告版本 `ad13f2f` 之 `pytest` 全綠、`npm run build` 成功、CI 兩個 job 皆綠）」達成；「全部 P0 通過」與「本次執行之 P1 通過率 ≥80%」兩項未達成，時點條件（09-20 審查前）尚在期限內。未達成之具體內容：

1. **FN-4（P0，未通過）**：Threads 機器人之三項實機發佈與錯誤分流行為——HTTP 429 → 設定 `backoff_until`、未知 4xx → 標 failed 不回覆、container `FINISHED` 才 publish 且 `ERROR` 重試一次——**尚未實作**，因此不適用「通過（待補驗）」，依 4.2 判為未通過；模擬模式其餘 7 項子準則之 73 個測試全數通過。修正依票 T-13（前兩項）與 T-12（第三項），目標 **2026-09-24～09-30**，並須一併統一 spec §7.5（其他 4xx → unreadable）與 §7.10／FN-4（未知 4xx → failed）之文字衝突。
2. **PF-2（P0，未通過）**：向量快取命中率 65%（13／20）低於 ≥70%，差 1 筆。原因分析與改善計畫見 6.2 該列與 6.3（DEF-05）；目標 **報告後（10-05 前）** 以組員審定之改寫句題組重測。
3. **未執行之 4 項 P0**：OP-1（全新 clone）、UI-1（深色全套與非實作組員勾核）、UI-6（OpenCC 與英文字允許清單界定）、PF-1（未命中延遲需 `--timing`，票 B-23）；OP-8 改列報告後。若要在報告前補齊，依 4.5 須於 09-17～09-20 完成。

對進度報告的意義：本計畫書本輪**不得宣稱「全部 P0 通過」**。進度報告與 demo 影片可引用的已驗證數字，限於本節判為通過之項目——150 筆評測 accuracy 1.000／FN 0／FP 0（QA-1a、QA-1b）、L1 快取命中 p50 213 ms 與 L2 向量命中 p50 3.06 s（PF-1 之子準則）、模擬模式 Threads 閉環回覆 205–264 ms（OP-3、PF-3a）、來源紀律與清洗後資料（UI-8、OP-9、QA-5）、CI 全綠與後端 478 個測試（QA-3）——並須同時說明未達標項目與其時程。依 4.3 第 1 列，FN-4 與 PF-2 觸發中止準則：受影響範圍為「Threads 實機發佈行為」與「向量快取命中率」兩項對外宣稱，其餘已通過項目之結論不受影響；程式凍結與 tag `v0.3.0-demo` 依 4.5 於 09-20 前，視 OP-1、OP-8、UI-1、UI-6、PF-1 之補齊情形由測試負責人廖晢勛決定。

6.2 各項結果明細

「本次執行」欄同第 3 節，報告後執行之原因見第 3 節各表；OP-3、FN-4、UI-1、UI-6、PF-3a 有部分準則延後，結果依 4.2 標示。證據路徑以 `docs/test/results/` 為根（`raw/…` 即 `docs/test/results/raw/…`；`functional_quality`、`operation_ui_performance` 指同目錄之 `functional_quality_2026-09-16.md`、`operation_ui_performance_2026-09-16.md`），其餘路徑自專案根目錄起算。

ID	優先級	本次執行	結果	主要實測數據	證據檔案
OP-1	P0	本次執行	未執行（附原因）	**未執行原因**：須於另一資料夾全新 clone 並由 pip／npm 下載套件、金鑰由廖哲勛自填（3.1 註 3），本輪執行者不下載套件、不處理金鑰；4.5 排 09-18。以本機 8030 預檢可判定之子項皆達標：`/health` 與 `/api/health` 200、`ai_available=true`、`threads_mode=sim`；`GET /api/knowledge/stats.total = 128`（門檻 ≥125）、`unverified_count=90`；`POST /api/threads/poll` 無 token／錯 token 皆 401、正確 token 202；`/api/result/{不存在}` 404；後端啟動至 `/health` 200 為 1.89 s。未驗：<5 分鐘（含 pip／npm）、`.env` 自動產生 ≥32 字 `ADMIN_TOKEN`、前端 5173	`raw/op_startup_health_8030.txt`、`raw/op_backend_runtime_notes.txt`
OP-2	P0	本次執行	通過	P0 條件全數達標：provider 鏈 `['cgu']`、`risk_type=SAFE`（合法值）、非 fallback、`usage={input_tokens: 1259, output_tokens: 304}`、`model=gpt-5.4-mini`、embedding 維度 **1536**；exit 0、約 8.4 s、依閘道計價約 USD 0.0046。記錄項未執行（腳本無 `--web-search`／`--allowed-domains`，票 B-02 未合入；`docs/test/cgu_usage.txt` 未建立），依 4.2 記錄項不影響判定	`raw/op2_test_ai_provider_cgu.txt`
OP-3	P0	本次執行	通過（待補驗）	3 輪 `--reset-sim` → `--poll`：每輪 `POST /api/threads/poll` 202、`checked=3 replied=3 skipped=0 errors=0`、`replies.jsonl` 每輪新增 3 行、`status.mode == "sim"`；m1（文字）走 L1 hash 命中並回覆紅燈「詐騙警告」＋來源 mygopen.com＋`{PUBLIC_BASE_URL}/r/{id}`。待補驗：`/bot` 頁 ≤4 秒顯示該回覆（票 S-11，報告後；目前為佔位頁）	`raw/pf3a_threads_sim_rounds.txt`、`raw/pf_backend_structured_log_8030.txt`；`docs/test/screens/S6_placeholder_375_light.png`
OP-4	P1	報告後執行	報告後執行	需 Meta App、Threads Tester 與實機授權；4.5 排 09-24～09-30	—
OP-5	P1	報告後執行	報告後執行	需 Threads 實機 token 與 Tester 帳號；FN-5 之「實測長度規則紀錄欄」依附本項	—
OP-6	P1	報告後執行	報告後執行	需實機 token 取得滿 24 小時（OP-4 通過後、10-01 前）	—
OP-7	P0	本次執行	通過	舊檔快照 SHA-256 與 `op7_legacy/README.txt` 三檔一致；以工作樹 HEAD 程式在 8031 啟動、2.17 s 健康。**載入成功**：`/health`、知識庫、熱門、`/api/threads/status` 與舊任務 completed×2／pending×2／failed×2 的 `/api/result/{id}` 皆 200。**新欄位為預設值**：知識庫 `verified` 補 False（stats `total=0`、`unverified_count=236`）、舊任務 `verification_status=unverified`、`source_tier=null`、`similar_news=[]`；`factcheck.db` 啟動時 `ALTER` 新增 6 欄。**筆數不變**：`check_db.py` 前後輸出逐字相同（知識庫 236、熱門 63），`tasks.parquet` 33 筆。差異：以 scratchpad 複本代替全新 clone（程式同為工作樹 HEAD）。附帶發現 DEF-02	`raw/op7_check_db_before.txt`、`raw/op7_check_db_after.txt`、`raw/op7_legacy_api_checks.txt`、`raw/op7_legacy_results.txt`
OP-8	P0	本次執行	報告後執行（本輪範圍變更，見 6.1 註 2）	本輪未執行：需 Cloudflare quick tunnel＋Vercel 公開部署與手機行動網路；`vercel.json` 之 tunnel 主機仍為 `REPLACE-ME.trycloudflare.com`。4.5 原排 09-18，本輪改列報告後，須經 6.4 確認	`operation_ui_performance` §2
OP-9	P0	本次執行	通過	① dry-run 不改檔（以提交種子之複本重跑，兩檔 SHA-256 與 mtime 皆不變）；② 各規則影響筆數與逐筆 before→after 見 D-05 dry-run 報告與審閱紀錄；③ apply 後知識庫 **218 = 236 − 18**（核准刪除清單中存在於種子者）、`verified=true` **128**（≥125）、熱門牆 24 筆、`news.google.com` **0**；④ `knowledge_base.parquet.bak-20260916`、`factcheck.db.bak-20260916` 存在；⑤ 第二次 apply 各規則影響 **0**（冪等，Cofacts 網路查詢 0 次）；⑥ `pytest tests` 綠	`docs/test/clean_sources_review.md`；`code/backend/data/clean_sources_report.txt`、`check_before_d05.txt`、`check_after_d05.txt`；`raw/op9_idempotency_rerun_scratch.txt`
FN-1	P0	本次執行	通過	8 檔 **37 passed**。`test_cache_and_store`／`test_marking_rules`／`test_url_validator` 自 2026-07-12 起未改；`test_processor_flow.py`（B-03）與 `test_api.py::test_health_and_root`（B-22）之斷言修改為 4.2 已登記之例外。新增測試：文字輸入不呼叫 crawler（`CountingCrawler.calls == 0`）、系統 prompt 含 FR-19 逐字規則之字串比對，皆通過。備註：spec §10.2 FN-1 原文尚未回寫這兩項例外（列入 6.4 待確認事項）	`raw/fn_per_item_pytest.txt`、`raw/fn1_protected_tests_git_history.txt`
FN-2a	P0	本次執行	通過	**53 passed**：10 個私網／協定樣本全部拒絕且未發出請求、3 個公網放行；連線逾時 10 s 與 `CRAWLER_TIMEOUT` 以 mock 各自驗證；爬取失敗 5 種錯誤碼回 UNVERIFIABLE 且 AI 0 次；非網址 422；同網域來源剔除。補充端點實測：10 樣本 × 2 端點共 19 次 422（`blocked_url` 18、`invalid_url` 1——`ftp://` 在 `/api/analyze/url` 回 `invalid_url`，在 `/sync` 走文字管線），對外請求 0 次	`raw/fn_per_item_pytest.txt`、`raw/fn2a_adhoc_endpoint_all10.txt`
FN-2c	P1	報告後執行	報告後執行	`similar_news` 向量近鄰未實作（`pandas_task_processor.py` L215、L479 固定回 `[]`，D-18），無對應測試	`raw/fn_per_item_pytest.txt`
FN-2b	P1	報告後執行	報告後執行	圖片查證端點未實作 magic bytes／10 MB 檢查（票 B-26 報告後），無 415／413／bytes hash 測試	`raw/fn_per_item_pytest.txt`
FN-3	P0	本次執行	通過	**38 passed**：`/api/result/{id}` 對 pending／completed／failed／404／ai_unavailable 五態 schema 正確；sync／async／threads_sim 三種來源皆 200；`/health` 含 `scheduler.{enabled,interval_hours}`。DEF-02 修正後另增回歸測試 `test_legacy_fallback_task_marked_ai_unavailable`	`raw/fn_per_item_pytest.txt`；`code/backend/tests/test_result_api.py`
FN-4	P0	本次執行	**未通過**	**73 passed**，但 10 項子準則中僅 7 項有測試且通過（文字 mention `threads_len ≤ 400` 且含 `/r/`、IMAGE → `reply_media_only`、`get_post` 403 → `reply_cannot_read`、二次 poll 不重複、fallback 不回覆不標記、自我貼文兩種跳過、每則後 state 已寫入）。**3 項行為尚未實作、亦無測試**：① HTTP 429 → 設定 `backoff_until`（現行把 429 當 transient、下輪重試）；② 未知 4xx → 標 failed 不回覆（現行依 spec §7.5 回 `reply_cannot_read` 並標記，與 §7.10／本準則原文衝突）；③ container `FINISHED` 才 publish、`ERROR` 重試一次（現行建 container 後直接 publish，無狀態輪詢）。因屬**未實作**而非「已實作但本週無法驗證」，依 4.2 判未通過（不適用「通過（待補驗）」）。修正：票 T-13（①②）、T-12（③），目標 **09-24～09-30**；併同統一 spec §7.5 與 §7.10 之衝突	`raw/fn_per_item_pytest.txt`；`code/backend/tests/test_threads_bot_sim.py` L639-667；`app/workers/threads_bot.py` L185-187；`app/services/threads_service.py` L299-311
FN-5	P0	本次執行	通過	**21 passed**：七種第一行模板 `threads_len ≤ 400`（目標常數 `THREADS_TARGET_LEN = 400`）、連結數 ≤2；4 emoji＋200 字與含警示符號（U+26A0 U+FE0F）兩個極端案例 ≤500 且保留結果頁連結；「尚無查核機構證實」替代行之連結數 = 1；`threads_len` 對 BMP emoji／U+FE0F／U+200D 以 bytes 計。記錄項「實測長度規則紀錄欄」依附 OP-5（報告後），依 4.2 不影響判定	`raw/fn_per_item_pytest.txt`
FN-6	P0	本次執行	通過	**23 passed**：`frame_of()` 對 spec §7.8 表 **8 列** + 13 組額外輸入（準則要求 ≥11）；含「SAFE、0.95、unverified → yellow 尚無查核機構證實」、「SAFE、0.95、verified → green」、「缺 `verification_status` 鍵 → 視為 unverified」三組	`raw/fn_per_item_pytest.txt`

ID	優先級	本次執行	結果	主要實測數據	證據檔案
FN-7	P0	本次執行	通過	**8 passed**：fallback 同時帶 `ai_unavailable=True` 與 summary 前綴；`scripts/evaluate.py`、`scripts/test_ai_provider.py` 皆改呼叫 `verdict.is_fallback`（單一判斷點）	`raw/fn_per_item_pytest.txt`
FN-8	P0	本次執行	通過	**8 passed**：`q="("` 200；`offset` 分頁不重複不遺漏；stats 四格加總 = total；fixture 中 `verified=false` 列不出現在列表且不計入 `total`	`raw/fn_per_item_pytest.txt`
FN-9	P0	本次執行	通過	**10 passed**：無 token／錯 token → 401；`ADMIN_TOKEN` 空或空白 → 403；正確 → 200（trending refresh）與 200／202／409（threads poll）；比對使用 `hmac.compare_digest`	`raw/fn_per_item_pytest.txt`
FN-10	P1	報告後執行	報告後執行	`DAILY_AI_CALL_CAP` 未實作（app/ 與 tests/ 皆無此字串），FR-14 護欄程式排報告後	`raw/fn_per_item_pytest.txt`
FN-11	P0	本次執行	通過	**29 passed**：同文 hash 命中；改寫文以固定向量 fixture 走完整管線得 `cache_layer == "vector"` 且 AI 0 次；`verified=false` 列即使相似度 1.0 仍不命中 vector 層、hash 層仍命中	`raw/fn_per_item_pytest.txt`
FN-12	P0	本次執行	通過	**32 passed**：`test_tier_table` 20 組（≥15），含 `gov.tw.evil.com` → 3、`news.google.com/rss` → 3、MyGoPen 任意標題 → 1、ETtoday 查核標題 → 2／一般標題 → 3、offline Cofacts → 3 且未發請求；Cofacts 有回覆 → 1／無回覆 → 3／GraphQL 逾時 → 3；GraphQL 端點斷言 `https://api.cofacts.tw/graphql`；Tier 2 以 mock 斷言委派 `news_fetcher._title_indicates_debunk`	`raw/fn_per_item_pytest.txt`
FN-13	P0	本次執行	通過	**22 passed**：FR-17 驗收 1 之四組（Tier 1 → true；只有 Tier 3 → false 且 vector 不命中；`sources=[]` + rule → true；Tier 1 但 validator 判死 → false）；`/api/result` 之 `verification_status` 三值正確；回應 `sources[]` 無 tier 3	`raw/fn_per_item_pytest.txt`
FN-14	P0	本次執行	通過	**11 passed**：fixture Parquet 與 SQLite 在 `--dry-run` 後 mtime 與 sha 不變；`--apply` 兩次結果相同且有備份；Google News 解析成功（覆寫＋去重）與失敗（刪列）兩種；`label_source="rule"` 列永不降級	`raw/fn_per_item_pytest.txt`
UI-1	P0	本次執行	未執行（附原因）	**未執行原因**：本輪只擷取淺色全套＋S2 深色抽查，**深色全套未擷取**；且準則要求由非實作組員（石岱勳）勾核、文件審查（張宇宏）覆核，本輪檢核表「目視」欄為 Claude Code 預檢，不代替勾核者。S6 /bot 格依票 S-11 延後、S4「載入更多」因範圍刪減不適用。4.5 排 09-17。已擷取之 **84 列全部「通過」、0 列未通過**：依 8.4 母版逐格擷取 S1–S4 各狀態淺色 74 張＋S2 深色 7 張，皆符合 §8.7 文案且無 §8.6 違規；81 張截圖之 DOM 自動檢查：橫向溢出 0、每頁 h1 恰 1 個、<13 px 可見文字 0、導覽／按鈕內判定色 0、hover-only `title` 提示 0、console error 0、`news.google.com` 0	`docs/test/ui_checklist.csv`（未執行列 UI-1-086～UI-1-089）、`docs/test/screens/`（85 張）、`raw/ui_dom_audit_summary.txt`
UI-2	P0	本次執行	通過	360×780 開 /、`/r/{id}`、`/trending`、`/knowledge`：`scrollWidth` 皆 360（無橫向捲動）；結果頁動作列 `position: sticky`，頂端時 595–724 px 可見、捲到底時 443–572 px 仍在分頁列（top 723）之上且未遮住頁尾 disclaimer（403–419）；分頁列 `position: fixed` 貼齊視窗底並套 `env(safe-area-inset-bottom)`（模擬器 inset 為 0，瀏海機實機留待 UI-7）	`raw/ui2_ui4_checks.txt`；`screens/S2_ui2-top_360_light.png`、`S2_ui2-bottom_360_light.png`
UI-3	P1	本次執行	通過	① `src/**/*.jsx` 中引用判定色 token 的元件檔 **2 個**（≤3）：`components/Banner.jsx`、`components/InputCard.jsx`；燈號色集中於 `lib/verdict.js` 的 `toneOf()`。② 81 張截圖 DOM 檢查：導覽與動作按鈕內判定色 **0**；判定色只出現在燈號區、燈號點／判定字、未證實橫幅與 UNVERIFIABLE 黃框。觀察（非判定依據）：`backend_down` 橫幅（mockup brief §11 指定）與 inline 驗證紅字（spec §8.3 S1 指定）使用判定色 token → 登錄 DEF-08，待 6.4 界定	`raw/ui_dom_audit_summary.txt`；`screens/S1_backend_down_*`、`S1_validation_*`
UI-4	P0	本次執行	通過	全新設定檔、無 `fcc_theme`：系統淺色 → `data-theme=light`（body `rgb(255,255,255)`）；系統深色 → 自動 dark（`rgb(15,17,21)`）。按「切換深淺色」後主題翻轉並寫入 `fcc_theme`，`Page.reload` 後保持（light→dark→重整仍 dark；dark→light→重整仍 light）	`raw/ui2_ui4_checks.txt`；`screens/S1_ui4-system-light-toggled-reloaded_375_dark.png`、`S1_ui4-system-dark-toggled-reloaded_375_light.png`
UI-5	P1	報告後執行	報告後執行	無障礙基準票 P-18 排報告後；Lighthouse 與 axe 本機未安裝且本輪不新增安裝。鍵盤預檢達標（Tab 依序走完首頁各焦點、每站 `outline: solid 2px`；於送出鈕按 Enter 後 2.4 s 進入 `/r/{id}` 並顯示「快取命中・相同內容」）	`raw/ui5_keyboard_walkthrough.txt`
UI-6	P0	本次執行	未執行（附原因）	**未執行原因**：① 簡體 OpenCC `t2s` diff 因本機未安裝 OpenCC、本輪不新增安裝而未做；② `grep -P '[a-zA-Z]{4,}'` 準則須先界定允許清單（命中字多為 §8.7 文案原文），依 3.3 註 2 須經 6.4 確認；③ 逐 key 在介面出現未系統化比對，本輪截圖只涵蓋 S1–S4。靜態逐字比對達標：自 spec §8.7 解析 **139 個 key**，**135 個**與 `STRINGS` 逐字相同，其餘 4 個為表格寫法差異（`confidence_chip` 實作拆為 high／mid／low、`frame_yellow_no_source`、`knowledge_stats`、`nav_bot` 之儲存格含括號註解，文案本體一致），**缺漏 0**。英文字掃描命中：品牌 Threads、MyGoPen、Cofacts、LINE、Meta，以及 Cookie、token、THREADS_MODE、WEBP、App Review 與 `{summary}`、`{total}` 等占位符	`raw/ui6_i18n_static_check.txt`
UI-7	P1	報告後執行	報告後執行	需真手機與 Threads App 內建瀏覽器。本機已確認分享鈕 href 格式為 `https://www.threads.com/intent/post?text=…&url=…`（擱下開新分頁，未對 threads.com 發出請求）	`raw/ui_dom_audit_summary.txt`；`screens/S2_shared*`
UI-8	P0	本次執行	通過	① 10 筆真實結果頁：每頁「查核來源」皆帶「查核機構」小標，網域 mygopen.com×6、tfc-taiwan.org.tw×2、165.npa.gov.tw×1、cofacts.tw×1，**無 Tier 3 網域**；以 `tier_of(offline=True)` 複核得 Tier 1×9（cofacts 文章依 offline 設計回 3，其在清洗報告為「有回覆」，存入之 Tier 1 有效）。② S3 截圖 12 張 DOM 皆無 `news.google.com`。③「尚無查核機構證實」狀態：SAFE 黃＋橫幅 4 張（375／1280 × 淺／深）、紅＋橫幅 2 張，已入檢核表	`raw/ui8_source_tiers.txt`；`screens/S2_ui8-01…10_375_light.png`、`S2_unverified_safe_*`、`S3_*`
PF-1	P0	本次執行	未執行（附原因）	**未執行原因**：未命中 p50／p90 之準則方法為 `evaluate.py --timing` 150 筆，該旗標（票 B-23）未合入 HEAD，本輪未依準則方法量測。兩個子準則達標：**L1 hash**（32 筆已入庫原文，準則要求 10 筆；另 1 筆暖機不計）32／32 `cache_layer=hash`、0 次 AI，用戶端 p50 **213 ms**／p95 257 ms、後端 p50 156 ms（準則 <1.5 s）；**L2 向量**（13 筆命中）用戶端 p50 **3.06 s**／p95 4.72 s、後端 p50 3.00 s（準則 <4 s），亦達 spec §9「快取命中 p95 ≤6 s」。未命中僅 5 則補充樣本（用戶端 p50 8.84 s、p90 12.54 s、最大 14.73 s；當輪 14 次 AI 呼叫後端 p50 9.94 s、p90 12.46 s），**樣本數與方法皆不符準則**，不作判定依據	`raw/pf_requests_2026-09-16.csv`、`raw/pf_backend_structured_log_8030.txt`
PF-2	P0	本次執行	**未通過**	20 筆改寫句送 `/api/analyze/sync`：`cache_layer=vector` **13／20 = 65%**，低於準則 ≥70%（差 1 筆）。命中 13 筆之 `kb_id` 皆為對應原文、燈號皆為預期紅燈；離線以同一 embedding 對 102 筆 1536 維向量複算，命中預測與線上結果逐筆一致。**未命中 7 筆之最高相似度**：0.7314、0.7213、0.7175（**3 筆貼近門檻 0.75**）與 0.6894、0.6841、0.5989、0.5748（**4 筆為脫離上下文的短句詐騙話術片段**，語意本就分散）。**資料說明**：本組改寫句由 Claude Code 為本次量測撰寫，非票 O-11 所指之組員審定版本、未經逐筆確認；量測後未依相似度回頭修改句子（避免結果偏差）。**改善計畫**：① 依票 O-11 由姚睿產出、廖哲勛逐筆確認之改寫句題組後重測；② 重算 DEF-05 之 11 筆非 1536 維向量，使可參與語意命中之列由 102 筆回到 113 筆；③ 評估 `bge-m3` 等中文向量模型，或以獨立保留組（held-out set）重新校準門檻。**不以「為了通過而調低門檻」處理**——0.75 係實測校準值，調低會提高誤命中風險	`docs/test/pf2_paraphrases.csv`、`raw/pf_requests_2026-09-16.csv`（section=vector，含離線相似度欄）
PF-3a	P0	本次執行	通過（待補驗）	模擬模式 3 輪：文字 mention（m1）`handle_mention` 由取出到回覆寫入 `elapsed_ms` = **205／215／264 ms**（準則 ≤60 s）；固定文案 m2 26／22／25 ms、m3 27／27／24 ms；第 3 輪自 `--poll` 啟動到 3 則回覆全數寫入 1.33 s。待補驗：live 3 次（3.4 註 1，報告後）	`raw/pf3a_threads_sim_rounds.txt`、`raw/pf_backend_structured_log_8030.txt`
PF-3b	P1	報告後執行	報告後執行	需 Threads 實機 @ 回覆（含 Meta 索引延遲，不可控）；未達標只記錄不擋	—

ID	優先級	本次執行	結果	主要實測數據	證據檔案
PF-4	P1	報告後執行	報告後執行	本週僅 3 則模擬 mention fixture（需 10 則），且 `THREADS_MAX_REPLIES_PER_POLL` 預設 5 需先調整	—
PF-5	P1	本次執行	通過	① 150 筆評測總花費：以閘道計價（輸入 USD 1.5／百萬、輸出 USD 9／百萬 tokens）估算評測自身上限 **USD 0.943**（≤1.5），約 USD 0.0063／筆。② 每次未命中平均：本輪 15 次 AI 呼叫合計約 USD 0.0954、平均 **USD 0.0064／次**（≤0.02），與評測估算一致。交付缺口：`docs/test/cgu_usage.txt` 未建立，用量改以 `/me/usage` 快照與後端結構化 log 之 `usd` 欄記錄（另見 DEF-06：後端價目表低估約 50%，本節數字均已改以閘道計價換算）	`raw/qa1_cgu_usage.jsonl`、`raw/opuipf_cgu_usage_snapshots.jsonl`、functional_quality §4.5
PF-6	P1（可選）	報告後執行	報告後執行	可選比較組（`CGU_MODEL=gpt-5.4`），預算保留至報告後；不作通過條件	—
QA-1a	P0（閘門）	本次執行	通過	CGU `gpt-5.4-mini`（鍵 `['cgu']`）150 筆、有效 **150**／分析失敗 **0**；**FN = 0**（TP 100／FP 0／TN 50）；執行 03:14:22–03:29:32、約 15 分 10 秒；跑前後各查一次 `/me/usage`。**執行偏差**：依當次指示未加 `--seed-db`（避免與並行測試同時寫入知識庫，單寫者假設），該旗標只影響判對案例是否回寫知識庫，不影響預測與指標	`raw/qa1_evaluate_run.txt`、`code/backend/data/eval_binary.csv`、`eval_predictions.csv`
QA-1b	P1（量測）	本次執行	通過	accuracy **1.000**（目標 ≥0.93；95% CI 0.976–1.000）、FP **0**（目標 ≤8）、macro-F1 **1.000**、三類 P／R／F1 皆 1.000、信心中位數 0.97。與前一版並列：舊 `gpt-5-mini`（myai168，2026-06）accuracy 0.960、FN 0、FP 5；兩模型判定不同之 6 筆全為「舊錯新對」、0 筆「舊對新錯」，精確 McNemar 雙尾 **p = 0.031**。**限制**：150 筆題庫對新模型已飽和（滿分、CI 下限 0.976），無法再區分模型或設定，且題庫自 2026-06 起公開於 repo，無法排除被新模型見過 → 改善項：擴充題庫（例如 300 筆）並做信心校準後重測（CLAUDE.md §8 選項）	`raw/qa1_evaluate_run.txt`、`raw/qa1_old_vs_new_comparison.txt`、`code/backend/data/eval_report.csv`、`assets/confusion_matrix.png`
QA-2	P1	本次執行	**未通過**	① `--report-only` 重算一致：`eval_report.csv`、`eval_binary.csv`、`confusion_matrix.png` 重算前後 sha256 完全相同（達標）。② 報告仍缺 `provider`／`model`／`date`／`use_web_search` 欄、預測檔無 `elapsed_ms`、`evaluate.py` 無 `--timing`（票 B-23 未合入）→ **未達標**。③ 量測時 `eval_errors.csv` 因「0 筆錯誤即 return、不重寫」而殘留舊模型 6 筆、與新報告矛盾；**量測後已修正**：0 筆錯誤時輸出只有表頭的空檔（commit `b1fc5c3`）。②之欄位與 `--timing` 仍待 B-23，故本項仍判未通過	`raw/qa2_report_only.txt`、`raw/qa1_post_run_checks.txt`；`code/backend/scripts/evaluate.py`
QA-3	P0	本次執行	通過	量測時最新 run **35008720030**（HEAD `c114413`）之 `test`（pytest，19 s）與 `frontend`（npm ci、build、unit tests）兩個 job 皆 success；其後 `b1fc5c3`（35015937421）與宣告版本 `ad13f2f`（**35019722949**）亦皆 success；2026-09-14 重做起算 17 次 run 全數 success；`ci.yml` 未寫死測試數	`raw/qa3_gh_run_list.txt`；`.github/workflows/ci.yml`
QA-4	P1	報告後執行	報告後執行	文件同步票 B-25 排 09-24～09-25。預查結果：`.env.example` 對應項全數一致；`CLAUDE.md` 與 `README.md` 於勾核表 8 個指定項目**全部不符**（多 provider 描述、STT 設定鍵、`ENABLE_THREADS_BOT`、Threads 權限清單、`legacy/` 路徑、測試數「31」對實際 478、timeout「150 s」對 `config.py` 之 60、種子提交規則）；交付物 `docs/test/doc_review.md` 未建立	`raw/qa4_doc_review_grep.txt`、functional_quality §3.2
QA-5	P0	本次執行	通過	數字與資料實測一致：知識庫種子（commit `db8c62d`）218 筆、`verified` 128（MISINFO 75／SCAM 29／SAFE 24）、未證實 90；熱門牆 24 筆全數 verified、`news.google.com` **0**；清洗前後 236 → 218、63 → 24；第二次 apply 各規則影響 0、`label_source="rule"` 被降級 **0 筆**。**證據缺口（不改判定，已登錄）**：① dry-run 之逐筆 before→after 報告已被第二次 apply 覆寫，現存報告無法核對準則所寫之「Cofacts 33 筆」（現存為 23 篇：有回覆 19／無回覆 4）；② 無「隨機抽 10 筆降級列逐筆判斷」之書面紀錄，審閱文件記錄的是三項決定之整體核准與本地模型 300 筆第二意見；③ 審閱文件「113 筆帶向量」實際可參與語意命中者為 **102 筆**（DEF-05）	`raw/qa5_data_verification.txt`、`docs/test/clean_sources_review.md`、`code/backend/data/clean_sources_report.txt`、`check_after_d05.txt`

4.4 交付項目落差（供文件審查檢查完整性）：本輪之證據以原始紀錄檔形式交付於 `docs/test/results/`（兩份執行結果彙整檔與 `raw/` 40 個原始輸出）、`docs/test/screens/`（85 張截圖）與 `docs/test/ui_checklist.csv`（89 列）。4.4 所列之下列彙整檔**尚未建立**，其內容目前以括號內的原始檔替代：`op_log.md`（`operation_ui_performance_2026-09-16.md` §2 與 `raw/op*.txt`）、`eval_summary.md`（`functional_quality_2026-09-16.md` §4 與 `raw/qa1_*`）、`perf_log.csv`／`perf_summary.md`／`threads_latency.csv`（`raw/pf_requests_2026-09-16.csv`、`raw/pf_backend_structured_log_8030.txt`、`raw/pf3a_threads_sim_rounds.txt`）、`cgu_usage.txt`（`raw/qa1_cgu_usage.jsonl`、`raw/opuipf_cgu_usage_snapshots.jsonl`）、`ui6_copy_check.txt`（`raw/ui6_i18n_static_check.txt`）、`ci_run.png`（`raw/qa3_gh_run_list.txt`，CI 截圖未擷取）；`deploy_log.md` 待 OP-8 執行後產出，`doc_review.md` 待 QA-4（報告後）產出。是否要求補齊彙整檔由 6.4 審查決定。

6.3 缺陷與處置

嚴重度定義：高＝使 P0 準則無法達成或中斷 demo 主流程；中＝影響 P1 準則或有替代操作；低＝外觀、文案、舊資料等不影響本輪判定者。

編號	缺陷描述（發現來源）
DEF-01	送出查證後，結果頁偶發顯示「出了點問題 伺服器發生錯誤（500）」並停止輪詢（demo 影片錄製 take S7_t1，`docs/demo/footage_log.md` §4 發現 1）

編號	缺陷描述（發現來源）
DEF-02	v1.0 前的舊任務若 AI 失敗，`GET /api/result/{id}` 仍回 `ai_unavailable=false`，結果頁顯示黃框判定與「分享到 Threads」；舊 `tasks.parquet` 28 筆 completed 中 17 筆為 fallback
DEF-03	知識庫頁同一主張出現兩張卡且標籤不同：`484ad500`（TEXT，假訊息）與 `cac3a014`（URL，詐騙）、`2ac98c6c`（TEXT，假訊息）與 `95acaa79`（URL，詐騙）；四列皆 `verified=true`，疑
DEF-04	部分已證實列之「主張」其實是查核機構文章標題卻被標為假訊息：`5b12ca94`（「解析『馬鈴薯之亂』…」）、`c1ca6a6a`（「臉書詐騙廣告年賺5000億」）；另 `c792a37e`（「禧年探索資本…已補
DEF-05	128 筆已證實列中 **11 筆**向量維度為 768（5 筆）／3072（6 筆），`find_similar_by_vector` 只比對同維度，實際可參與語意命中者為 **102 筆**；`clean_sources_review.md` 與 2.2 受測範圍
DEF-06	後端 `MODEL_PRICING_PER_1M["gpt-5.4-mini"]`（USD 0.75／4.50 每百萬 tokens）為 CGU 閘道實際計價（USD 1.5／9）的一半，結構化 log 的 `usd` 欄低估約 50%（PF-5 成本核對）
DEF-07	每次寫入知識庫時 `app/services/pandas_store.py:281` 之 `pd.concat` 印出「空欄或全 NA 欄之 dtype」`FutureWarning`（全套 pytest 440 warnings 之大宗）

編號	缺陷描述（發現來源）
DEF-08	backend_down 橫幅（mockup brief §11 指定 yellow／yellow-soft）與首頁 inline 驗證錯誤紅字（spec §8.3 S1 指定紅字）使用判定色 token，與 spec §8.1「紅黃綠只用於判定」之字

殘餘風險：

1. DEF-01 之鎖僅在單一行程內有效，跨行程同時寫入仍依單寫者假設以排程避免（4.3 第 4 列）。
2. FN-4 之三項未實作行為屬實機模式：在取得 Threads 實機 token 前不影響 demo，但 live 上線後可能造成 429 後持續重試、未知 4xx 被當成可讀取失敗、以及 container 未 `FINISHED` 即 publish 而漏發；此三者為報告後 live 測試（OP-5、PF-3b）之前置條件。
3. PF-2 未通過與 DEF-05 相關但不等同：即使 11 筆向量修復，仍有 4 筆短句話術片段之相似度 ≤0.69，需靠題組審定與模型／門檻評估處理。

6.4 審查結論與簽核

結論（彙整，待審查者裁定）：本輪於 2026-09-16 對 46 個測試項目中之 34 項（第 3 節指定本次執行者）實際執行，完成 24 項通過、2 項通過（待補驗）、3 項未通過、4 項未執行，其餘 13 項依範圍列為報告後執行。已驗證之主要結果為：CGU `gpt-5.4-mini` 150 筆評測 **accuracy 1.000、macro-F1 1.000、FN 0、FP 0**（有效預測 150／150，對照前一版 `gpt-5-mini` 0.960／FN 0／FP 5，精確 McNemar p = 0.031），**絕對閘門 QA-1a 達成**；後端 `pytest tests` **478 passed**、CI（`test`＋`frontend`）於宣告版本 `ad13f2f` 綠燈（run 35019722949）；三層快取 L1 命中用戶端 p50 **213 ms**、L2 向量命中 p50 **3.06 s**；Threads 模擬模式閉環回覆 **205–264 ms**；來源紀律與清洗後資料（知識庫 218 筆／已證實 128 筆、熱門牆 24 筆、Google News 轉址 0 筆）逐項核對相符；84 列介面檢核格全部符合且無 §8.6 違規。**未達 4.2 通過準則**：P0 通過 23／30——**FN-4**（Threads 429 backoff、未知 4xx 分流、container 兩段式發佈三項行為未實作，票 T-12／T-13，目標 09-24～09-30）與 **PF-2**（向量命中率 65% < 70%，改善計畫見 6.2）未通過，**OP-1、UI-1、UI-6、PF-1** 未執行（需全新 clone、非實作組員勾核、OpenCC 與允許清單界定、`--timing` 前置票），**OP-8** 由本次執行改列報告後；本次執行之 P1 通過率 66.7%（2／3，不含記錄性項目）亦未達 ≥80%。缺陷方面 DEF-01、DEF-02 已修正並通過回歸，DEF-03～DEF-07 排報告後處理，DEF-08 為規格文字衝突需本次審查裁定。建議之處置為「有條件通過」：以 QA-1a 閘門達成與回歸全綠為基礎，允許進度報告與 demo 影片引用上列已驗證數字，但報告中須明列 FN-4、PF-2 未達標與四項未執行項目及其時程；程式凍結與 tag `v0.3.0-demo` 於 09-20 前視 OP-1、OP-8、UI-1、UI-6、PF-1 補齊情形決定。最終結論由下表審查者裁定。

審查項目	結論
全部 P0 項目是否通過	**否**：P0 通過 23／30（含通過（待補驗）2）；未通過 2（FN-4、PF-2）、未執行 4（OP-1、UI-1、UI-6、PF-1）、報告後執行 1（OP-8，原列本次執行）
本次執行之 P1 項目通過率是否 ≥80%（依 4.2 計算）	**否**：66.7%（分母 3＝UI-3、PF-5、QA-2，已扣除記錄性項目 QA-1b；通過 UI-3、PF-5，未通過 QA-2）
QA-1a FN=0 閘門是否達成	**是**：FN = 0、有效預測 150／150（`errored` 0）、FP 0、accuracy 1.000；偏差：未加 `--seed-db`（不影響預測與指標），請審查者確認接受
準則修訂（4.2）與 UI-6 範圍界定（3.3 註 2）是否同意	待審查裁定。待確認事項：① 4.2 已登錄之 OP-1、OP-9、FN-1、QA-1b 四項修訂；② UI-6 之 `[a-zA-Z]{4,}` 允許清單（品牌 Threads／MyGoPen／Cofacts／LINE／Meta 與 Cookie、token、THREADS_MODE、WEBP、App Review、{占位符}）；③ spec §10.2 FN-1 原文回寫 B-03、B-22 兩項例外；④ DEF-08 之 §8.1 顏色紀律例外
部分延後準則與報告後執行項目之目標日期（4.5）是否同意	待審查裁定。含本輪範圍變更：OP-8 由 09-18 移至報告後；OP-3、PF-3a 之待補驗項（S-11、live 量測）；FN-4 依 T-12／T-13 排 09-24～09-30；PF-2 重測排 10-05 前
未通過項目與缺陷（6.3）之處置是否完成	**部分**：DEF-01、DEF-02 已修正且回歸通過；DEF-03～DEF-07 排報告後；DEF-08 待本次裁定；FN-4、PF-2 之修正與重測均排報告後，本輪未完成
整體結論（通過／有條件通過／不通過）	待審查裁定（彙整建議：**有條件通過**，條件為上列結論段所述之報告揭露與補齊時程）
審查意見	待審查者填寫

角色	姓名	日期	簽名
測試負責人	廖晢勛		
文件審查	張宇宏		
審查者（指導教授）	黃崇源		

6.5 第二輪重測紀錄（2026-09-19～09-20）

依 4.3「中止與再繼續」，第一輪未通過與未執行之項目於缺陷修正後重測。第一輪結果（6.1～6.3）保留原樣，本節只記重測。判定由測試負責人確認後生效；審查者之裁定仍在 6.4。

受測系統的變更：2026-09-19 起正式環境改為雲端部署——前端 Vercel（`https://fakenewsverify.vercel.app`）、後端 Render 免費方案（`https://fakenewsverify-api.onrender.com`）、資料庫 Supabase Postgres + pgvector、AI 仍為學校 CGU AIR 閘道 `gpt-5.4-mini`；並加上每日 AI 次數上限（300）、每 IP 限速與請求大小上限。第一輪是在負責人電腦（本機檔案儲存）上執行；本節各項註明執行位置。

項目	優先	第一輪	修正內容	重測方式與結果	重測判定
FN-4	P0	未通過	票 T-12／T-13（commit `8074c7c`）：① HTTP 429 → `backoff_until = now + min(60, 輪詢間隔 × 2^n)` 分鐘、成功後歸零，退避期間整輪跳過；② 未知 4xx → 標 failed、不回覆、不重試（spec §7.5 依 §7.10 修訂）；③ 建立 container 後輪詢狀態，`FINISHED` 才 publish，`ERROR` 重建一次	本機、離線（模擬用戶端與 mock `requests`）：Threads 相關測試新增 135 個，10 項子準則皆有測試且通過；後端全套 **700 passed／24 skipped**。限制：回應格式依 spec §7.6／§7.10，尚未對真的 Threads API 驗證（票 T-17，報告後）	**通過**
PF-1	P0	未執行	票 B-23（commit `ce1dd11`）：`evaluate.py --timing`	本機，2026-09-20 03:07–03:20，`evaluate.py --timing --delay 0`、web_search 關、150 筆皆非 fallback：未命中 **p50 4.86 s**（準則 ≤15 s）、**p90 6.64 s**（準則 <20 s）。L1／L2 子準則沿用第一輪量測（L1 p50 213 ms <1.5 s；L2 p50 3.06 s <4 s）。結果檔 commit `49be377`	**通過**

項目	優先	第一輪	修正內容	重測方式與結果	重測判定
QA-2	P1	未通過	同上（B-23）：預測檔與報告加 `provider`／`model`／`date`／`use_web_search`／`elapsed_ms`	① `--report-only` 重算前後 `eval_report.csv`、`eval_binary.csv`、`eval_errors.csv`、`confusion_matrix.png` 之 sha256 完全相同；② 報告每列帶 `cgu`／`gpt-5.4-mini`／`2026-09-20`／`False` 與 `elapsed_ms_p50`／`p90`／`n`，預測檔逐筆有 `elapsed_ms`；③ 0 筆錯誤時 `eval_errors.csv` 只有表頭（第一輪後已修正），`error_type` 欄由單元測試 `test_evaluate_timing.py` 確認	**通過**
QA-1a／QA-1b	P0／P1	通過	—（同一次重跑的附帶結果）	150 筆 accuracy **1.000**、FN **0**、FP 0、有效預測 150／150	維持通過
OP-1	P0	未執行	`start.bat` 省去重複的 pip 同步（commit `a161351`）；啟動腳本改用 `python -m pip`／`uvicorn`，專案資料夾搬移後仍可用	本機，全新 `git clone --depth 1` 後執行 `start.bat`：第 1 次（修正前）後端 300 s、前端 309 s，**未達** <5 分鐘；修正後第 3 次後端與前端皆 **247 s**（第 2 次因量測方法錯誤未取得後端時間，前端 238 s）。`.env` 自動建立且 `ADMIN_TOKEN` 為 32 字；`POST /api/threads/poll` 回 200 `threads_disabled`；`/api/knowledge/stats.total = 128`（≥125）；前端 5173 回 200。**待補驗**：`/health` 的 `ai_available=true` 來自範本檔的佔位金鑰，真實金鑰須由負責人自行填入後再確認一次	**通過（待補驗）**
OP-8	P0	報告後執行	改為雲端部署（不再使用 quick tunnel）；`vercel.json` 的 `/api` 代理指向 Render（commit `21cc3d7`）	正式站：`https://fakenewsverify.vercel.app/api/health` 回 200，內容含 `"storage_backend":"supabase"`、`"ai_available":true`；桌機瀏覽器開 `/r/{id}` 顯示結果；新訊息 AI 判定 9–27 s、改寫句命中向量層約 3 s 且不耗每日額度；**手機**：負責人 2026-09-20 14:51 以 iPhone、行動網路 4G、App 內建瀏覽器開啟 `/r/71c8d80e-…`，顯示紅燈「假訊息」、「尚無查核機構證實」橫幅、摘要與分享按鈕（截圖存負責人處）。同日 14:41 第一次開啟時後端正在休眠，頁面顯示「連不上伺服器」→ 登錄為 DEF-09 並修正後再測	**通過**
PF-2	P0	未通過	DEF-05 已修正（commit `3ce32bb`）：13 筆非 1536 維向量以現行模型重算，本機與 Supabase 同步；可參與語意比對的已證實列 102 → 113	離線複查第一輪的 20 句：原文向量**全部本來就是 1536 維**，未命中的 7 句是相似度確實低於 0.75（0.7314、0.7213、0.7175 與 4 句脫離上下文的話術片段），所以 DEF-05 的修正不會改變該題組的 65%。未以調低門檻或回頭修改句子處理。待組員（姚睿）依票 O-11 產出、負責人逐筆確認之題組後重測	**仍未通過**
UI-1、UI-6	P0	未執行	—	尚未重測：UI-1 需補深色全套截圖並由非實作組員（石岱勳）勾核、張宇宏覆核；UI-6 之英文字允許清單須經 6.4 裁定	仍未執行

重測後的統計（待測試負責人確認）

指標	第一輪（09-16）	重測後（09-20）
P0 通過數／P0 項目數	23／30	**27／30**（新增 FN-4、PF-1、OP-8、OP-1（待補驗））；未通過 1（PF-2）、未執行 2（UI-1、UI-6）
本次執行之 P1 通過率（不含記錄性項目）	2／3 = 66.7%	**3／3 = 100%**（QA-2 通過），達 ≥80%
QA-1a 絕對閘門（FN=0）	達成	達成（重跑再次確認）
回歸	後端 478、前端 375 全數通過	後端 **700 passed／24 skipped**（24 項為需要真 Postgres 的契約測試，另以 `RUN_PG_TESTS=1` 對 Supabase 執行 24 passed）、前端單元測試 380 passed、lint 與 build 成功；CI 於 commit `49be377`（含 T-12／T-13 與評測結果）`test`、`frontend` 兩個 job 皆 success

重測後是否達到 4.2 之通過準則：仍未達成——「全部 P0 通過」尚差 PF-2、UI-1、UI-6 三項；其餘三個條件（P1 ≥80%、QA-1a 閘門、回歸）皆達成。彙整建議維持「有條件通過」，條件縮小為：PF-2 以組員題組重測、UI-1 與 UI-6 補執行、OP-1 的待補驗項目補齊。

新增缺陷 DEF-09（已修正）：後端（Render 免費方案）閒置 15 分鐘後休眠、喚醒約 1 分鐘，而結果頁第一個請求 15 秒逾時就顯示「連不上伺服器」；原本用來防止休眠的 GitHub Actions 排程實際每 2–5 小時才執行一次。修正（commit `f25e08b`）：結果頁在 90 秒時限內持續重試並維持載入畫面、後端恢復後自動重新載入、送出查證的逾時由 30 秒改為 75 秒；前端單元測試 385 passed。防止休眠的可靠排程另案處理。

缺陷狀態更新：DEF-05 已修正並重測（正式站以改寫句命中原為 768 維的列 `cdb968b1`）；其餘 DEF-03、DEF-04、DEF-06～DEF-08 維持 6.3 所列狀態。

6.6 PF-2 第三輪重測：組員審定題組（2026-09-21）

票 O-11 要求 PF-2 的改寫句由組員出題，而非由 AI 助理撰寫。姚睿依 `docs/test/PF-2_出題說明.md` 於 `docs/test/pf2_worksheet.csv` 填入 20 句改寫句 （commit `9e8970b`），經測試負責人確認後執行本次重測。

執行環境：本機後端 `127.0.0.1:8030`，`STORAGE_BACKEND=local`、`USE_WEB_SEARCH=false`、 `ENABLE_SCHEDULER=false`、`THREADS_MODE=off`，`SIMILARITY_THRESHOLD` 維持 0.75（未調整）。 依 4.3 於執行前備份 `knowledge_base.parquet`、`tasks.parquet`、`factcheck.db`， 量測後還原並確認 SHA-256 與測試前相同。執行工具 `code/backend/scripts/run_pf2.py`， 逐句結果 `docs/test/results/pf2_rerun_2026-09-21.csv`，延遲另寫入 `docs/test/perf_log.csv`。 本次耗用 6 次 AI 呼叫。

結果

命中層	句數	延遲中位數
`vector`（語意相似）	10	1,944 ms
`hash`（相同內容）	4	256 ms
未命中，交由 AI 判讀	6	6,675 ms

語意快取命中率 **10／20 = 50%**，未達 70% 之準則，**PF-2 仍未通過** （第一輪 13／20 = 65%，本輪題組不同，兩者不可直接比較）。

結果的兩點說明

1. 第 9、10、15、18 句的改寫與原文逐字相同，因此命中的是 hash 層而非語意層。 出題說明要求「不要照抄原文的句子」，這四句未符合；依測試負責人裁示不重新出題， 照原樣執行並據實記錄。若僅計入其餘 16 句，語意命中為 **10／16 = 62.5%**，同樣未達準則。
2. 未命中的 6 句（第 2、3、4、5、11、12）字面相似度介於 0.10～0.57，是本組改寫幅度最大的幾句， 多為改寫成新聞體或大幅縮減資訊（例如「『又要限電了』」改為「台電說有限電計畫」、 「黃仁勳～輝達創辦人～站在世界舞台中央，身價一路飆升」改為「輝達創辦人，身價飆升」）。 相似度確實低於門檻，並非向量資料錯誤。

未採取的處置：未調低 0.75 的相似度門檻（該值為實測校準所得，調低會提高誤命中）， 亦未在執行後修改任何句子。

逐句相似度診斷（`scripts/pf2_similarity.py`，唯讀；與 `find_similar_by_vector` 同一算法： 只比對 `verified=True` 且維度相符的 113 筆、cosine similarity 取最高分。不呼叫判讀模型、 不寫入知識庫、不累加命中次數，可重複執行而不影響量測結果）：

句	最高相似度	對門檻 0.75	說明
9、10、15、18	1.0000	高於	與原文逐字相同。相似度滿分，但系統先在 hash 層命中，不會走到語意層，因此不計入本測試

句	最高相似度	對門檻 0.75	說明
13、14、16、17、19	0.9545–0.9869	高於	只更動一兩個字
6、8	0.8770、0.8704	高於	保留主角、事件與關鍵詞，只換句型——語意層正常運作的典型案例
20、1、7	0.8310、0.7663、0.7734	高於	改寫幅度較大但關鍵資訊保留
4	0.6995	低 0.050	改為新聞體，主詞與語氣改變
2、12	0.6759	低 0.074	前者改為新聞體；後者刪去「黃仁勳」「站在世界舞台中央」等關鍵詞
5	0.6292	低 0.121	改為新聞體，且刪去「李在明政府」「選舉舞弊」
11	0.5668	低 0.183	「『又要限電了』」改為「台電說有限電計畫」，由口語驚嘆改為中性政策陳述
3	0.5242	低 0.226	刪去「韓國」「地方選舉」「十點」，另加入原文沒有的「選務機關緊急調度查明」

命中與未命中的分界清楚：**保留主角、地點、數字與事件、只更換句型者全部高於門檻； 刪去關鍵詞、改為新聞體或加入原文沒有的內容者全部低於門檻。** 未命中的六句中最接近的也差 0.050，並非臨界值的抖動。

後續：PF-2 之未通過狀態維持。診斷顯示問題不在向量資料或門檻設定，而在兩處： 一是題組中有 4 句未依出題說明改寫（逐字相同），這 4 句無論系統表現如何都不會計入語意層； 二是語意層對「大幅刪減關鍵詞」與「改寫為新聞體」的耐受度不足。 處置方向為擴充知識庫中已證實列的涵蓋面，並在語意層之外補強同義詞與縮寫處理； 不以調整門檻的方式達成。P0 通過數維持 27／30。

6.7 AI 模型下架後的重測（2026-09-30）

新增缺陷 DEF-10（已修正）：以真的閘道試跑每週新查核自動評測（規格 v1.6 FR-24）時， 每一次判讀都回 HTTP 404「Model 'gpt-5.4-mini' is not available on this gateway」（`model_not_found`）； 閘道的模型清單（`GET {CGU_BASE_URL}/models`）已經沒有該模型。影響：正式站所有沒命中快取的查證都顯示 「AI 分析暫時無法使用」，快取命中不受影響；`/api/health` 的 `ai_available` 只代表金鑰有設，仍為 `true`， 所以沒有被發現，開始時間不明。原因：學校閘道無預警下架模型，而系統只設定一個模型、也沒有檢查模型是否還在。 修正（票 B-37）：比較兩個候選模型後改用 `gpt-5.6-luna`；閘道回 404 時自動改用備援 `gpt-6-luna`； 查核結論同步（FR-23，每天兩次）每次檢查模型清單，設定的模型不見時 GitHub Actions 變紅並寄信。 選型紀錄 `docs/test/results/model_switch_2026-09-30.md`。

重測項目（本機，`CGU_MODEL=gpt-5.6-luna`、`CGU_REASONING_EFFORT=medium`、`USE_WEB_SEARCH=false`； `scripts/evaluate.py --timing --delay 0`，未加 `--seed-db`；舊結果封存於 `code/backend/data/eval_archive_gpt54mini_2026-09/`）：

項目	準則	結果	判定
QA-1a	FN = 0（絕對條件）	FN 0（有效預測 150／150）	**通過**
QA-1b	accuracy ≥ 93%、FP ≤ 8（記錄性）	accuracy 96.7%（95% CI 92.4%–98.6%）、macro-F1 0.967、FP 5	達成
PF-1	未命中 p50 ≤ 15 s、p90 < 20 s	p50 5.87 s、p90 8.31 s	**通過**
PF-5	成本記錄	每次判讀約 USD 0.0014（`/me/usage` 實扣；舊模型約 0.0064）	記錄

說明：

1. 5 筆偽陽性全是 SAFE 題中的官方公告（綜所稅申報期間、基本工資審議、故宮開放時間、高溫假指引、節能補助）， 被判為 MISINFO；同日並行的比較執行中同一模型只錯 2 筆，此類題目的結果會浮動。
2. 與 2026-09-16 的 `gpt-5.4-mini`（150／150）逐題比較：5 筆由對變錯、0 筆由錯變對，McNemar 精確檢定 p = 0.0625。
3. 選型另以最近 7 天發布的 41 則查核結論比較（模型沒看過的題目）：`gpt-5.6-luna` 偽陰性 5 則，`gpt-6-luna` 10 則； 因偽陰性是唯一的絕對禁止項，選前者。
4. 後端 `pytest tests` 810 passed（另 31 項 PostgreSQL 契約測試以 `RUN_PG_TESTS=1` 對 Supabase 全數通過）； 前端單元測試 409 passed。

正式站確認：2026-09-30 22:22 推送（commit `533aeaf`），CI 通過，Render 約 2 分鐘後換上新版（`/api/admin/factcheck-sync` 由 404 變為 401）。以一則沒查過的新訊息（冒充市立圖書館催繳滯納金）呼叫 `POST /api/analyze/sync`：HTTP 200、25.6 s，判為 SCAM（紅燈「詐騙警告」、信心中、依據 `pattern`），`ai_unavailable=false`、`cached=false`；結果頁 `/r/8ea6031e-b6f6-4347-b219-2a4382786ad2`。DEF-10 關閉。

6.8 判定校準後的重測（2026-10-12）

起因：第一次每週新查核自動評測（M5，2026-10-05）的覆核發現兩個問題（`docs/test/results/weekly/review_2026-10-05.md`）：

- AI 常把真的內容判成假：Cofacts「不是謠言」的安全題 991 題中 679 題被判有風險，網站上就是紅燈「假訊息」；
- MyGoPen 的主張只取到標題第一個問號前的主題。

修正：

- 系統提示加判定校準 5 條（票 B-40）；
- 查核標題的主張改取結論以外的所有問句段落（票 B-41）。

結果（細節在 `docs/test/results/prompt_calibration_2026-10-12.md`）：

1. 306 題開發組（每週評測的歷史抽樣與本週偽陰性複驗）：風險題漏判 16 → 13、安全題誤報 94 → 75。 第 1 版規則讓漏判增加 14 題，所以不採用。
2. QA-1b（150 題）：兩次都是 accuracy 100%、FN 0、FP 0。2026-09-30 校準前是 96.7%、FP 5，5 題全是官方公告。 未命中延遲 p50 4.75 s、p90 6.07 s。
3. 限制：這組題庫已公開也已飽和，而校準第 5 條正是針對它已知的錯誤型態寫的，所以 100% 偏樂觀。 以每週評測為準：2026-10-12 的每週評測已在新規則上執行（`docs/test/results/weekly/weekly_eval_2026-10-12.md`），安全題誤判率 68.5% → 55.0%， 歷史風險題漏判率 10.4% → 12.8%（兩週抽樣不同），取捨待負責人決定。
4. 後端 `pytest tests` 843 passed（另 34 項 PostgreSQL 契約測試需 `RUN_PG_TESTS=1`）。

6.9 AI 可回「無法查證」後的重測（2026-10-15）

起因：6.8 的判定校準 v2 上線後，2026-10-12 每週評測的歷史風險題漏判率 10.4% → 12.8%。負責人 2026-10-15 選擇讓 AI 查不到又沒有明顯跡象時回「無法查證」（票 B-43）。

結果（細節見 `docs/test/results/prompt_calibration_2026-10-12.md` 第 6 節）：

1. 306 題開發組：風險題漏判 16 → 2；紅燈抓到的謠言 89.7% → 85.1%，其餘變黃燈「無法查證」；安全題誤報 94 → 69。

2. QA-1b（150 題）：風險題 100 題全判對，FN 0、FP 0；安全題 50 題中 32 題判「無法查證」。三類 accuracy 78.7%（無法查證算錯）、作答率 78.7%、作答的全對；未命中延遲 p50 4.82 s、p90 6.30 s。QA-1b 準則（accuracy ≥ 93%）以嚴格算法未達成。改以「FN 0、FP 0、作答的全對」記錄，是否修訂準則待審查裁定。
3. 後端 `pytest tests` 851 passed；前端單元測試 409 passed、lint 與 build 通過。

6.10 第二次簡報輪次（2026-10-26～11-03）

本節記錄 3.6 各項在第二次簡報輪次的結果。**結論：本輪未達 4.2 的通過條件；學校 2026-11-03 起不再提供 embedding，語意比對停用，見 DEF-13。** 用語同 4.2；未執行的項目附原因，執行後回填。每一筆數字都出自所列的證據檔案。

6.10.1 執行摘要

項目	結果
執行期間	2026-10-26～11-03
受測版本	`main` 分支 commit `02061cc` 起，2026-11-03 為 `8b8adcb`；後端 Render 自動部署，前端 Vercel 自動部署
P0（4 項）	通過 3（FN-20、QA-6、QA-7）；未執行 1（OP-10，受 DEF-13 影響）
P1（12 項）	通過 8（OP-12、FN-15～FN-19、FN-21、FN-22）；未通過 2（OP-11、PF-7）；未執行 2（UX-1、UX-2）。未執行者計為未通過，通過率 66.7%
第一輪仍未結	PF-2 未通過（50%，6.6）；UI-1、UI-6 未執行（6.5），依原準則追蹤
整體判定（4.2 第二輪）	**未達成**：P0 未全數通過（差 OP-10）；P1 通過率 66.7%，未達 80%；也沒有趕上 10-31 的時點。回歸條件達成

6.10.2 各項結果

ID	結果	主要實測數據	證據檔案
OP-10	未執行（附原因）	10-27～10-28 的拍攝沒有進行，後來改由負責人於簡報前執行。2026-11-03 查明語意比對停用（DEF-13），而且查核中心的豬肉報告不在知識庫，現在做不到「查核來源（Tier 1）」這條準則，所以先不執行。機器人本身的雲端回覆 2026-10-01 起有實機紀錄	`docs/test/threads_live_log.md`；`docs/test/results/embedding_closed_2026-11-03.md`
OP-11	**未通過**	`factcheck-sync` 最近 30 次成功 25 次（83.3%，未達 90%）。最後一次成功 10-31 05:26 UTC，之後連續失敗 5 次（DEF-13）；2026-10-26 查的那一輪是 30／30。知識庫筆數 18,604（09-30）→ 18,806（11-03），沒有減少	GitHub Actions `factcheck-sync` 執行紀錄；`GET /api/knowledge/stats`；`docs/test/results/embedding_closed_2026-11-03.md`
OP-12	通過	10-04 起五次週日排程都完成並 commit 報告（GitHub 排程比設定的 21:17 晚 3～5 小時開始）；執行後本週剩餘：10-18 USD 6.18（實扣 USD 2.97）、10-25 USD 7.01（實扣 USD 2.99）、11-01 USD 5.31，皆 ≥ 3。11-01 那次闡道不穩，超過 150 分鐘提前結束，歷史抽樣 660 題有 323 題 AI 服務不可用	`docs/test/results/weekly/weekly_eval_2026-10-05.md`、`-10-12.md`、`-10-19.md`、`-10-26.md`、`-11-02.md`
FN-15	通過	`test_factcheck_supersede.py` 全過	`pytest tests -q`：933 passed、34 skipped（2026-11-03，`docs/test/results/regression_2026-11-03.txt`）
FN-16	通過	`test_hot_claims.py`、`test_knowledge_api.py` 全過	同上
FN-17	通過	`test_evidence.py` 全過（含 `ai_unverifiable`、`conflict`）	同上
FN-18	通過	`test_factcheck_sync.py` 全過	同上
FN-19	通過	`test_weekly_eval.py` 全過	同上
FN-20	通過	後端契約、證據信心與評測相關測試全過；前端 `resultState.test.js` 全過；正式站「無法查證」範例結果頁為一般結果頁＋黃燈	同上；`npm run test:unit` 409 pass
FN-21	通過	兩個新測試通過；2026-10-26 部署後，正式站 10-18 產生的結果頁 `/r/981b5722-…` 分類由「其他」變為「已查核假訊息」	同上；`GET /api/result/981b5722-c381-44db-ad3d-bc8b227476d1`
FN-22	通過	`test_threads_cloud.py`、`test_threads_publish.py`、`test_threads_token.py` 全過	同上
PF-7	**未通過**	已證實列命中 10 次：p50 1.87 s、最長 2.83 s（達標）；未證實列命中 3 次：p50 14.28 s、最長 16.03 s（未達 5 s）→ DEF-11	`docs/test/results/pf7_latency_2026-10-26.txt`
QA-6	通過	歷史風險題被判 SAFE：校準前 10.4%（206／1,988）→ v2 12.8%（256／1,997）→ **v4 2.0%（40／1,996）、2.1%（41／1,985）、4.7%（16／337，闡道不穩）**，都低於校準前，達準則。記錄項見下表	`docs/test/results/weekly/weekly_eval_2026-10-05.md`、`-10-12.md`、`-10-19.md`、`-10-26.md`、`-11-02.md`
QA-7	通過	2026-11-03 重跑：後端 `pytest tests -q` 933 passed（另 34 項 skipped；PostgreSQL 契約測試需 `RUN_PG_TESTS=1`）；前端 `npm run test:unit` 409 pass、`npm run lint` 無錯誤、`npm run build` 成功；正式站 commit `8b8adcb` 的 `ci` 兩個 job（test、frontend）皆綠。這些測試是離線的，不會發現 DEF-13 這類外部服務關閉	`docs/test/results/regression_2026-11-03.txt`；GitHub Actions `ci`
UX-1	未執行（附原因）	排定 10-27～10-29，沒有進行；記錄表與問卷目前只有空白表格，沒有受測者資料	`docs/test/第三方實測_記錄表.csv`、`第三方實測_問卷.csv`
UX-2	未執行（附原因）	情境劇的兩則訊息還沒在正式站完成兩次查證：語意比對停用時查不到查核來源（DEF-13），而查證結果會快取，所以先不貼原文。2026-11-03 負責人用改寫的短句查豬肉那則：假訊息、信心低、尚無查核機構證實（不是原文，不列入判定）。影片的煮蛋網站段 2026-11-03 改貼知識庫裡查核中心的謠言原文（3,075 字；hash 層命中：假訊息、信心高、附查核中心報告，AI 花費 0），不是情境劇原文 1；「查不到的時候」為正式站實錄（快取命中）；Threads 段為標明的示意畫面。2026-10-26 舊版訊息的紀錄留存	`docs/test/results/embedding_closed_2026-11-03.md`；`docs/test/results/ux2_scenario_messages_2026-10-26.txt`

QA-6 記錄項：每週新查核自動評測五週對照（「本週新查核」為當週新發布的查核結論，模型推出後才出現；「歷史抽樣」取自知識庫，可能出現在模型訓練資料中）

指標	10-05（校準前）	10-12（v2）	10-19（v4）	10-26（v4）	11-02（v4，闡道不穩）
歷史風險題被判 SAFE（漏判）	10.4%（206／1,988）	12.8%（256／1,997）	**2.0%（40／1,996）**	**2.1%（41／1,985）**	4.7%（16／337）
歷史風險題判紅燈	89.6%	87.2%	83.5%	83.4%	88.4%
歷史風險題判無法查證	0%	0%	14.5%（289／1,996）	14.5%（288／1,985）	6.8%（23／337）
歷史安全題被判紅燈（誤報）	68.5%（679／991）	55.0%（393／714）	54.0%（309／572）	51.9%（315／607）	本次沒有安全題
本週新查核的漏判	6／41	4／24	1／29	1／32	0／9
本週新查核判無法查證	0	0	9／29	6／32	1／9
本週新查核風險判定一致率（95% 信賴區間）	84.1%（70.6～92.1%）	76.9%（58.0～89.0%）	65.5%（47.3～80.1%）	71.9%（54.6～84.4%）	88.9%（56.5～98.0%）

解讀：v4 讓「查不到」的內容改回答「無法查證」（黃燈），漏判大幅下降，代價是一部分謠言從紅燈變成黃燈，所以「一致率」（無法查證算不一致）下降。安全題的誤報仍超過一半，列為研究限制與下一步（降低誤報）。本週新查核每週只有 9～41 題，信賴區間很寬，只看趨勢。11-02 那週闡道不穩：本週新查核 20 題只有 9 題有效，歷史抽樣 660 題只有 337 題有效，而且沒有抽到安全題，不能和前幾週直接比較。

6.10.3 缺陷與處置

編號	發現日	說明	影響	處置
DEF-13	2026-11-03	**語意比對停用，未修復。** 學校 CGU AIR 閘道因資安考量關閉 API 與外部模型：`POST /v1/embeddings` 回 404「目前的上游模式（codex）不支援 /v1/embeddings」，模型清單已沒有 embedding 模型，公告沒有恢復日期。判讀 `gpt-5.6-luna` 仍可用，所以 `/api/health` 的 `ai_available` 還是 true，只有 `embedding.ok` 是 false	語意快取、證據信心、相似查證都停用：和知識庫文字不完全相同的謠言查不到查核來源，只有 AI 判讀。`factcheck-sync` 10-31 起連續失敗，新查核進不了知識庫（查核中心的豬肉報告不在知識庫）。OP-10、OP-11、UX-2 與情境劇 Threads 段受影響；煮蛋網站段只能貼知識庫原文才查得到來源	不是本系統的程式錯誤，但使用者看到的結果受影響。2026-11-03 負責人決定：先在本文件與簡報說明，再開發不靠 embedding 的備援比對，原有 embedding 程式保留（票 B-48、B-49，簡報後做）。完成後重測 OP-10、OP-11、UX-2 並回填。證據：`docs/test/results/embedding_closed_2026-11-03.md`
DEF-11	2026-10-26	命中「未證實」知識庫列（例如 AI 判無法查證的內容）時，正式站要 13～16 秒才出結果；命中已證實列只要約 2 秒。原因：查核結果回補（FR-20）在 Postgres 版沒有讀出已存的向量，每次都重新呼叫 embedding	PF-7 未通過；使用者重查同一則「無法查證」訊息時等待較久（結果正確）	已開票：改用資料庫中已存的向量（不再呼叫 embedding）；修正後重測 PF-7
DEF-12	2026-10-18	結果頁燈號下方的分類，命中查核機構資料時一律顯示「其他」：程式寫入的中文分類（「已查核假訊息」「已查核詐騙」）不在英文對照表裡	正式知識庫絕大多數列受影響；製作專題海報時發現	已修正（票 B-44，2026-10-26 上線）：中文分類原樣顯示，舊結果頁讀取時重算；FN-21 通過

6.10.4 審查與簽核

角色	姓名	審查日期	結論	簽名
測試負責人	廖晢勛			
文件審查	張宇宏			
指導教授	黃崇源			

附錄 A 需求追溯矩陣

spec v1.6 §4 每一條功能需求，對應到第 3 節的測試項目與最新結果（2026-10-26）。「—」表示該需求不在測試範圍（P2）。

FR	需求	優先級	測試項目	最新結果
FR-01	文字查證	P0	FN-1、FN-11、FN-20、PF-1、PF-7、QA-1a、QA-1b、QA-6	QA-1b 150 題：FN 0、FP 0（10-15，6.9）；QA-6 通過；PF-7 已證實列達標、未證實列未達標（DEF-11）
FR-02	網址查證	P0	FN-2a、FN-2c	通過（pytest）
FR-03	圖片查證	P1	FN-2b	後端端點已有；上傳介面尚未開放
FR-04	結果頁 `/r/{id}`	P0	FN-3、FN-21、UI-1、UI-2、OP-8	FN-3、FN-21、UI-2、OP-8 通過；UI-1 未執行
FR-05	分享到 Threads	P0	UI-7、UX-1（T4）	UX-1 待執行
FR-06	熱門牆	P0	FN-16、UI-1	FN-16 通過
FR-07	知識庫搜尋	P0	FN-8	通過
FR-08	查證歷史	P0	UI-1	前端單元測試通過；UI-1 未執行
FR-09	Threads @機器人回覆	P0	FN-4、FN-5、FN-22、OP-4～OP-6、OP-10、PF-3a、PF-3b	2026-10-01 實機串接成功（`threads_live_log.md`）；FN-22 通過；OP-10 未執行（DEF-13）
FR-10	模擬 Threads 模式	P0	OP-3、FN-4	通過
FR-11	機器人狀態頁 `/bot`	P0	OP-3、UI-1（S6）	頁面 2026-09-30 上線；截圖檢核未做
FR-12	每日查核貼文	P2	—	不在範圍
FR-13	隱私與資料刪除靜態頁	P0	UI-1	頁面已上線；UI-1 未執行
FR-14	AI 額度護欄	P1	FN-10、PF-5	每日 300 次上限已上線（`test_ai_budget.py` 通過）；PF-5 通過（6.2）
FR-15	工程清理	P0	OP-1、OP-7、QA-3、QA-4、QA-7	QA-7 通過
FR-16	來源分級與顯示	P0	FN-12、UI-8	通過
FR-17	知識庫寫入門檻	P0	FN-8、FN-11、FN-13	通過
FR-18	資料清洗	P0	OP-9、FN-14、QA-5	通過（2026-09-16）
FR-19	AI 來源規則	P0	FN-1、OP-2	通過
FR-20	查核結果回補	P1	FN-15、PF-7	FN-15 通過；回補造成的延遲見 DEF-11
FR-21	本站熱門查證	P1	FN-16	通過
FR-22	證據信心	P1	FN-17	FN-17 通過；正式站 2026-11-03 起因 DEF-13 無法算相似度
FR-23	查核結論同步	P1	FN-18、OP-11	FN-18 通過；OP-11 未通過（DEF-13）
FR-24	每週新查核自動評測	P1	FN-19、OP-12、QA-6	通過