長庚大學　資訊工程學系　軟硬體專題

AI 為核心的
假訊息驗證系統

系統名稱：全民查證公社

報告別	第四次進度報告（第二次簡報：使用情境文）
報告日期	2026 年 11 月
團隊成員	廖晢勛、石岱勳、姚睿、張宇宏、廖育翔
指導教授	黃崇源
系統網址	https://fakenewsverify.vercel.app
原始碼	github.com/cansfakenewsverify/AI-Fake-News-Verification-System

指導教授簽名

簽名：＿＿＿＿＿＿＿＿＿＿＿＿＿＿＿＿　日期：＿＿＿＿＿＿＿＿

一、這一期做了什麼

上次報告（2026 年 9 月）時，系統剛上線。這一期的重點不是再加新畫面，而是回答一個問題： **系統上線之後，怎麼維持準確、怎麼自動更新、外部服務出狀況時怎麼辦？** 這一期遇到兩次來自學校 AI 閘道的突發狀況（模型下架、向量服務關閉），兩次都是上線後才發現的， 處理經過與尚未解決的部分都照實寫在本報告中。

這一期完成的項目：

1. **換模型救急（9 月 30 日）**：學校閘道無預警下架原本使用的模型，正式站所有沒查過的內容都顯示 「AI 分析暫時無法使用」，卻沒有人發現。改用新模型 `gpt-5.6-luna`，並加上備援模型與「模型清單檢查」， 下架時 GitHub Actions 會變紅並寄信通知。
2. **知識庫自動成長**：每天兩次自動同步 MyGoPen、台灣事實查核中心、Cofacts 的新查核結論。 已證實的知識庫資料從上次報告時的 128 筆，成長到約 1.88 萬筆（2026 年 11 月 4 日查正式站為 18,825 筆已證實；後文向量重算的 18,922 列還包含未證實的列）。
3. **每週自動評測**：每週日用學校每週剩下的額度，拿「模型推出後才發布的新查核」測驗系統， 報告自動存回版本庫。目前已累積五次（10 月 5 日～11 月 2 日）。
4. **判定校準**：每週評測發現系統常把真的內容判成假的。調整後，AI 在查不到可以確認的資料時改回答「無法查證」（黃燈），歷史風險題被判成安全的比例從 10.4% 降到 2～5%（10–19、10–26 約 2%；11–02 閘道不穩，為 4.7%）， 代價是一部分謠言改判「無法查證」，與固定答案的一致率下降（見第四節）。
5. **證據信心**：信心程度不再由 AI 自評，改依規則表決定（有沒有查核機構已證實的相似內容等）， 結果頁並列出「知識庫中的相似查證」。
6. **Threads 機器人實機串接並搬上雲端（10 月 1 日）**：機器人帳號可以真的回覆貼文，每 30 秒檢查一次提及， 狀態存在資料庫、重啟不會重複回覆。仍是 Meta 開發模式，只回覆測試人員。
7. **影片與文件**：開箱簡報影片改為男聲口語版並加上配樂與音效（v1.3）； 完成第二次簡報的情境劇《轉傳之前》（3 分 36 秒）；測試計畫書升為 v2.1（完整版）並另出短版測試報告書； 完成兩張 A1 專題介紹海報。
8. **外部事件：學校關閉向量服務（11 月 3 日）**：語意比對停用。當天上線關鍵字比對作為備援， 但備援有誤命中（見第六節）。
9. **改用新的向量模型 bge-m3（11 月 5～6 日）**：學校改由新服務提供向量，只有 `bge-m3`（1024 維）， 和原本的 1536 維不能互比。已改程式（**已合併進主線，但尚未推上線**）、重新校準相似度門檻（0.75 → 0.84），並把正式資料庫 18,922 列全部重新算過向量（舊向量保留，可退回）。**所以正式站目前語意比對仍停用，驗證尚未完成** （見第六節）。

二、系統在做什麼

使用者把收到的可疑訊息（文字或網址）貼到網站上，系統判定它是**詐騙**、**假訊息**、 還是**查無異常**，以紅黃綠燈呈現，並附上已經做出判定的查核來源。判不出來的內容標為 「無法查證」（黃燈）。每一筆結果都有自己的網址，可以複製連結或分享到 Threads。

這一期的第二次簡報要求「使用情境文」：情境劇《轉傳之前》用兩個日常情境——家族群組轉傳的冷水煮蛋小知識 （貼文字查證）、Threads 上流傳的法國暴動「唯獨豬肉沒人搶」AI 圖（標記機器人）——呈現使用系統前的困擾與使用後的好處。 影片的網站畫面全部是正式站實錄；Threads 段因機器人實機錄影沒有進行，畫面是片中標明的示意畫面。

除了單筆查證之外，網站還有三個部分：

- **熱門牆**：「查核機構最新」彙整 MyGoPen、台灣事實查核中心與 Cofacts 的查核結果； 「本站熱門查證」列出最近 7 天大家查最多的已證實內容。
- **知識庫**：所有查證過而且有來源佐證的內容，可以搜尋與依判定篩選。
- **Threads 查核機器人**（`@factcheck_tw_bot`）：在可疑貼文底下標記機器人， 它會回覆判定、來源與結果頁連結。目前是測試版，只有被加入測試名單的帳號收得到回覆 （2026 年 10 月 3 日決定先不送 Meta App Review）。

三、系統架構

```
瀏覽器
  └ Vercel（前端：React 靜態檔；/api/* 同源代理）
       └ Render（後端：FastAPI）
            ├ Supabase PostgreSQL + pgvector（知識庫、結果、熱門、用量、Threads 機器人狀態）
            ├ 長庚 CGU AIR 閘道（判讀模型 gpt-5.6-luna，備援 gpt-6-luna）
            │     向量模型：text-embedding-3-small 於 2026-11-03 停供，改用 bge-m3（1024 維；
資料庫 11-06 已換，程式待上線）
            └ Threads API（機器人每 30 秒檢查提及）
GitHub Actions：ci（每次提交） / factcheck-sync（每天兩次） / weekly-eval（每週日） / keepalive（每
10 分鐘）
```

金鑰只存在三個地方：負責人本機的設定檔、Render 後台，以及 GitHub 的加密 secret。 版本庫是公開的，裡面不含任何金鑰。

判讀流程：先找答案，找不到才問 AI

呼叫大型語言模型是整個系統最貴的一步，所以設計了多層比對，前面的層命中時就不呼叫 AI：

層	比對方式	說明	實測延遲
L1	內容雜湊	完全相同的內容直接沿用先前的判定。	213 ms（9/16）
L2	向量語意相似	換句話說也認得。只比對已經證實的資料列。舊模型的門檻 0.75； **11-03 起停用**（學校關閉向量服務，DEF-13），11-06 改用 bge-m3 並重新校準，門檻改為 **0.84**（資料庫已重算；程式尚未上線，所以正式站目前仍停用）。	約 3.1 秒（9/16，舊模型）
L2 備援	關鍵字比對	11-03 上線：算不出向量時改用關鍵字找查核報告。結果頁標「關鍵字比對」，不假裝是語意比對。 有誤命中（DEF-14）。	11～35 秒（11-03）
L3	AI 判讀	前面都沒中才呼叫一次模型；判讀對象一律是使用者的原文。4.8 秒是語意比對正常時的 150 題數字； 向量停用期間未命中的查證實測約 28 秒（11-03，11 句），未達 15 秒的準則。	p50 4.8 秒（10/15）

上線護欄與額度

項目	設定值	目的
每日 AI 呼叫上限	300 次 / 日	控制學校提供的額度；達上限後仍可回覆快取命中的內容。
每個 IP 的頻率限制	30 次 / 分、200 次 / 時	避免單一來源大量佔用。
請求與上傳大小	1 MB / 圖片 10 MB	避免超大請求拖垮免費主機。
每週評測的額度	最多 USD 6，保留 USD 3	學校每週額度為 USD 10；先留 3 美元給網站使用者，評測只用剩下的。

四、評測結果

150 筆固定題庫

自建 150 筆已標註的訊息資料集（詐騙、假訊息、安全各 50 筆），其中刻意放入「看起來像詐騙的合法官方訊息」 作為難題。每次換模型或調整判定規則就重跑一次：

> 名詞：**漏判**＝有風險的內容被判成安全；**誤報**＝安全的內容被判成有風險； **p50**＝一半的查詢在這個秒數內完成；**P0 / P1**＝必過項目 / 重要項目。

日期	判讀模型 / 設定	準確率	漏判	誤報	說明
2026-06	gpt-5-mini	96.0%	0	5	誤報全是把反詐宣導、政府補助公告判成詐騙。
2026-09-16	gpt-5.4-mini	100%	0	0	上次報告的數字；該模型 9/30 被閘道下架。
2026-09-30	gpt-5.6-luna	96.7%	0	5	換模型後；5 筆誤報都是官方公告被判成假訊息。
2026-10-15	gpt-5.6-luna＋判定校準 v4	78.7%＊	0	0	風險題 100 題全判對；安全題 50 題中 18 題判安全、32 題判「無法查證」（全是官方公告類）。

＊「無法查證」算答錯的嚴格算法。換成「作答率」看：作答 118 / 150（78.7%），作答的全部判對。依原準則（準確率 ≥ 93%）嚴格算法未達標，準則是否修訂待審查者裁定。

在這 150 題固定題庫上，四次評測都沒有把任何詐騙或假訊息判成安全（漏判為 0）； 但這組題庫已公開且飽和，不代表實際表現（見下一小節）。校準 v4 的取捨是： 把「查不到」的內容誠實標成「無法查證」，而不是硬猜安全或假訊息。

每週新查核自動評測（模型沒看過的題目）

固定題庫已經飽和，所以另外每週用「當週新發布的查核結論」測驗，最接近上線後的真實表現。 下表為五次評測的對照（「歷史抽樣」取自知識庫，可能出現在模型的訓練資料中，數字偏樂觀）：

指標	10–05 校準前	10–12 v2	10–19 v4	10–26 v4	11–02 v4＊
歷史風險題被判安全（漏判）	10.4%	12.8%	**2.0%**	**2.1%**	4.7%
歷史風險題判無法查證	0%	0%	14.5%	14.5%	6.8%
歷史安全題被判紅燈（誤報）	68.5%	55.0%	54.0%	51.9%	（無安全題）
本週新查核的漏判	6 / 41	4 / 24	1 / 29	1 / 32	0 / 9
本週新查核風險判定一致率	84.1%	76.9%	65.5%	71.9%	88.9%

＊11 月 2 日那週學校閘道不穩：本週新查核 20 題只有 9 題有效，歷史抽樣 660 題只有 337 題有效，不能和前幾週直接比較。

> **如何解讀。**校準 v4 之後，漏判大幅下降，代價是一部分謠言從紅燈變成黃燈「無法查證」， 所以「一致率」（無法查證算不一致）下降。**安全題被判成紅燈的比例仍超過一半（51.9%）**， 代表系統對「真的內容」仍偏保守，這是已知的研究限制，也是下一步要降低的指標。 本週新查核的風險題每週只有 9～41 題，信賴區間很寬（例如 10–26 為 54.6%～84.4%），只看趨勢，不當作精確數字。

五、測試與品質

自動化測試

2026 年 11 月 3 日重跑：後端 970 項通過（另有 36 項需要真的資料庫的契約測試，在拋棄式的測試資料庫中全數通過）， 前端 410 項通過，前端檢查與建置無錯誤，正式站版本的 GitHub Actions 兩個工作都是綠燈。 這些測試全部離線執行、不消耗 AI 額度。**但離線測試發現不了「外部服務被關掉」這類問題**—— 模型下架與向量服務關閉都是這樣漏過去的，所以新增了模型清單檢查、`/health` 的向量狀態欄位， 以及同步時的向量檢查。

測試計畫書 TP–FNV–2026–01（v2.1）

依課程格式撰寫，目前共 62 個測試項目：通過 38、通過（待補驗）3、未通過 4、未執行 4、待審查裁定 1、報告後執行 12。 第二次簡報輪次新增的 16 項（P0 共 4 項、P1 共 12 項）結果如下：

範圍	結果	說明
P0（4 項）	通過 3、未執行 1	通過：FN–20（無法查證的契約）、QA–6（歷史漏判率 ≤ 10.4%）、QA–7（回歸全綠）。 未執行：OP–10（Threads 機器人實機回覆的正式驗證），負責人 11 月 3 日決定不錄 Threads 實機畫面，沒有排定執行。
P1（12 項）	通過 8、未通過 3、未執行 1	通過率 66.7%，**未達 80% 的準則**（未執行算未通過）。
整體判定	**本輪未達通過條件**	P0 未全數通過，P1 通過率不足；回歸條件（測試與建置全綠）達成。

未通過與未執行的項目，原因都寫明，沒有為了讓它通過而調整準則或門檻：

項目	狀態	說明
OP–11	未通過	查核同步最近 30 次成功 25 次（83.3%），未達 90%。10 月 31 日起因向量服務關閉連續失敗 5 次； 11 月 2 日深夜（UTC；台灣時間 11 月 3 日凌晨）備援上線後恢復成功。窗口中的失敗要約 2 週才會移出。
PF–7	未通過	快取命中延遲：命中「已證實」列 p50 1.22 秒（達標）；命中「未證實」列 p50 12.61 秒（準則 5 秒）。 已改成不再重新算向量，但只快了一點，真正耗時的步驟還沒查明（DEF–11）。
UX–2	未通過	情境訊息的判定與查核來源一致（原文 1、2 各查兩次，皆為假訊息並附查核中心報告）；未達的部分是影片的 Threads 段不是全部實錄。
UX–1	未執行	第三方實測（5～8 位非組員）原排 10 月 27～29 日，沒有進行；作業包（說明、題卡、記錄表、問卷）已備妥。
PF–2	未通過（第一輪遺留）	語意快取命中率 50%（9 月 21 日以組員審定的 20 句重測），低於 70%。**沒有為了通過而調低 0.75 的門檻**。 11 月 3 日以關鍵字備援再量一次：正確 10 句（50%）、相關但不算同一則 2 句、錯誤 2 句，同樣未達。
UI–1、UI–6	未執行（第一輪遺留）	介面逐格檢核需非實作組員勾核；簡繁與英文字檢查需先界定允許清單。均非測試失敗，依原準則追蹤。

缺陷與處置

編號	狀態	說明
DEF–10	已修正	閘道下架模型，正式站所有新內容判讀失效（9/30）。改用新模型＋備援＋模型清單檢查，並在正式站實測確認。
DEF–12	已修正	結果頁分類命中查核機構資料時一律顯示「其他」，已改為顯示「已查核假訊息」等（10/26 上線）。
DEF–11	未修復	命中未證實列時要 12～16 秒（見上表 PF–7）。
DEF–13	處理中（外部原因）	學校 2026–11–03 起關閉 embedding：呼叫回 404。不是本系統的程式錯誤，但使用者看到的結果受影響。 11–03 先上線緩解（關鍵字備援）；11–05 學校改由新服務提供 bge–m3，11–06 完成程式修改、門檻重新校準（0.84： 40 句改寫句有 28 句命中原文，50 題安全訊息誤命中 0 題）與整庫重算（18,922 筆）。 **正式站驗證未完成**：11–06 查正式站健康檢查，向量仍是逾時（ReadTimeout），因為程式尚未上線、正式站還是舊程式。 待推上線並刪除 Render 的 `EMBED_API_KEY` 後，重測 PF–2、OP–11、UX–2，才能關閉。
DEF–08	待審查裁定	錯誤橫幅與輸入驗證的紅字用了判定色，與「紅黃綠只用於判定」的規格文字衝突（規格文字問題，非實作缺陷），待審查者擇一。
DEF–14	未修復	關鍵字備援會誤命中：PF–2 的 10 筆命中人工看過，6 筆正確、2 筆相關、2 筆錯誤（很短的詐騙話術配到別的詐騙訊息）。 判定多半仍是紅燈，但附的來源是錯的。已開票修正（B–51）；備援可由設定值一鍵關閉。
DEF–03、04	未處理	知識庫頁同一主張出現兩張卡且標籤不同；少數已證實列的「主張」其實是查核文章標題。待負責人逐筆人工確認。

六、誠實交代的限制

1. **語意比對剛換模型，正式站尚未驗證完。**學校 2026–11–03 停供向量服務，11–05 改由新服務提供 bge–m3。資料庫（18,922 列）已換好、相似度門檻已重新校準為 0.84，程式已合併但**尚未推上線**（還要刪除雲端的舊向量金鑰設定）、 上線後的重測（PF–2、OP–11、UX–2）尚未做，所以**本報告的測試結果仍是 11 月 3 日、語意比對停用期間的數字。** 在驗證完成前，換句話說的謠言可能查不到查核來源，備援的關鍵字比對也有誤命中（DEF–14）。 新門檻是用既有的 40 句改寫句與 150 題校準，樣本小，仍需線上資料檢驗。
2. **系統依賴學校閘道，這一期發生兩次無預警變動。**9 月 30 日模型下架、11 月 3 日向量服務關閉， 都是上線後才發現。已加上偵測，但閘道是唯一的 AI 來源，沒有第二個供應商可以自動切換。
3. **固定題庫已飽和且公開**，100% 或 0 漏判不能解讀成「系統不會出錯」。 可信的指標是每週新查核評測，而它每週樣本只有 9～41 題。
4. **對「真的內容」仍偏保守**：歷史安全題被判紅燈的比例是 51.9%（10 月 26 日），降低誤報是下一步。
5. **尚未做使用者實測**（UX–1）。系統的可用性目前只有團隊內部的操作紀錄，沒有非團隊使用者的達成率與問卷數據。
6. **Threads 機器人仍是測試版**：只回覆測試人員；影片中的 Threads 段是示意畫面； 10 月 1 日機器人已有實機回覆的紀錄，但這一期沒有做實機的正式驗證項目（OP–10）。授權約 2026 年 12 月 29 日到期，屆時要重新授權。
7. **免費雲端方案的限制**：後端 15 分鐘沒有流量會休眠，喚醒約需 1 分鐘（已用定時叫醒降低影響）； 每週自動評測的排程在 GitHub 上常比設定的時間晚 3～5 小時才開始。
8. **AI 判讀僅供參考**：網站每一頁都標示判讀由 AI 自動產生、可能有誤，請使用者自行查證， 並提供隱私政策與資料刪除說明。

七、下一步

1. 完成 bge–m3 上線：推上線並刪除 Render 的舊向量金鑰設定、確認向量檢查正常，並在正式站重測 PF–2、OP–11、UX–2，結果回填測試計畫書； 之後決定舊向量欄位何時清掉，並處理關鍵字備援的誤命中（B–51）。
2. 查明「命中未證實列」仍要 12 秒的真正原因（DEF–11），重測 PF–7。
3. 執行第三方實測（5～8 位非組員），把達成率與問卷結果回填測試計畫書。
4. 補做 UI–1（深色版全套截圖與非實作組員勾核）、UI–6（簡繁與英文字檢查）；處理 DEF–03、DEF–04；請審查者裁定 QA–1b 的準則（校準 v4 之後「作答的全對」是否可取代嚴格準確率）與 DEF–08。
5. 降低安全題的誤報（目前 51.9%），並累積更多週的新查核評測。
6. 開放首頁的圖片上傳介面（後端端點已具備檔頭檢查與大小限制）。
7. 2026 年 12 月 3 日期末成果展前，確認系統在學校閘道現況下的穩定度。

八、分工

成員	角色	這一期的工作與狀態
廖晢勛	組員 A · 測試負責人	系統實作、部署與維運（換模型、同步、備援比對）；測試執行與彙整；情境劇旁白；金鑰與資料管理。
石岱勳	組員 B · 介面測試	預定主持第三方實測與介面檢核勾核；**本期尚未進行**。
姚睿	組員 C · 績效與品質數據	9 月 21 日完成語意快取題組的審定與重測；預定記錄第三方實測；**實測本期尚未進行**。
張宇宏	組員 D · 文件與審查	審閱測試計畫書。
廖育翔	組員 E · 影片與簡報	簡報當天播放影片與回答提問。

九、附件與可查證的位置

項目	位置
線上系統	https://fakenewsverify.vercel.app
情境劇《轉傳之前》（3 分 36 秒）	https://fakenewsverify.vercel.app/demo/scenario_v1.mp4
開箱簡報影片 v1.3（4 分 41 秒）	https://fakenewsverify.vercel.app/demo/presentation_v1.mp4
原始碼	github.com/cansfakenewsverify/AI-Fake-News-Verification-System
測試計畫書（完整版）	docs/test/TP-FNV-2026-01.md（v2.1）；PDF 在 presentations/2026-11_第二次簡報/
測試報告書（短版，62 個案例總表）	docs/test/TP-FNV-2026-01_v2.1_報告版.md
每週評測報告	docs/test/results/weekly/
學校關閉向量服務的證據	docs/test/results/embedding_closed_2026-11-03.md
bge-m3 門檻校準報告	docs/test/results/bge_m3_calibration_2026-11-06.md
評測資料與結果	code/backend/data/eval_set.csv、eval_*.csv
規格與實作票	docs/rebuild/（共識、規格書、實作票、部署手冊）

本專題的程式實作與自動化測試執行，包括撰寫程式與測試碼、執行測試、評測與量測腳本、 以無頭瀏覽器擷取截圖與彙整紀錄檔，由 AI 程式開發助理 Claude Code（Anthropic）協助完成， 全程在負責人監督下進行。需要人工判斷的工作——介面勾核、資料清洗審閱、測試結論與簽核——由組員與審查者執行， 不由 AI 代為判定。此一說明同時記載於測試計畫書中。